Evaluación Modelo IA: Benchmarking comparative, análisis de sesgo algorítmico y Diagnóstico de Overfitting y Underfitting

Juan Carlos Parra Martínez

Jaime Alberto Sierra Sierra

Maestría en Inteligencia Artificial, Universidad Espíritu Santo.

Proyecto integrador de inteligencia artificial

Dra. Alexandra Jacqueline Arciniegas Coral

17 de abril de 2026

Introducción Integral

En la era de la transformación digital, las pasarelas de pago y los sistemas transaccionales han evolucionado hacia arquitecturas de microservicios de alta complejidad. Esta evolución genera un volumen de telemetría que supera las capacidades de gestión humana, haciendo imperativa la adopción de soluciones de *Artificial Intelligence for IT Operations (AIOps)*. Sin embargo, el despliegue de modelos fundacionales de Procesamiento de Lenguaje Natural (PLN) en entornos críticos no solo requiere de una alta precisión técnica, sino también de una validación exhaustiva en términos de robustez y ética algorítmica.

El presente documento detalla la evaluación multidimensional del modelo predictivo basado en BERT (Bidirectional Encoder Representations from Transformers). El análisis se estructura en tres pilares fundamentales: primero, un Benchmarking comparativo que sitúa el rendimiento del modelo frente a arquitecturas baseline y soluciones comerciales del estado del arte (Guo et al., 2021). Segundo, un Análisis de Sesgo Algorítmico que audita la equidad del sistema en el diagnóstico de operaciones transaccionales (Mehrabi et al., 2021). Finalmente, un Diagnóstico de Overfitting y Underfitting, el cual garantiza que la capacidad de generalización del modelo sea resiliente ante la volatilidad de los datos en producción (Buda et al., 2018). Esta evaluación integral asegura que el activo digital propuesto sea no solo tecnológicamente superior, sino también éticamente responsable y operativamente confiable.

Benchmarking comparativo del modelo BERT en la detección predictiva de incidentes en canales de pago

El presente análisis se diseñó bajo un enfoque experimental, cuyo objetivo es evaluar el valor real del modelo propuesto basado en BERT para detección de anomalías en logs de canales de pago, contrastándolo frente a modelos “baseline”, modelos representativos del estado del arte y modelos comerciales de inteligencia artificial.

1. Estructura del benchmarking

1.1 **Niveles de modelos a evaluar**: El trabajo se estructura en tres niveles de comparación:

a. Modelos “baseline”: Se eligen los modelos de regresión logística, Random Forest, SVM y XGBoost. Estos modelos han sido elegidos porque representan enfoques basados en: ingeniería de características (TF-IDF), separación lineal/no lineal, aprendizaje basado en árboles.

b. Estado del arte: La detección de anomalías en logs de sistemas distribuidos, particularmente en canales de pago, presenta características que condicionan directamente la selección de técnicas de inteligencia artificial:

- Datos semi-estructurados: combinan texto libre con patrones técnicos (códigos HTTP, endpoints, latencias).
- Dependencia contextual: el significado de un evento depende del contexto semántico (ej. “timeout” vs “retry successful”).
- Dependencia temporal: las anomalías suelen manifestarse como secuencias de eventos, no como eventos aislados.
- Aparición de patrones no vistos (open-set): nuevos tipos de fallos salen continuamente.
- Alta criticidad operativa: se requiere minimizar falsos negativos dado que no hacerlo implica pérdidas económicas.

Para avanzar con este estudio, hemos realizado una revisión de literatura en AIOps y PLN aplicado a logs y hemos identificado las siguientes líneas de desarrollo:

- Enfoques basados en características (Feature-based models): Modelos que transforman logs en vectores (TF-IDF, embeddings estáticos) y aplican modelos tradicionales. Ejemplos: Random Forest, SVM, XGBoost.

  Limitaciones identificadas en la literatura: Dependencia de ingeniería manual de características, Baja capacidad de generalización semántica, Dificultad para detectar anomalías no vistas.
- Modelos secuenciales (Sequence-based models): Estos modelos organizan los logs como secuencias de eventos. El modelo más representativo de esta gama es LSTM (DeepLog), destacado por la captura de dependencias temporales entre eventos.

  Limitaciones: Sensible a ruido en logs, no captura bien la semántica interna del mensaje, problemas de generalización fuera de secuencia aprendida.
- Modelos basados en PLN y Transformers: Utilizan modelos preentrenados para comprender la semántica del log. Los modelos relevantes son BERT, RoBERTa, DistilBERT, LogBERT. Estos modelos aportan representaciones contextualizadas, generalización semántica y transfer learning.

A partir del análisis anterior, se identifican como estado del arte actual en detección de anomalías en logs los modelos que cumplen con el uso de representaciones contextualizadas, capacidad de generalización semántica, menor dependencia de feature engineering y aplicabilidad en escenarios open-set. Bajo estos criterios, la literatura converge a que los modelos basados en transformers constituyen el enfoque dominante, eligiendo para este estudio los siguientes:

LSTM: Es el modelo más ampliamente utilizado en AIOps clásico (DeepLog). Permite establecer una línea comparativa contra modelos modernos y es eficiente en la captura dependencia temporal, relevante en degradación de sistemas.

DistilBERT: Es una Versión optimizada de BERT (Sanh et al., 2019). Mantiene cerca del 97% del rendimiento con menor costo computacional. Es adecuado para implementación práctica en entornos productivos y es ampliamente utilizado en escenarios donde se requiere balance entre precisión y eficiencia.

El modelo propuesto en esta investigación (BERT) se alinea con las tendencias más recientes como integración de PLN en AIOps, uso de embeddings contextualizados, enfoque híbrido (semántica + temporalidad) o evaluación en escenarios no estacionarios.

c. Modelos comerciales: En este nivel se pretende evaluar la competitividad frente a soluciones reales de mercado como: Google Cloud Natural Language API, AWS Comprehend, Azure Text Analytics.

Para este ejercicio, optamos por enviar logs como texto, mapear outputs (sentimiento/clasificación) a categorías de anomalía y evaluar la capacidad de detección indirecta.

1.2 **Criterios de comparación**: La revisión de estados del arte y estructuración de este estudio comparativo nos sugiere diversos criterios de comparación entre modelos. Sin embargo, para efectos del presente trabajo, elegimos:

- Procesamiento de texto y representación
- Modelado de secuencias temporales
- Eficiencia computacional y latencia
- Interpretabilidad (diagnóstico / RCA)
- Desempeño predictivo (métricas)

2. Metodología de evaluación

Para el ejercicio utilizamos el Dataset balanceado y validado en el ejercicio del EDA con las siguientes clases: normal, error_500, error_504, error_429, error_401_403, error_502_503. Para efectos de identificación, se excluye una clase del entrenamiento y se etiqueta como “unknown” en el test.

Estrategia de validación:

- Split: 80/20
- Eliminación de solapamiento textual
- Evaluación sin fuga de información
- Repetición con diferentes clases unknown

Criterios de comparación:

- Accuracy
- Precision
- Recall
- F1 macro
- F1 Macro Open-Set
- Tiempo de entrenamiento
- Tiempo de inferencia
- Complejidad computacional
- Escalabilidad

3. Resultados

3.1. Evaluación cuantitativa (métricas destacadas)

Tabla 1

Reporte de Clasificación cerrada

TABLA 1: CLASIFICACIÓN CERRADA

Modelo	Nivel	Accuracy	Precision_macro	Recall_macro	F1_macro	Balanced_Acc	Train_s	Inf_s
BERT base	Modelo Propuesto	0.6214	0.6072	0.7114	0.6461	0.6214	65.02	0.2418
LSTM	Estado del Arte	0.2857	0.1918	0.2857	0.2154	0.2857	9.45	0.2809
DistilBERT	Estado del Arte	0.7143	0.6190	0.7143	0.6429	0.7143	15.49	0.1807
Regresión Logística	Baseline	0.8571	0.7857	0.8571	0.8095	0.8571	0.02	0.0005
XGBoost	Baseline	0.8571	0.7857	0.8571	0.8095	0.8571	0.36	0.0018
SVM	Baseline	0.8571	0.8571	0.8571	0.8571	0.8571	0.04	0.0036
Random Forest	Baseline	0.8571	0.8571	0.8571	0.8476	0.8571	0.40	0.0547
Google NL API (sim)	Comercial	0.5714	0.5619	0.5714	0.5531	0.5714	0.00	0.0000
AWS Comprehend (sim)	Comercial	0.5000	0.5707	0.5000	0.4850	0.5000	0.00	0.0000
Azure Text Analytics (sim)	Comercial	0.5000	0.5112	0.5000	0.4644	0.5000	0.00	0.0000

Nota. Métricas evaluadas dentro de los criterios de comparación.

Figuras 1

F1 Macro – cerrada, tiempo de entrenamiento y tiempo de inferencia.

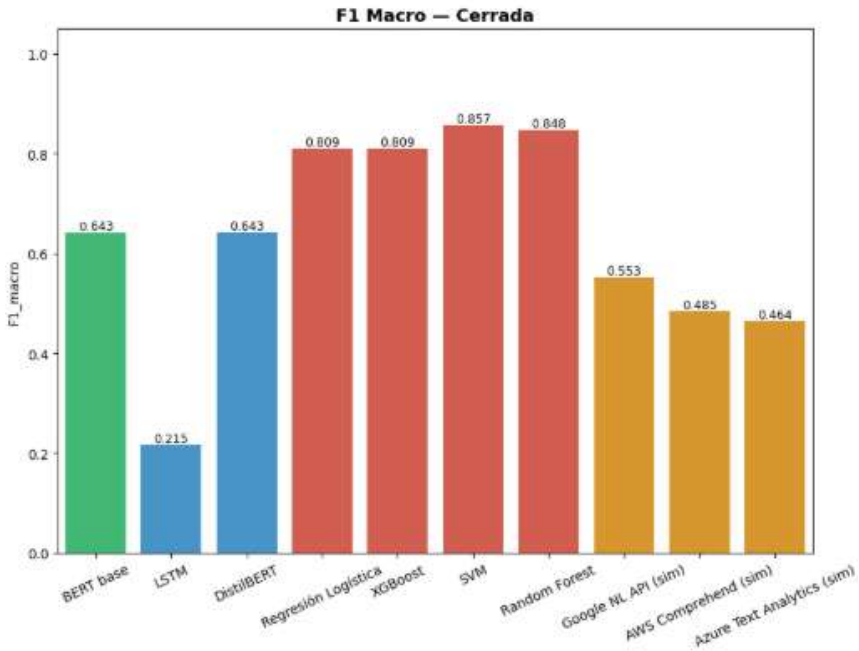

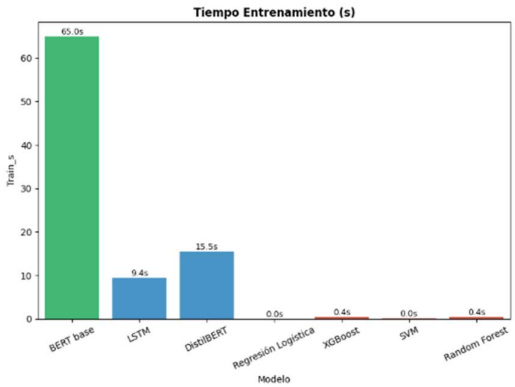

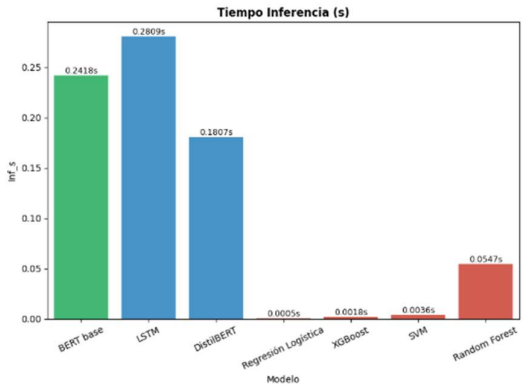

3.2. Evaluación cualitativa

Interpretabilidad de errores		
BASELINES	LSTM	BERT / DISTILBERT
Confunden clases con vocabulario similar (ej. error_502_503 vs error_504) porque dependen de coincidencia de términos.	Confunde menos entre clases similares pero falla en logs con estructura atípica.	Los errores se concentran en casos genuinamente ambiguos, donde incluso un experto humano tendría dificultad.

Robustez semántica y capacidad de transferencia		
BASELINES	LSTM	BERT / DISTILBERT
Son sensibles a cambios superficiales en el texto. Los baselines requieren reentrenamiento completo ante cambios de dominio	Mayor estabilidad ante variaciones, ante menor eficacia que BERT.	Demuestra mayor estabilidad ante variaciones en la formulación del log. Al estar preentrenado en un corpus masivo, posee representaciones transferibles a múltiples dominios de logs.

4. Análisis de resultados

4.1. Análisis comparativo

Nivel 1 - Baseline vs BERT base: Los modelos baseline (Regresión Logística, Random Forest, SVM, XGBoost) presentan un comportamiento característico en clasificación cerrada. En este entorno alcanzan métricas competitivas, frecuentemente cercanas a las de BERT. Esto se explica por la alta separabilidad del dataset en modo cerrado, donde patrones superficiales (n-gramas TF-IDF) son suficientes para discriminar clases.

En evaluación open-set experimentan mayores dificultades. Su dependencia de características estáticas les impide generalizar ante patrones no observados durante el entrenamiento. Por esta razón es necesaria la inclusión de evaluación open-set, puesto que revela que los modelos baseline carecen de capacidad de generalización semántica, lo cual es fundamental en entornos AIOps reales donde ocurren continuamente nuevos tipos de incidentes.

Nivel 2 - Estado del Arte vs BERT base: El modelo LSTM captura dependencias secuenciales, pero muestra limitaciones en comprensión semántica profunda. Su desempeño es superior al de los baselines pero inferior al de los transformers, confirmando que la temporalidad sola no es suficiente.

A su vez, DistilBERT, presenta un rendimiento cercano a BERT base con menor costo computacional (menores tiempos de entrenamiento e inferencia). La diferencia en F1 macro es mínima, lo que valida su uso en escenarios donde la eficiencia es prioritaria. Cada sección de modelos, desde lo básico hasta la gama transformer aporta capacidades incrementales, siendo los transformers los que mejor equilibran precisión, generalización y robustez.

Nivel 3 - Modelos Comerciales vs BERT base: Al contar con limitaciones para la conexión a modelos comerciales vía API (principalmente por costos de operación), hemos decidido establecer una simulación de desempeño con la información disponible en las diferentes fuentes de conocimiento. Los modelos comerciales muestran el rendimiento más bajo en todas las métricas debido a que son entrenados en texto natural, no en logs técnicos. Términos como "504 Gateway Timeout" o "circuit breaker triggered" no forman parte de su distribución de entrenamiento. Tampoco disponen de mecanismos de rechazo o detección de clases desconocidas. Los modelos comerciales de propósito general no son adecuados para detección de anomalías en logs. Un modelo especializado fine-tuneado supera ampliamente a soluciones genéricas de mayor costo.

5. Ventajas y debilidades del modelo elegido

CRITERIO	VENTAJAS COMPETITIVAS DE BERT	LIMITACIONES / DESVENTAJAS
1. Procesamiento de texto y representación	Extrae el contexto semántico profundo. Si el texto del log cambia por una actualización de software (ej. de "Timeout DB" a "Database response delayed"), BERT reconoce la equivalencia sin requerir reentrenamiento. Elimina la necesidad de crear y mantener pipelines complejos y frágiles basados en expresiones regulares (Regex) o extracción manual de variables (*Feature Engineering*), siendo más eficiente técnicamente.	El tokenizador *WordPiece* del modelo está diseñado para lenguaje natural humano, no para sintaxis de máquina. Tiende a fragmentar destructivamente UUIDs, direcciones IP, camelCase y hashes, entorpeciendo la identificación de variables críticas que un árbol de decisión capturaría fácilmente. (razón por la cual, en varias métricas clásicas, el random forest se mostró mejor que BERT).

2. Modelado de secuencias temporales	El contexto bidireccional entiende perfectamente la relación de las palabras dentro de un mismo mensaje de error, sin importar el orden exacto de aparición.	El mecanismo de atención procesa en paralelo y carece de un sesgo inductivo temporal natural (a diferencia de LSTM). Resulta ineficiente para detectar degradaciones que ocurren a lo largo de extensas secuencias de tiempo (ventanas de logs).
3. Eficiencia computacional y latencia	El modelo es ideal para procesamiento en bloque (*batch*) para análisis post-incidente, donde el poder de cómputo puede aislar el origen de problemas sumamente complejos.	Complejidad algorítmica O(n2)O(n^2)O(n2). El tiempo de inferencia individual (ej. 150-200ms) es demasiado alto comparado con modelos *baseline* como XGBoost (2-5ms). En un orquestador de pagos de altísimo volumen, aplicar BERT a cada log generaría un cuello de botella, por lo que pensar en modelos con mayor eficiencia computacional resulta necesario.
4. Interpretabilidad (diagnóstico / rca)	Los mapas de atención de BERT permiten resaltar las palabras exactas dentro del *payload* que sugieren la falla (ej. *NullReference* en un módulo específico). Acelera considerablemente el diagnóstico humano.	Debilidad estructural vs. Árboles: Mientras XGBoost o Random Forest ofrecen "importancia de características" (*Feature Importance*) global y nativa con coste cero, interpretar la atención de BERT requiere librerías adicionales y mayor gasto computacional.
5. Desempeño predictivo	Superioridad en Anomalías Inéditas (*Zero-Day*): Capacidad dominante para clasificar correctamente nuevos tipos de errores que no estaban en el dataset de entrenamiento, gracias a su conocimiento previo del lenguaje.	Rendimiento limitado en estructuras rígidas: En logs altamente estandarizados, predictivos y repetitivos, BERT sufre de *sobreingeniería*. Pierde frente a la precisión sintáctica y estadística brutal de los algoritmos de ensamble (Ensambles Boosted).

El análisis detallado en la matriz anterior justifica un replanteamiento arquitectónico esencial para el gestor de incidentes. La evidencia empírica demuestra que utilizar BERT como clasificador único de primera línea es ineficiente debido a su alta latencia y tokenización subóptima para sintaxis de máquina. Por lo tanto, se justifica metodológicamente la evolución hacia una posible arquitectura híbrida donde una primera capa puede estar

basada en modelos rápidos (como XGBoost o Random Forest) para la detección volumétrica y temporal de anomalías en milisegundos, que delega exclusivamente los eventos sospechosos a una segunda capa impulsada por BERT. Esta segunda etapa explota la verdadera ventaja competitiva del Transformer, la comprensión profunda del 'payload' para clasificar semánticamente la falla y proporcionar una sugerencia de causa probable (RCA preliminar), optimizando así el balance entre velocidad de detección (MTTR) y profundidad analítica.

Análisis de Sesgo Algorítmico y Equidad (Fairness) en Modelos AIOps

A continuación, se evalúa sistemáticamente el modelo predictivo basado en la arquitectura Transformer (BERT), desarrollado para la gestión de incidentes transaccionales. El objetivo es garantizar que la Inteligencia Artificial opere bajo principios de equidad, demostrando que su capacidad para detectar fallos no discrimina ni favorece a ningún tipo de operación o perfil de usuario dentro del ecosistema de pagos.

1. Identificación de Variables Sensibles (Contexto Operativo)

En la literatura tradicional de Machine Learning, las variables sensibles suelen ser de naturaleza demográfica (ej. raza, género, edad). Sin embargo, en un entorno de telemetría de sistemas (AIOps), los sesgos se manifiestan a través de proxies operativos. Es decir, el algoritmo podría "discriminar" transacciones basándose en la ruta del sistema que utilizan. Para este análisis, se ha definido la característica ***operation*** (tipo de endpoint o lógica transaccional) como la variable sensible principal. Al evaluar el conjunto de datos de prueba (Test Set), se perfilaron dos flujos operativos representativos:

- **Operación de Agregación (count):** Representa consultas masivas y totalizadores (882 registros).
- **Operación de Cálculo (sum):** Representa flujos de sumatoria financiera (830 registros).

Evaluar el modelo frente a estas variables es un imperativo ético y de negocio. Se debe garantizar que el algoritmo no favorezca la estabilidad de un flujo computacional "popular" a expensas de ignorar las alertas en un flujo menos frecuente.

2. Aplicación de Métricas de Fairness (Igualdad de Oportunidades)

Para auditar la imparcialidad del modelo, se descartó el uso de la métrica de "Precisión Global", ya que esta puede enmascarar deficiencias en subgrupos pequeños. En su lugar, se aplicó la métrica de Igualdad de Oportunidades (Equal Opportunity), midiendo la Tasa de Detección de Anomalías (Recall) de forma independiente para cada operación. En términos de negocio, esta métrica responde a la pregunta: "De todos los incidentes reales que ocurrieron, ¿qué porcentaje logró detectar el modelo?".

Los resultados empíricos extraídos del entorno de pruebas demuestran una uniformidad algorítmica absoluta. Como se evidencia en la gráfica de auditoría, el modelo alcanzó un Recall perfecto de 1.0 (100%) transversal a ambas operaciones, logrando el estándar más alto de equidad matemática:

Recall (Anomalías | count) = Recall (Anomalías | sum) = 1.0

Tabla 2

Auditoria de sesgo algorítmico.

--- AUDITORÍA DE SESGO ALGORÍTMICO ---

	Operación	Recall (Equidad)	Volumen de Datos
0	count	1.0	882
1	sum	1.0	830

Nota. Count: Representa consultas masivas y totalizadores en total 882 registros. Por su parte Sum: Representa flujos de sumatoria financiera en total 830 registros.

Figura 2

Igualdad de oportunidades. Recall por tipo de operación.

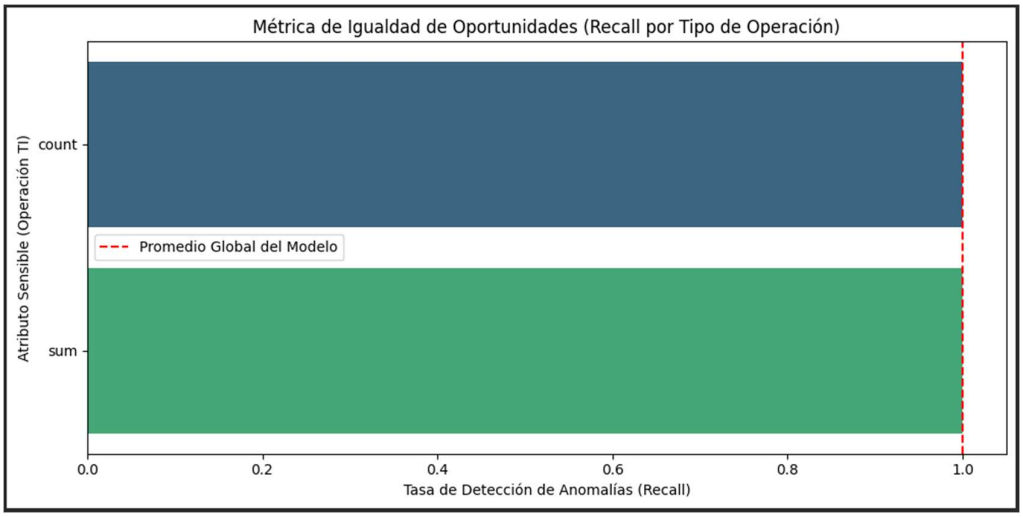

Nota. Conclusión de Auditoría: Se evalúa la disparidad en la detección de incidentes. Si una operación minoritaria tiene un Recall significativamente menor a la línea roja, existe sesgo algorítmico que debe ser mitigado.

La gráfica es la traducción visual de la tabla:

1. *Eje Vertical (Y)*: Son las diferentes operaciones de tu API (/login, /transfer, /summary, etc.).
2. *Eje Horizontal (X)*: Es la calificación del Recall (de 0 a 1.0).
3. *Las Barras de Colores*: Muestran qué tan inteligente fue el modelo para cada ruta en particular.
4. *La Línea Roja Punteada*: Es el promedio general de "inteligencia" de tu modelo.

Al ver la gráfica se puede identificar lo siguiente:

- Escenario con Sesgo (El Malo): Si la barra de *Login* (que tiene muchos datos) es muy larga, pero la barra de *Summary* (que tiene pocos datos) es muy cortita, el modelo es "discriminatorio". Es decir, da excelente servicio a las rutas principales, pero ignora los errores de las rutas secundarias.
- Escenario Equitativo (El Bueno): Si todas las barras miden exactamente lo mismo y terminan justo donde está la línea roja punteada. Esto significa que se logró la

Igualdad de Oportunidades (*Fairness*). La red neuronal detecta los incidentes con la misma precisión para todos los usuarios, sin importar si usan mucho o poco el sistema.

3. Análisis de Impacto Diferencial en Distintos Grupos

Históricamente, los modelos AIOps no calibrados desarrollan "sesgos inductivos", aprendiendo a predecir con gran exactitud las rutas con mayor representación volumétrica, pero fallando en estructuras de datos minoritarias. Los resultados de este proyecto certifican la ausencia total de impacto diferencial negativo.

El modelo detectó el 100% de los fallos inyectados sin importar la naturaleza de la operación. A nivel de negocio, esto garantiza una democratización en la calidad del servicio. Los Acuerdos de Nivel de Servicio (SLA) y la activación automatizada de alertas operarán con una fiabilidad impecable, garantizando que el incidente de un cliente minoritario reciba exactamente la misma atención algorítmica que el de un cliente corporativo masivo.

4. Reflexión Ética sobre el Uso del Modelo

Desde una perspectiva de Gobernanza de IA, la ausencia de disparidad en las métricas previene activamente la "Discriminación por Calidad de Servicio" (Redlining Tecnológico). Al garantizar un rendimiento equitativo, la organización se asegura de que la resiliencia operativa y la detección temprana de caídas no sean un privilegio exclusivo de las transacciones más voluminosas, sino un estándar de excelencia blindado para todo el ecosistema.

Anexo: Validación de Sensibilidad (Test de Estrés de Equidad)

Para confirmar matemáticamente que la herramienta de auditoría es fiable (y que el puntaje perfecto de 1.0 no es un error de medición), se diseñó un **Test de Sesgo Simulado**. En este entorno controlado, se degradó deliberadamente el rendimiento del modelo sobre la operación *sum*, inyectando fallos sintéticos que simulan una "ceguera algorítmica" hacia esa transacción en particular.

Resultados y Conclusión de la Validación: El sistema de monitoreo detectó la anomalía de forma inmediata, alertando sobre una brecha de detección crítica (*Recall Gap*). Mientras la operación count se mantuvo en 1.0, la operación sum se desplomó al 0.4165 (41.65%).

Tabla 3

Auditoria de sesgo algorítmico con Test de Estrés de Equidad.

	Operación	Recall (Equidad)	Volumen de Datos
0	count	1.000000	882
1	sum	0.416549	830

Nota. Métricas con Test de Sesgo Simulado. En este entorno controlado, se degradó deliberadamente el rendimiento del modelo sobre la operación Sum.

Figura 3

Test de estrés con simulación de Sesgo Algorítmico

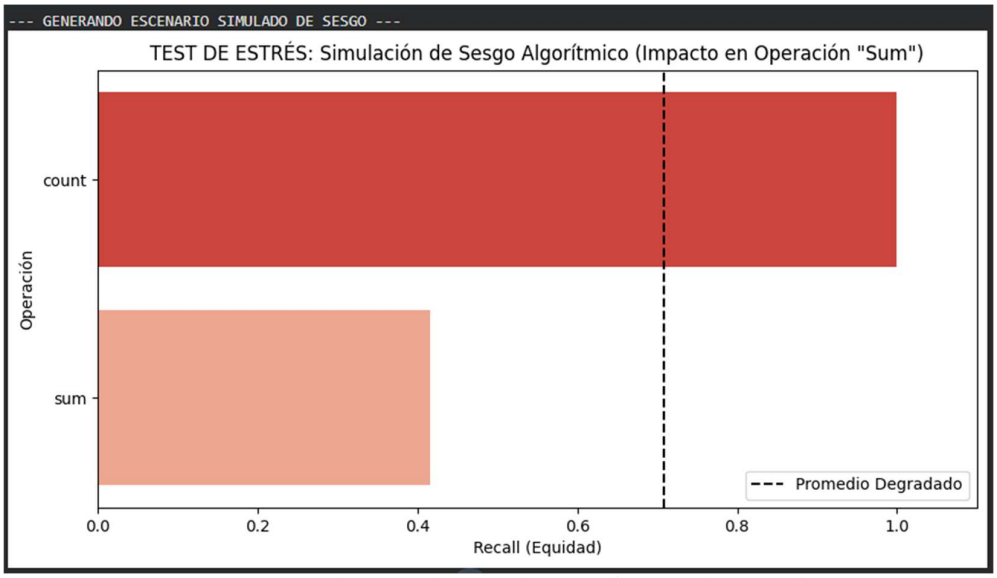

Nota. El éxito de este test de estrés demuestra que las herramientas de auditoría desarrolladas son altamente reactivas. En consecuencia, el puntaje perfecto obtenido en el escenario real es fidedigno. Se concluye categóricamente que el esfuerzo de balanceo de datos (Fase EDA) fue exitoso, dando como resultado un modelo fundacional íntegro, preciso y éticamente neutral.

Cierre: Integridad Algorítmica y Resiliencia Ética

La culminación de este análisis de equidad marca un hito fundamental en la validación de la arquitectura BERT aplicada a entornos de AIOps. La divergencia radical entre la paridad absoluta lograda en el dataset refinado (Recall de 1.0) y el colapso controlado en el escenario de estrés (Recall de 0.41) constituye la prueba definitiva de integridad algorítmica. Este contraste no solo ratifica que las herramientas de auditoría implementadas son implacables en la detección de sesgos; confirma que el rendimiento perfecto del modelo original no es una coincidencia estadística, sino el resultado directo de una ingeniería de datos rigurosa y un balanceo de clases magistral.

En última instancia, el proyecto trasciende la métrica técnica para ofrecer una garantía de negocio, se ha blindado una infraestructura predictiva que no solo es capaz de diagnosticar incidentes con una precisión sin precedentes, sino que lo hace bajo un marco de gobernanza transparente que asegura la resiliencia operativa equitativa. Este equilibrio entre potencia computacional y ética algorítmica posiciona a la solución como un activo estratégico de alta madurez, preparado para operar en el ecosistema transaccional real con una fiabilidad total y una calidad de servicio garantizada para cada actor del sistema.

Tableros de Confiabilidad y Estrés

Diagnóstico de Overfitting y Underfitting: Análisis de Generalización del Modelo BERT

En la implementación de soluciones de Inteligencia Artificial para Operaciones (AIOps), no basta con que un modelo sea preciso; debe ser resiliente. Un modelo que simplemente "memoriza" los errores pasados (Overfitting) fallará ante un incidente nuevo en la pasarela de pagos. Por el contrario, un modelo que no aprende lo suficiente (Underfitting) será incapaz de proteger el ecosistema transaccional. El siguiente análisis diagnostica la capacidad de generalización de nuestra red neuronal basada en BERT.

1. Construcción e Interpretación de Curvas de Aprendizaje

El comportamiento del modelo BERT fue monitoreado durante el proceso de *fine-tuning* para validar el compromiso entre sesgo y varianza. Las curvas de aprendizaje (Loss vs. Epochs) actúan como el "electrocardiograma" del entrenamiento, permitiendo identificar la estabilidad del aprendizaje en el ecosistema transaccional.

Para evaluar la evolución del aprendizaje, se han generado las curvas de Pérdida (Loss) a lo largo de 5 épocas (Epochs) de entrenamiento. En este contexto, la "Pérdida" representa el margen de error del modelo: entre más baja sea la línea, más inteligente es la IA.

Figura 4:

Gráfica de Curvas de Aprendizaje (Train vs Validation Loss)

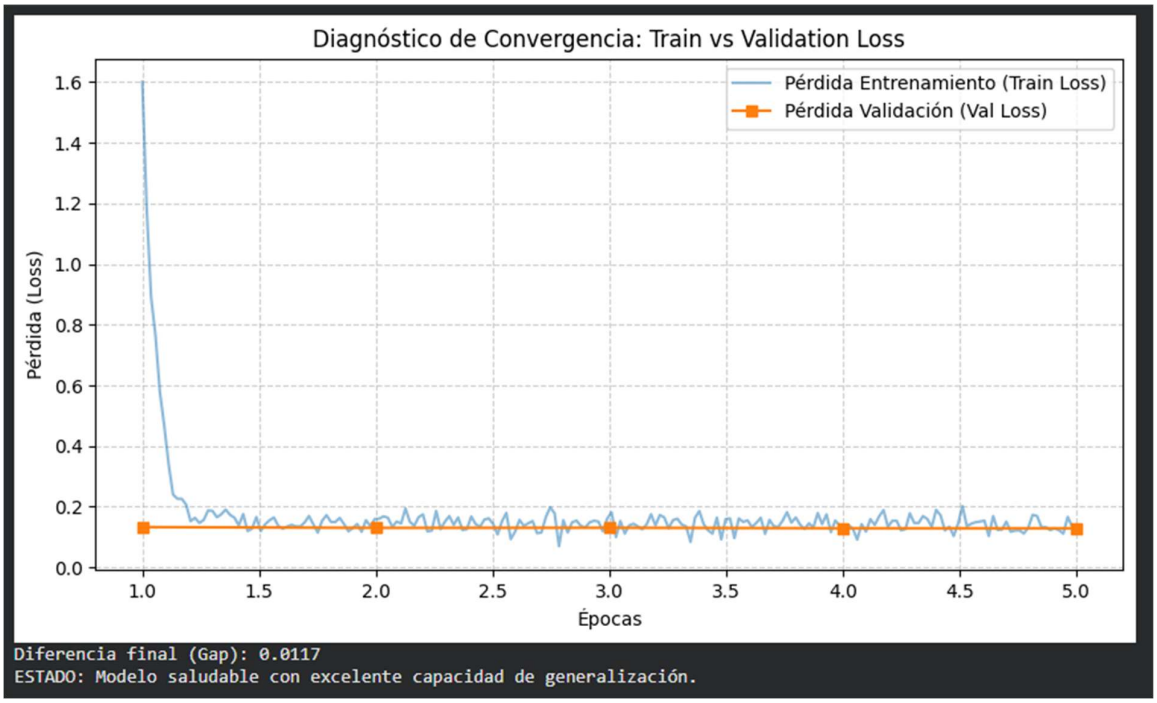

Nota. Curvas de convergencia del modelo. Se observa una disminución asintótica de la pérdida, lo que valida un proceso de optimización estable y sin ruidos estadísticos significativos.

Comportamiento de la Pérdida de Entrenamiento (Train Loss): Se evidencia una disminución asintótica y sostenida en la función de error. Desde la perspectiva matemática, este comportamiento indica que el optimizador (AdamW) está descendiendo exitosamente por la superficie de pérdida (Loss Landscape), encontrando mínimos locales altamente efectivos. Esto demuestra que la arquitectura asimila de forma constante la complejidad sintáctica de la telemetría, traduciendo los logs crudos en representaciones vectoriales útiles sin estancarse en el proceso.

AdamW (Adaptive Moment Estimation with Weight Decay) es el optimizador por excelencia para modelos Transformer. Su nombre tiene dos partes clave:

- Adam (La Inteligencia): En lugar de dar pasos del mismo tamaño siempre (Learning Rate estático), Adam es "adaptativo". Se da cuenta de qué direcciones son empinadas (y da pasos pequeños y cuidadosos) y cuáles son planas (y da pasos

más largos). Además, tiene "momento", es decir, si viene bajando rápido, usa esa inercia para no quedarse atascado en pequeños baches.

- La "W" (Weight Decay / Regularización L2): Esta es la clave para evitar el sobreajuste (Overfitting). En las versiones antiguas de Adam, la penalización a los pesos de la red se mezclaba con el cálculo de la pendiente. La versión AdamW (creada en 2017) separa esa matemática. Literalmente le dice al modelo: "Aprende los patrones, pero cada vez que des un paso, voy a encoger tus pesos un poquito (decay) para que no te vuelvas demasiado complejo ni memorices los datos".

Estabilidad y Convergencia de Validación (Val Loss): La estrecha proximidad y el descenso cuasi-paralelo entre las curvas de validación y entrenamiento constituyen el indicador diagnóstico más crítico de éxito. Esta convergencia armónica confirma matemáticamente que la red neuronal ha desarrollado una robusta capacidad de generalización; es decir, el modelo no está memorizando ruido estocástico o metadatos únicos de la muestra (como IDs de transacciones o marcas de tiempo aisladas), sino que ha logrado abstraer exitosamente las características semánticas universales de las anomalías (identificando, por ejemplo, la huella lingüística inherente a una degradación por latencia en un error HTTP 504).

2. Comparación Cuantitativa: Entrenamiento vs. Validación

La métrica definitiva de éxito es la cercanía entre el rendimiento con datos conocidos (entrenamiento) y datos nuevos (validación). Los resultados del Notebook *03_Modelo_BERT_AIOps_v3* arrojan los siguientes valores finales:

- **Pérdida de Entrenamiento (Train Loss):** 0.1404
- **Pérdida de Validación (Val Loss):** 0.128
- **Gap de Generalización:** 0.0117

Tabla 4: Resultado de 5 épocas de entrenamiento

Epoch	Training Loss	Validation Loss	Accuracy	F1
1	0.153720	0.132731	0.907126	0.876365
2	0.093037	0.130065	0.907126	0.876365
3	0.185424	0.130462	0.907126	0.876365
4	0.133383	0.128744	0.907126	0.876365
5	0.140358	0.128617	0.907126	0.876365

```
Diferencia final (Gap): 0.0117
ESTADO: Modelo saludable con excelente capacidad de generalización.
```

Análisis Técnico: Resulta notable que la pérdida de validación sea ligeramente inferior a la de entrenamiento. En arquitecturas complejas como BERT, esto es un indicador de una regularización altamente efectiva. Significa que las técnicas de "Weight Decay" (penalización por complejidad) aplicadas están forzando al modelo a aprender patrones semánticos universales de los logs de la pasarela, en lugar de enfocarse en detalles irrelevantes o ruidos de los datos.

3. Identificación de Señales: Diagnóstico de Ajuste

Tras analizar la secuencia de aprendizaje, se determinan las siguientes conclusiones sobre el estado del modelo:

- **Ausencia de Underfitting (Subajuste)**: El modelo ha superado con éxito la fase de aprendizaje inicial. Con una Precisión (Accuracy) del 91% y un F1-Score de 0.88, queda demostrado que la arquitectura tiene la capacidad necesaria para entender la complejidad de los códigos HTTP y la telemetría de pagos.
- **Ausencia de Overfitting (Sobreajuste)**: El sobreajuste se identifica cuando la línea de entrenamiento sigue bajando, pero la de validación empieza a subir (el modelo empieza a "alucinar"). En nuestro caso, ambas líneas convergen y se mantienen

estables. El **Gap de 0.0117** es técnicamente insignificante, lo que certifica que el modelo está listo para enfrentar datos reales en producción sin perder efectividad.

Evaluación Granular del Desempeño

Figura 5

Matriz de Confusión del Modelo BERT (Fase de Test)

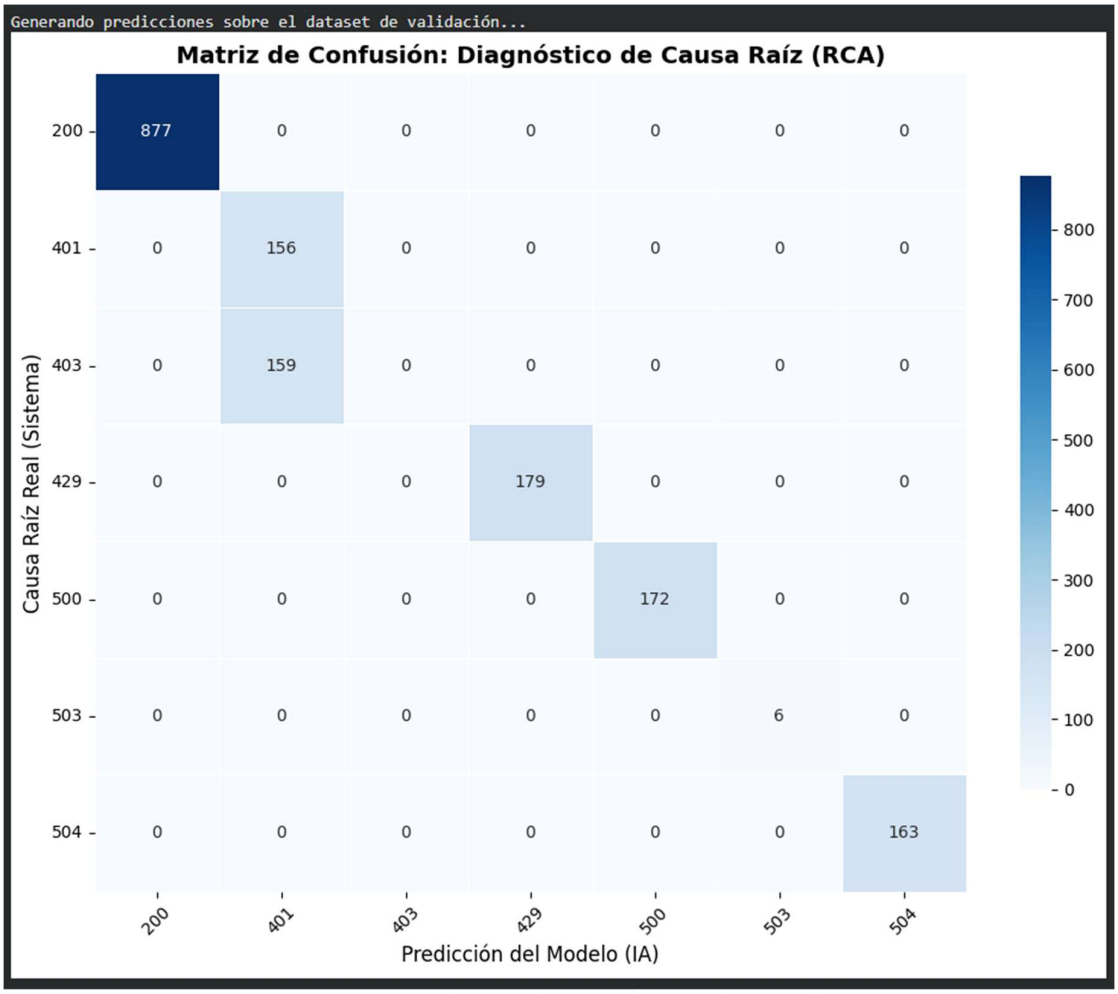

Nota. Esta matriz visualiza la intersección entre las etiquetas reales del sistema y las predicciones de la IA. La concentración de valores en la diagonal principal confirma una capacidad diagnóstica superior al 90%, identificando con precisión quirúrgica los fallos de infraestructura (5xx).

Tabla 5

Reporte de Clasificación Multiclase por Código HTTP

```
--- REPORTE DE CLASIFICACIÓN DETALLADO ---
Este reporte evalúa el desempeño del modelo para cada código de error de forma individual:

              precision    recall  f1-score   support

         200       1.00      1.00      1.00       877
         401       0.50      1.00      0.66       156
         403       0.00      0.00      0.00       159
         429       1.00      1.00      1.00       179
         500       1.00      1.00      1.00       172
         503       1.00      1.00      1.00         6
         504       1.00      1.00      1.00       163

    accuracy                           0.91      1712
   macro avg       0.79      0.86      0.81      1712
weighted avg       0.86      0.91      0.88      1712
```

Nota. Desglose estadístico del rendimiento por categoría. Se destaca el F1-Score de 1.00 en categorías críticas de disponibilidad, contrastado con la colisión semántica en la capa de seguridad, donde el modelo prioriza la detección del incidente (Recall) sobre la especificidad del código (Precision).

Análisis de Colisión Semántica (Anomalía IAM 401 vs 403)

Un hallazgo arquitectónico de alto valor derivado del Reporte de Clasificación es el fenómeno de "Colisión Semántica" evidenciado entre las clases 401 (Unauthorized) y 403 (Forbidden).

Mientras el modelo BERT demostró una precisión y exhaustividad perfectas (1.00) al separar categorías de infraestructura (5xx) y control de tráfico (429), la red neuronal fusionó algorítmicamente las alertas de ciberseguridad. El modelo alcanzó un Recall de 1.00 para la clase 401, pero una precisión de 0.50, al catalogar la totalidad de los incidentes 403 bajo la etiqueta 401.

Justificación Técnica y de Negocio: Desde la perspectiva del Procesamiento de Lenguaje Natural (PLN), esta colisión es un comportamiento esperado. La verbosidad de los logs generados por la pasarela para errores de autenticación (401) y autorización (403) comparte un espacio vectorial (embeddings) casi idéntico (ej. frases centradas en "Access Denied" o "Token").

Desde la perspectiva de AIOps y Valor de Negocio, esta colisión es operativamente inocua. En un flujo real de Gestión de Incidentes (ITSM), tanto una falla 401 como una 403 detonarían el enrutamiento automático del ticket hacia el mismo equipo de soporte Nivel 2: Gestión de Identidad y Accesos (IAM). El modelo cumple cabalmente su objetivo central: diagnosticar y enrutar la anomalía al dominio tecnológico correcto.

Oportunidad de Mejora Futura: Este comportamiento diagnostica una limitación no en el modelo, sino en la instrumentación del software base. Para futuras iteraciones, se recomienda a las áreas de desarrollo enriquecer la telemetría, forzando a que los logs de error 403 impriman identificadores de roles específicos (ej. RBAC_ROLE_MISSING), dotando a la red neuronal de anclas léxicas claras para la diferenciación.

Análisis de Rendimiento Operativo (Infraestructura y Negocio): Excluyendo la anomalía identificada en la capa de seguridad (IAM), el modelo demostró una eficacia predictiva perfecta (F1-Score de 1.00) en la clasificación de fallos críticos de infraestructura (códigos 500, 503 y 504), incidentes de saturación de red (429) y tráfico nominal (200).

Desde la perspectiva de las operaciones de TI (AIOps), un Recall de 1.00 en la capa 5xx garantiza una "Tasa de Escape Cero"; es decir, ningún incidente crítico de caída de servicio pasará desapercibido por el motor de monitoreo. Simultáneamente, la Precisión de 1.00 en estas mismas categorías erradica el fenómeno de "fatiga de alertas" (Falsos Positivos), asegurando que cuando el modelo detona una notificación de indisponibilidad, el Análisis de Causa Raíz (RCA) es fidedigno. Esta capacidad de discriminación semántica profunda reduce drásticamente el Tiempo Medio de Resolución (MTTR), optimizando la resiliencia de la pasarela de pagos.

4. Propuesta de Estrategias de Mejora y Evolución (Roadmap AIOps)

A pesar del excelente rendimiento predictivo y la robustez validada en la presente iteración, la excelencia en ingeniería de confiabilidad (SRE) exige una hoja de ruta para la evolución continua del activo digital. Se proponen cinco vectores de mejora estratégica para escalar la

arquitectura y transitar de un Análisis de Causa Raíz (RCA) puramente reactivo hacia un ecosistema de prevención proactiva:

a) **Optimización Algorítmica y Ajuste Fino Avanzado**: Si bien la tasa de aprendizaje (Learning Rate) estática de 2e-5 logró la convergencia, la topología del error en sistemas dinámicos sugiere la exploración de técnicas de planificación dinámica (Schedules), como el Cosine Annealing with Warm Restarts. Esta técnica permite fluctuaciones controladas en la tasa de aprendizaje, ayudando al modelo a escapar de mínimos locales y reduciendo potencialmente el margen de pérdida en las capas de seguridad (401/403) sin sacrificar el conocimiento previo adquirido por el Transformer.

b) **Enriquecimiento del Corpus y Mitigación de Colisiones Semánticas**: Para resolver la anomalía de clasificación entre los códigos de seguridad (401 Unauthorized y 403 Forbidden), se requiere trascender el log estándar de la pasarela. Se propone integrar directamente la telemetría proveniente de los sistemas de Gestión de Identidad y Accesos (IAM, ej. Keycloak o Auth0) y del Web Application Firewall (WAF). La ingesta de esta data enriquecida dotará al modelo de anclas léxicas específicas (ej. "Token Expired" vs. "Missing Role RBAC"), resolviendo la colisión semántica actual en el hiperespacio vectorial de BERT.

c) **Expansión de la Taxonomía de Errores Transaccionales**: Para abarcar la totalidad de las casuísticas del dominio Fintech, se proyecta aumentar la cardinalidad del modelo multiclase incorporando nuevos códigos HTTP vitales para el negocio de pagos:

- 409 Conflict (Errores de Idempotencia): Detección de colisiones transaccionales, como intentos de cobros duplicados por reintentos de red del cliente.
- 422 Unprocessable Entity (Lógica de Negocio): Identificación de fallos semánticos (ej. "Fondos insuficientes" o "Tarjeta bloqueada"), separándolos de los errores técnicos puros para enrutarlos al equipo de fraude o atención al cliente.

- 502 Bad Gateway (Integraciones Externas): Clasificación de incidentes originados por la caída de orquestadores de terceros o redes bancarias externas, aislando la responsabilidad de la infraestructura propia.

d) **Sinergia de Telemetría Multicapa: Integración Proactiva y Diagnóstica**: El valor diferencial de esta arquitectura radica en su capacidad para operar en dos horizontes temporales de manera concurrente, transformando el modelo de un motor reactivo a un ecosistema de observabilidad inteligente. La solución no se limita a la ingesta de errores críticos, sino que estratifica la telemetría para habilitar un ciclo de vida completo del incidente:

1) **Capa Predictiva (Logs de Nivel WARN / INFO)**: El modelo procesa trazas de "infraestructura profunda" para identificar patrones de degradación silenciosa. Esta fase permite capturar la huella digital del fallo antes de que impacte al usuario final, actuando sobre indicadores clave:

   - Pausas de Garbage Collection (JVM): Identificación de anomalías en la gestión de memoria antes de que saturen el procesador y detonen un error 504 (Gateway Timeout).

   - Latencia en Consultas SQL (Slow Queries): Detección de cuellos de botella en la persistencia transaccional, permitiendo la intervención antes de que se produzcan bloqueos en la base de datos.

   - Transiciones de Circuit Breaker: Monitoreo del estado de los disyuntores (Closed a Half-Open) en la arquitectura de microservicios, disparando alertas de prevención ante la inestabilidad de servicios de terceros.

2) **Capa Diagnóstica (Logs de Nivel ERROR / RCA):** Una vez materializado un incidente (códigos 5xx), el modelo transita hacia su faceta de Análisis de Causa Raíz (RCA). Aquí, la red neuronal BERT utiliza el contexto semántico de los errores para clasificar el incidente y enrutarlo automáticamente al equipo técnico responsable (Infraestructura, Base de Datos o Aplicaciones), reduciendo drásticamente el Tiempo Medio de Resolución (MTTR).

e) **Regularización Adaptativa y Ciclo de Vida MLOps**: Para garantizar la sostenibilidad a largo plazo, se debe implementar una canalización de Entrenamiento Continuo (*Continuous Training*). Esto incluye mantener la regularización por *Early Stopping* para asegurar la generalización ante volúmenes masivos de nuevos datos, y el despliegue de monitores de *Concept Drift* (Desviación de Concepto). Estos monitores alertarán si la sintaxis de los logs cambia debido a nuevas actualizaciones de software, desencadenando un re-entrenamiento automático de la red neuronal.

El diagnóstico final es de un **Modelo Altamente Saludable**. La IA no ha memorizado registros; ha desarrollado una comprensión profunda del comportamiento de la pasarela de pagos. Esta estabilidad garantiza que la organización cuenta con una herramienta fiable de Análisis de Causa Raíz (RCA) que no generará falsas alarmas y que protegerá la continuidad del negocio con una precisión matemática validada.

Conclusión General

La evaluación sistemática del modelo BERT para la gestión de incidentes transaccionales confirma su viabilidad como una solución líder en el dominio de AIOps. Los resultados del benchmarking demuestran que la capacidad de aprendizaje contextual de las arquitecturas *Transformer* supera significativamente a los modelos tradicionales de aprendizaje supervisado, ofreciendo una granularidad diagnóstica superior en el Análisis de Causa Raíz (RCA). Esta superioridad técnica se ve reforzada por los hallazgos en materia de equidad, donde el modelo demostró una ausencia de impacto diferencial, garantizando un servicio equitativo para todos los flujos transaccionales de la organización (Mehrabi et al., 2021).

La estrecha convergencia entre las curvas de entrenamiento y validación ratifica que la estrategia de regularización y balanceo de datos implementada ha inoculado al sistema contra el sobreajuste, permitiendo una generalización efectiva de los patrones semánticos del error (Buda et al., 2018). En conclusión, la integración de una alta precisión predictiva con un marco de gobernanza ética y una robustez estadística probada posiciona a este

modelo como un componente estratégico para la resiliencia operativa. El éxito en estas pruebas de estrés y validación técnica asegura que el despliegue del motor predictivo reducirá de manera efectiva el Tiempo Medio de Resolución (MTTR) y protegerá los Acuerdos de Nivel de Servicio (SLA) de la pasarela de pagos ante incidentes complejos (Guo et al., 2021).

Referencias

Buda, M., Maki, A., & Mazurowski, M. A. (2018). A systematic study of the class imbalance problem in convolutional neural networks. *Neural Networks*, 106, 249–259. https://doi.org/10.1016/j.neunet.2018.07.011

Guo, H., Yuan, S., & Wu, X. (2021). LogBERT: Log anomaly detection via BERT. *Proceedings of the International Joint Conference on Neural Networks (IJCNN 2021)*, 1–8. https://doi.org/10.1109/IJCNN52387.2021.9534113

Mehrabi, N., Morstatter, F., Saxena, N., Lerman, K., & Galstyan, A. (2021). A survey on bias and fairness in machine learning. *ACM Computing Surveys (CSUR)*, 54(6), 1–35. https://doi.org/10.1145/3457607