JAIME ALBERTO SIERRA SIERRA.
JUAN CARLOS PARRA MARTINEZ

Flujo de Preparación y Procesamiento de Datos (AIOps)

Arquitectura de Preprocesamiento para Prevención de Incidentes en Canales de Pago:

01

Datos Crudos (Raw Data)

Origen

Telemetría de red de API Gateway (simulación de alta concurrencia) extraída vía API.

Estado

99,99%

(Tráfico exitoso). Datos altamente asimétricos.

Target (variable objetivo)

http_status_code

Clasificación multiclase de 7 clases

Volumen Inicial

+426,000

Registros procesados mediante Chunking (lectura por bloques) para optimizar memoria.

02

Limpieza de Datos (Data Cleaning)

Valores Nulos & Duplicados

Ausencia de nulos en columnas core; campos de error vacíos justificados por la tasa de éxito operativo.

Gestión de Outliers (Latencia)

Se identificaron latencias de hasta 14,000 ms. Justificación: Se conservaron deliberadamente, ya que representan fenómenos de degradación reales (Timeouts), vitales para el entrenamiento del modelo.

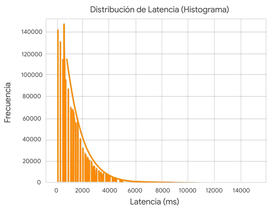

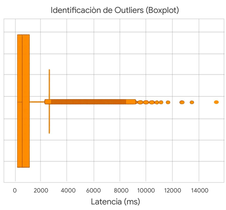

Eliminación por multicolinealidad: plaintext_size_bytes

03

Feature Engineering

Derivación Temporal

Derivación Temporal: Creación de variables hora_dia y dia_semana a partir del Timestamp. Impacto: Permite al modelo detectar patrones de ráfaga (bursts) en ventanas críticas de procesamiento.

Inyección Semántica

Inyección Semántica: Transformación de códigos HTTP planos en trazas de texto profundo (Ej. Excepciones Java) simulando registros de Software Observability.

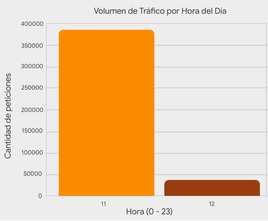

04

Balanceamiento de Clases

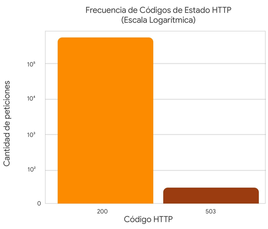

Problema

Desbalance crítico (Clase mayoritaria: 200 HTTP).

Técnica

Submuestreo Estratégico (Undersampling) estocástico.

Justificación

Reducir la clase mayoritaria garantiza un corpus matemáticamente simétrico (50/50), erradicando el sesgo inductivo de la red neuronal predictiva.

05

Data Augmentation

Técnica

Inyección de Fallos Sintéticos (Fault Injection).

Implementación

Mutación sistemática del 1% del tráfico normal para cubrir el espectro multicategoría faltante (401, 403, 429, 500, 504).

Justificación

Aumenta artificialmente la variabilidad de incidentes críticos, dotando al modelo de ejemplos ante "cisnes negros" operativos no capturados en la muestra original.

06

Preprocessing Automatizado

Implementación

Diseño de un Data Pipeline secuencial utilizando scikit-learn (FunctionTransformer).

Data Masking (NLP)

Integración de expresiones regulares automatizadas (Regex) para el enmascaramiento dinámico de PII (IDs de usuario) y latencias absolutas, asegurando la privacidad y la abstracción de patrones.

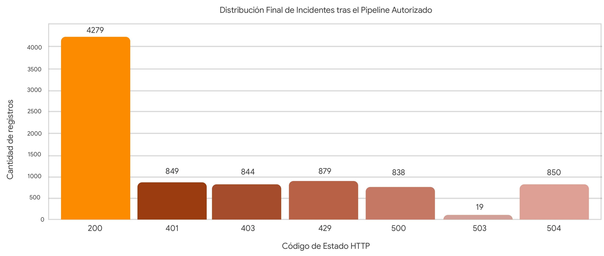

Corte estructural: Reducción en campos esenciales: 32 a 5

07

Dataset Listo para Entrenamiento

Calidad Final

Corpus híbrido transaccional consolidado (dataset_hibrido_final_AIOps.csv).

Dimensionalidad Óptima

8,558 registros estructurados, documentados, balanceados y mapeados numéricamente para el fine-tuning de la arquitectura Transformer (BERT).