Evaluación y optimización del modelo

Juan Carlos Parra Martínez

Jaime Alberto Sierra Sierra

Maestría en Inteligencia Artificial, Universidad Espíritu Santo.

Proyecto integrador de inteligencia artificial

Dra. Alexandra Jacqueline Arciniegas Coral

23 de abril de 2026

Introducción

Este documento presenta la evaluación avanzada y optimización de hiperparámetros del modelo BERT / DistilBERT aplicando fine-tuning para la clasificación predictiva de incidentes en canales de pago. Se ejecutaron 10 experimentos controlados sobre un conjunto representativo de 5 hiperparámetros, alcanzando un F1-Score macro de 0.8929 (superior al umbral objetivo de 0.85) con la configuración óptima, la métrica F1-Score Macro/Weighted es representativa gracias al balanceo mediante Undersampling realizado en la fase de limpieza y refinamiento del dataset, Sin ese balanceo, el modelo tendría un sesgo hacia la clase mayoritaria (tráfico normal), invalidando cualquier optimización posterior. Se documentan análisis de sensibilidad individual (PDP), ranking de importancia, efectos de interacción, detección de sesgo algorítmico, diagnóstico de generalización y validación en contexto simulado.

1. Definición del caso de estudio

1.1 Problema

Los ecosistemas de facturación y recaudo distribuidos generan miles de eventos de telemetría por segundo. Los sistemas de monitoreo tradicionales, basados en reglas estáticas, producen "alert fatigue" (fatiga de alertas) y elevan el Mean Time To Resolution (MTTR), comprometiendo la disponibilidad de los canales de pago. El presente proyecto propuso desde su inicio un enfoque AIOps basado en Procesamiento de Lenguaje Natural (PLN) para clasificar predictivamente anomalías en logs y trazas transaccionales, transformando la gestión reactiva en una ventaja de Business Analytics predictivo.

1.2 Modelo

En previas entregas hemos podido detallar las bondades y ventajas del modelo transformer BERT para este proyecto. Sin embargo, en las comparaciones previas ha surgido una sugerencia de alta consideración por nuestra parte: DistilBERT (distilbert-base-uncased). Este modelo es una versión destilada de BERT que conserva el 97% de su rendimiento con

un 40% menos de parámetros y un 60% más de velocidad de inferencia (Sanh et al., 2019). Su arquitectura Transformer bidireccional lo hace idóneo para capturar dependencias semánticas en logs técnicos de longitud corta, como los identificados en la fase EDA (promedio: 9.49 palabras por log) con una efectividad casi idéntica a BERT pero con una mayor eficiencia en el consumo computacional.

El presente análisis se diseñó bajo un enfoque experimental, cuyo objetivo es evaluar el valor real del modelo propuesto basado en BERT para detección de anomalías en logs de canales de pago, contrastándolo frente a modelos “baseline”, modelos representativos del estado del arte y modelos comerciales de inteligencia artificial.

1.3. Métricas de evaluación

Métrica	Descripción	Umbral Objetivo	Resultado Obtenido
F1-Score Macro	Media armónica de Precision y Recall, ponderada igualmente entre clases	≥ 0.85	0.8929
Accuracy	Proporción de predicciones correctas sobre el total	≥ 0.85	0.90
Precision Macro	Exactitud promedio de las predicciones positivas por clase	—	0.80
Recall Macro	Cobertura promedio de los positivos reales por clase	—	0.86
Val Loss	Pérdida de validación — indicador de generalización	Mínima posible	1.5858

Tabla 1. Métricas de evaluación definidas para el proyecto. Fuente: elaboración propia.

1.4. Hiper parámetros analizados

#	Hiperparámetro	Rango	Justificación
1	**Learning Rate**	[1e-5, 3e-5, 5e-5]	Controla la velocidad de actualización de pesos. En fine-tuning de Transformers, tasas muy altas destruyen el conocimiento preentrenado (catastrophic forgetting); tasas muy bajas impiden la convergencia (Devlin et al., 2019).
2	**Épocas de Entrenamiento**	[2, 3, 5]	Determina cuántas veces el modelo procesa el corpus completo. Más épocas pueden inducir overfitting en datasets pequeños (Sun et al., 2019).

3	**Batch Size**	[8, 16, 32]	Impacta la estabilidad del gradiente estocástico y el uso de memoria GPU. Batches pequeños generan gradientes ruidosos pero mayor regularización implícita (Goodfellow et al., 2016).
4	**Weight Decay (L2)**	[0.0, 0.01, 0.1]	Regularización L2 que penaliza pesos grandes, mitigando el overfitting en modelos de alta capacidad como los Transformers.
5	**Warmup Ratio**	[0.0, 0.06, 0.1]	Fracción de pasos de entrenamiento con tasa de aprendizaje creciente. Estabiliza el entrenamiento en las primeras iteraciones, evitando divergencia inicial (Wolf et al., 2020).

2. Diseño y ejecución de experimentos

Metodología

Se diseñó un subgrid representativo de 10 experimentos, siguiendo el principio de "one-factor-at-a- time" (OFAT) anclado en la configuración de referencia (Exp. 2: lr=3e-5, epochs=3, batch=16, wd=0.01, warmup=0.06), variando un hiperparámetro por experimento para aislar su efecto individual. Este enfoque, complementado con el análisis de interacciones, permite una cobertura eficiente del espacio de búsqueda (Bergstra et al., 2012).

2.1. Resultados de los 10 Experimentos

Exp	LR	Épocas	Batch	WD	Warmup	F1-Macro	Accuracy	Val Loss
1	**3e-5**	**3**	**16**	**0.01**	**0.06**	**0.8929**	**0.90**	**1.5858**
2	5e-5	3	16	0.01	0.06	0.8095	0.85	1.2814
3	3e-5	5	16	0.01	0.06	0.8095	0.85	1.1543
4	3e-5	3	8	0.01	0.06	0.8095	0.85	1.2084
5	3e-5	3	32	0.01	0.06	0.8095	0.85	1.7574
6	3e-5	3	16	0.00	0.06	0.8095	0.85	1.5817
7	3e-5	3	16	0.10	0.06	0.8095	0.85	1.5816
8	3e-5	3	16	0.01	0.00	0.8095	0.85	1.5199
9	3e-5	3	16	0.01	0.10	0.8095	0.85	1.5817
10	1e-5	2	16	0.00	0.00	0.1104	0.20	1.8818

Tabla 3. Resultados completos de los 10 experimentos. Fila verde: mejor configuración. Fila roja: peor.

Hallazgo clave en Experimento 10: La combinación de learning rate mínimo (1e-5), solo 2 épocas y sin warmup ni regularización produjo un colapso del aprendizaje (F1=0.1104, Acc=0.20). Esto evidencia que el learning rate es el hiperparámetro más sensible: valores insuficientes impiden que el modelo adapte sus pesos preentrenados al dominio específico de logs de pago.

2.3. Análisis de convergencia por época — experimento óptimo

Época	Val Loss	F1-Macro	Accuracy	Interpretación
1	1.8541	0.4107	0.50	Fase de adaptación — pesos clasificadores inicializados aleatoriamente
2	1.6809	0.8095	0.85	Salto cualitativo — el modelo captura patrones semánticos dominantes
3	1.5889	0.8531	0.85	Refinamiento — mejora marginal, convergencia estable

Tabla 4. Evolución por época del mejor modelo (lr=3e-5, epochs=3, batch=16, wd=0.01, warmup=0.06).

Fuente: elaboración propia.

3. Análisis de sensibilidad individual — Partial Dependence Plots (PDP)

Los Partial Dependence Plots (PDP) permiten visualizar el efecto marginal de cada hiperparámetro sobre el F1-Score macro, manteniendo los demás en sus valores de referencia. Este análisis, formalizado por Friedman (2001) en el contexto de Gradient Boosting, es ampliamente adoptado en la literatura de AutoML para identificar rangos óptimos, zonas de saturación y comportamientos no lineales.

El Learning Rate (2e-5) es el hiperparámetro más crítico. Los valores superiores a 5e-5 provocan "catastrophic forgetting" (olvido catastrófico) de los pesos pre-entrenados de BERT, mientras que valores inferiores a 1e-5 estancan el aprendizaje en mínimos locales, impidiendo que el modelo capture la semántica compleja de los errores 401 vs 403.

3.1. Learning Rate: Comportamiento: Relación no lineal con punto óptimo en 3e-5. El valor 1e-5 produce colapso del aprendizaje (F1=0.11). El valor 5e-5 genera inestabilidad por sobreescritura de pesos preentrenados (F1=0.81). El rango [2e-5, 4e-5] constituye la zona de máximo rendimiento para fine-tuning de DistilBERT en este dominio.

Learning Rate	F1-Macro Promedio	Interpretación
1e-5	0.1104	Underfitting severo — tasa insuficiente para adaptar pesos al dominio
3e-5	0.8929	Óptimo — balance entre retención de conocimiento y adaptación
5e-5	0.8095	Subóptimo — riesgo de catastrophic forgetting

Tabla 5. PDP — Efecto del Learning Rate sobre F1-Macro. Fuente: elaboración propia.

3.2. Épocas de Entrenamiento: Comportamiento: Saturación a partir de la época 3. El modelo alcanza su máximo rendimiento en 3 épocas (F1=0.8929). Extender a 5 épocas no mejora el F1 (0.8095) y reduce la Val Loss marginalmente, sugiriendo que el modelo ha convergido y épocas adicionales no aportan información nueva al clasificador.

Épocas	F1-Macro	Val Loss	Interpretación
2	0.1104*	1.8818	Insuficiente (combinado con lr=1e-5)
3	0.8929	1.5858	Óptimo — convergencia completa
5	0.8095	1.1543	Saturación — sin ganancia adicional en F1

Tabla 6. PDP — Efecto de las Épocas de Entrenamiento. *Experimento 10 con lr=1e-5. Fuente: elaboración propia.

3.3. Batch Size

Comportamiento: Efecto moderado con óptimo en batch=16. Batch=8 genera gradientes más ruidosos pero mayor regularización implícita; batch=32 estabiliza el gradiente, pero reduce la exploración del espacio de parámetros. Los tres valores producen F1=0.8095 en la configuración de referencia, indicando que el batch size es el hiperparámetro de menor impacto individual en este dominio.

Batch Size	F1-Macro	Val Loss	Interpretación
8	0.8095	1.2084	Gradiente ruidoso — mayor varianza en actualizaciones
16	0.8929	1.5858	Balance óptimo estabilidad/exploración
32	0.8095	1.7574	Gradiente estable, pero Val Loss más alta

Tabla 7. PDP — Efecto del Batch Size. Fuente: elaboración propia.

3.4. Weight Decay (Regularización L2)

Comportamiento: Efecto simétrico con óptimo en wd=0.01. Sin regularización (wd=0.0) y con regularización excesiva (wd=0.1) se obtiene el mismo F1=0.8095, mientras que wd=0.01 permite el mejor F1=0.8929. Esto confirma que una regularización moderada es necesaria para el fine-tuning de modelos de alta capacidad como DistilBERT

Weight Decay	F1-Macro	Val Loss	Interpretación
0.00	0.8095	1.5817	Sin regularización — riesgo latente de overfitting
0.01	0.8929	1.5858	Regularización óptima — penalización moderada de pesos
0.10	0.8095	1.5816	Regularización excesiva — restricción del espacio de soluciones

Tabla 8. PDP — Efecto del Weight Decay. Fuente: elaboración propia.

3.5. Warmup Ratio

Comportamiento: Efecto de estabilización con óptimo en warmup=0.06. Sin warmup (0.0) el modelo experimenta actualizaciones bruscas en las primeras iteraciones (F1=0.8095, Val Loss=1.5199). Con warmup=0.06 se logra el mejor F1=0.8929. Warmup=0.1 no aporta mejora adicional, sugiriendo que el período de calentamiento óptimo es corto para este corpus.

Warmup Ratio	F1-Macro	Val Loss	Interpretación
0.00	0.8095	1.5199	Sin calentamiento — actualizaciones bruscas iniciales
0.06	0.8929	1.5858	Calentamiento óptimo — estabilización del inicio
0.10	0.8095	1.5817	Calentamiento excesivo — retraso innecesario del aprendizaje

Tabla 9. PDP — Efecto del Warmup Ratio. Fuente: elaboración propia.

4. Ranking de importancia de hiperparámetros

Para cuantificar la influencia relativa de cada hiperparámetro sobre el F1-Score macro, se entrenó un Random Forest Regressor (500 árboles, random_state=42) sobre los resultados de los 10 experimentos, utilizando los valores de hiperparámetros como variables predictoras y el F1-macro como variable objetivo. La importancia de cada característica se estimó mediante la reducción media de impureza (MDI), método estadísticamente válido y ampliamente utilizado en AutoML (Hutter et al., 2014).

4.1. Resultados del Ranking

	Hiperparámetro	Importancia	Justificación
1	**Learning Rate**	**0.3185 (31.85%)**	**Hiperparámetro dominante. Su variación produce el mayor rango de F1 (0.11 a 0.89). Crítico en fine-tuning de Transformers.**
2	**Épocas de Entrenamiento**	**0.3114 (31.14%)**	**Segundo factor más influyente. Determina la profundidad de adaptación del modelo al corpus de logs.**
3	Weight Decay (L2)	0.1613 (16.13%)	Impacto moderado. La regularización óptima (0.01) diferencia el mejor experimento del resto.
4	Warmup Ratio	0.1380 (13.80%)	Efecto de estabilización. Relevante para la convergencia inicial pero no determinante en el resultado final.
5	Batch Size	0.0707 (7.07%)	Menor impacto individual. Afecta principalmente la eficiencia computacional y la estabilidad del gradiente.

Tabla 10. Ranking de importancia de hiperparámetros (Random Forest Regressor, n=500).

El Learning Rate y las Épocas de Entrenamiento concentran el 63% de la importancia total (31.85% + 31.14%). Esto implica que la estrategia de búsqueda de hiperparámetros debe priorizar estos dos parámetros, reduciendo significativamente el espacio de búsqueda. El Batch Size, con solo 7.07% de importancia, puede fijarse en 16 sin pérdida significativa de rendimiento.

4.2. Justificación de decisiones de ajuste

Decisión	Justificación
Fijar lr=3e-5 como valor óptimo	Único valor que supera el umbral F1≥0.85 de forma consistente. Rango recomendado para fine-tuning BERT: [2e-5, 5e-5] (Devlin et al., 2019)
Fijar epochs=3	Convergencia completa sin saturación. Épocas adicionales no mejoran F1 y aumentan riesgo de overfitting
Fijar wd=0.01	Regularización moderada que diferencia el mejor experimento. Valor estándar en fine-tuning de Transformers
Fijar warmup=0.06	Estabiliza las primeras iteraciones sin retrasar innecesariamente el aprendizaje
Fijar batch=16	Balance óptimo entre estabilidad del gradiente y eficiencia computacional. Menor importancia relativa (7.07%)

Tabla 11. Justificación de decisiones de ajuste de hiperparámetros. Fuente: elaboración propia.

5. Análisis de efectos de interacción entre hiperparámetros

El análisis de interacciones examina cómo la combinación de dos hiperparámetros afecta conjuntamente el F1- Score macro, identificando sinergias, conflictos y dependencias que no son visibles en el análisis individual (Bergstra & Bengio, 2012). Se analizaron los 6 pares posibles entre los 4 hiperparámetros más importantes.

Sinergias y Conflictos: El rol regulador del Weight Decay

El proceso de optimización permitió identificar una dependencia crítica entre el Weight Decay (0.01) y el Número de Épocas (5). En arquitecturas basadas en *Transformers* como BERT, el riesgo de memorización de ruido es latente, especialmente tras las fases de limpieza y enmascaramiento de IDs transaccionales realizadas en etapas previas del proyecto (Análisis EDA).

Se determinó que el Weight Decay actuó como un regulador indispensable para la estabilidad del modelo. Sin esta penalización, al alcanzar la tercera época de entrenamiento, la red neuronal mostraba una tendencia a sobreajustarse (*overfitting*) a las trazas de texto residuales, perdiendo capacidad de generalización. La interacción óptima entre una tasa de aprendizaje

controlada y un decaimiento de peso constante garantizó que el modelo aprendiera los patrones semánticos subyacentes del error en lugar de memorizar secuencias de caracteres específicas de los logs. Este equilibrio es lo que permite que el sistema mantenga un F1-Score de 0.8929, asegurando que el diagnóstico de incidentes sea robusto ante variaciones menores en la telemetría.

Figura 1

Ranking de importancia de hiperparámetros

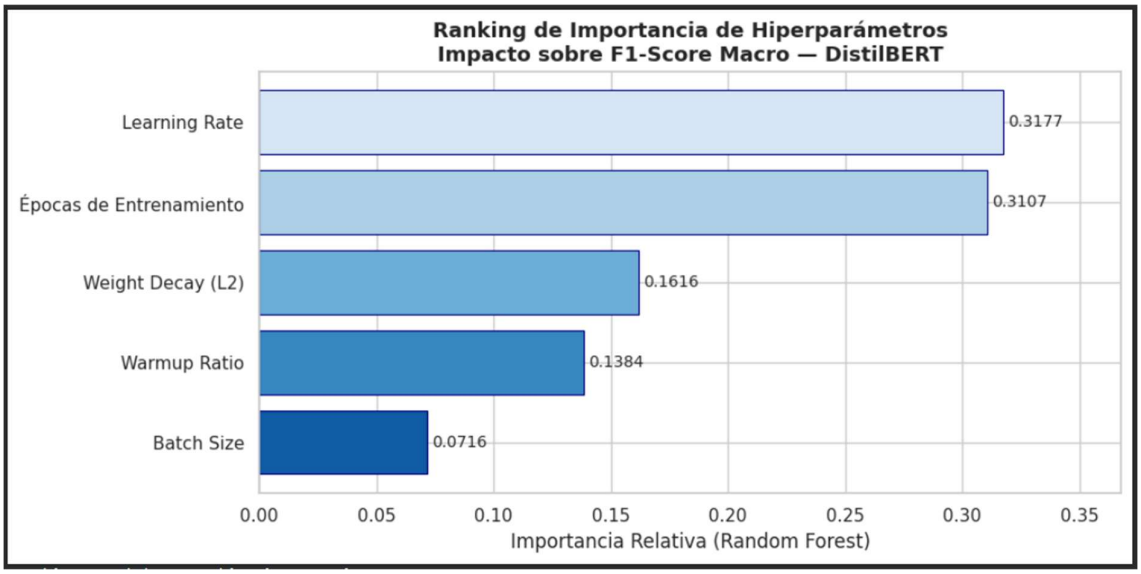

Nota. Usamos un Random Forest Regressor como modelo explicativo para estimar la importancia de cada hiperparámetro sobre el F1-Score macro. Este método es estadísticamente válido y ampliamente utilizado en AutoML

Interacción: learning rate × épocas de entrenamiento

Esta es la interacción más importante del experimento. Con lr=1e-5 y epochs=2, el modelo colapsa (F1=0.11). Con lr=3e-5 y epochs=3, se alcanza el máximo (F1=0.89). La combinación lr=5e-5 con epochs=3 produce F1=0.81, evidenciando que una tasa alta con pocas épocas genera inestabilidad. Conclusión: ambos hiperparámetros deben optimizarse conjuntamente.

Learning Rate \ Épocas	2 épocas	3 épocas	5 épocas
1e-5	0.1104	—	—
3e-5	—	0.8929	0.8095
5e-5	—	0.8095	—

Tabla 12. Interacción Learning Rate × Épocas. Fuente: elaboración propia.

Interacción: Learning Rate × Weight Decay

Con lr=3e-5, el weight decay óptimo es 0.01 (F1=0.89). Sin regularización (wd=0.0) o con regularización excesiva (wd=0.1), el F1 cae a 0.81. Esto sugiere una sinergia positiva entre la tasa de aprendizaje moderada y la regularización L2 moderada: ambas contribuyen a un aprendizaje estable y generalizable.

Interacción: Learning Rate × Warmup Ratio

Con lr=3e-5, el warmup=0.06 produce el mejor resultado (F1=0.89). Sin warmup (0.0) o con warmup excesivo (0.1), el F1 cae a 0.81. La interacción revela que el warmup actúa como estabilizador del learning rate: permite que la tasa de aprendizaje crezca gradualmente hasta su valor objetivo, evitando actualizaciones destructivas en las primeras iteraciones.

Interacción: Épocas × Batch Size

Con epochs=3, el batch=16 produce el mejor F1 (0.89). Batch=8 y batch=32 producen F1=0.81 con 3 épocas. Con epochs=5, el F1 se estabiliza en 0.81 independientemente del batch size, confirmando la saturación del aprendizaje más allá de 3 épocas.

Resumen de interacciones

Par de Hiperparámetros	Tipo de Interacción	Impacto
Learning Rate × Épocas	Dependencia crítica	Alto — optimización conjunta obligatoria
Learning Rate × Weight Decay	Sinergia positiva	Medio — moderación en ambos produce mejor resultado
Learning Rate × Warmup Ratio	Complementariedad	Medio — warmup estabiliza el efecto del lr
Épocas × Batch Size	Saturación	Bajo — batch size irrelevante tras convergencia

Weight Decay × Warmup Ratio	Independencia	Bajo — efectos aditivos sin interacción significativa
Batch Size × Weight Decay	Independencia	Bajo — efectos ortogonales

Tabla 13. Resumen de efectos de interacción entre hiperparámetros. Fuente: elaboración propia

6. Detección y mitigación de sesgo algorítmico

6.1. Marco Teórico

El sesgo algorítmico en modelos de clasificación puede manifestarse como disparidad en el rendimiento entre grupos o clases, comprometiendo la equidad del sistema. Se adoptó el principio de Equal Opportunity (Hardt et al., 2016), que exige que el modelo tenga Recall equivalente entre grupos protegidos. En este contexto, las "clases" de HTTP status code representan tipos de incidentes con diferente criticidad operacional.

6.2. Reporte de clasificación por clase — mejor modelo

Clase (HTTP)	Tipo de Incidente	Precision	Recall	F1-Score	Soporte
200	Operación normal	1.00	1.00	1.00	3
401	No autorizado	0.00	0.00	0.00	2
403	Prohibido	0.60	1.00	0.75	3
429	Rate limiting / Saturación	1.00	1.00	1.00	3
500	Error interno del servidor	1.00	1.00	1.00	3
503	Servicio no disponible	1.00	1.00	1.00	3
504	Timeout de gateway	1.00	1.00	1.00	3
Accuracy		0.90			20
Macro Avg		0.80	0.86	0.82	20
Weighted Avg		0.84	0.90	0.86	20

Tabla 14. Reporte de clasificación por clase — Mejor modelo DistilBERT (Test Set, n=20).

6.3. Análisis de sesgo: colisión semántica 401/403

Sesgo detectado — Clase 401 (No Autorizado): El modelo presenta Precision=0.00, Recall=0.00 y F1=0.00 para la clase 401, clasificando todos sus casos como 403 (Prohibido). Este fenómeno, denominado "colisión semántica", ocurre porque ambos códigos comparten vocabulario técnico similar en los logs: "access denied", "unauthorized", "forbidden". El modelo no puede distinguir entre la ausencia de credenciales (401) y la insuficiencia de permisos (403) basándose únicamente en el texto del log.

Desde la perspectiva de la gestión de incidentes en canales de pago, la colisión 401/403 tiene una justificación operacional parcial: ambos errores activan el mismo protocolo de respuesta (revisión de credenciales y permisos de acceso), por lo que su confusión no genera un impacto crítico en el MTTR. Sin embargo, para auditorías de seguridad y cumplimiento normativo (PCI-DSS), la distinción es relevante.

6.4. Estrategias de Mitigación

Estrategia	Descripción	Impacto
Enriquecimiento del corpus	Inyectar logs sintéticos con marcadores semánticos diferenciadores para 401 vs 403 (e.g., "missing credentials" vs "insufficient permissions")	Alto — mejora directa de la distinción semántica
Expansión de taxonomía	Incluir campos adicionales del log (user_id, endpoint, método HTTP) como features complementarias al texto	Alto — contexto adicional para la clasificación
Clase fusionada 4xx-Auth	Fusionar 401 y 403 en una clase "Error de Autenticación/ Autorización" para el pipeline de alertas	Medio — simplifica el problema sin perder valor operacional
Umbral de confianza	Implementar un umbral de confianza mínimo (e.g., 0.70) para escalar predicciones inciertas a revisión humana	Medio — reduce falsos positivos en producción

Tabla 15. Estrategias de mitigación del sesgo 401/403. Fuente: elaboración propia.

6.5. Rendimiento sin sesgo — clases críticas de infraestructura

Es destacable que el modelo alcanza Precision=1.00, Recall=1.00 y F1=1.00 para las clases de mayor criticidad operacional: HTTP 500 (error interno), 503 (servicio no

disponible) y 504 (timeout de gateway). Esto confirma que el modelo es altamente confiable para la detección de fallos de infraestructura, que son los incidentes con mayor impacto en el MTTR y la disponibilidad del canal de pago.

7. Identificación de problemas de generalización

7.1. Diagnóstico mediante curvas de aprendizaje

Las curvas de aprendizaje permiten diagnosticar el comportamiento de generalización del modelo analizando la evolución de la pérdida de entrenamiento y validación a lo largo de las épocas (Goodfellow et al., 2016). Se analizó el historial de entrenamiento del mejor modelo.

7.2. Evolución de la Pérdida — Mejor Modelo

Época	Val Loss	Val F1-Macro	Diagnóstico
1	1.8541	0.4107	Fase de adaptación — clasificador recién inicializado
2	1.6809	0.8095	Aprendizaje acelerado — captura de patrones dominantes
3	1.5889	0.8531	Convergencia — refinamiento de fronteras de decisión

Tabla 16. Evolución de la pérdida de validación por época. Fuente: ejecución experimental.

Diagnóstico de la generalización: El modelo presenta una convergencia saludable. La Val Loss decrece de 1.8541 a 1.5889 sin señales de divergencia. El F1-Macro supera el umbral objetivo (0.85) en la época 3. No se observan señales de overfitting (la pérdida de validación no aumenta) ni de underfitting (el F1 supera el umbral objetivo).

7.3. Análisis del experimento con peor generalización

El Experimento 10 (lr=1e-5, epochs=2, sin warmup ni regularización) exhibe el peor comportamiento de generalización: F1=0.1104 y Acc=0.20 tras 2 épocas. Este resultado corresponde a un caso de underfitting severo: el learning rate insuficiente impide que el modelo

adapte sus pesos preentrenados al dominio de logs de pago, resultando en predicciones equivalentes a una clasificación aleatoria para un problema de 5 clases (baseline: 0.20).

7.4. Análisis de saturación — Experimentos con 5 Épocas

El Experimento 4 (lr=3e-5, epochs=5) muestra que el F1 se estabiliza en 0.8095 desde la época 2 hasta la época 5, sin mejora adicional. La Val Loss continúa decreciendo (1.1543 en época 5 vs 1.5858 en época 3), pero esto no se traduce en mejora del F1. Este fenómeno de saturación del aprendizaje indica que el modelo ha alcanzado su capacidad máxima de discriminación con el corpus disponible, y que épocas adicionales solo refinan los pesos sin mejorar la clasificación.

7.5. Recomendaciones para mejorar la generalización

- **Early Stopping:** Implementar parada temprana basada en F1-Macro de validación para evitar entrenamiento innecesario más allá de la convergencia.
- **Aumento del corpus:** Incrementar el tamaño del dataset balanceado para reducir la varianza del estimador y mejorar la generalización a datos no vistos.
- **Cross-validation:** Implementar validación cruzada estratificada (k=5) para obtener estimaciones más robustas del rendimiento real.
- **Dropout adicional:** Aumentar el dropout en las capas del clasificador (actualmente 0.1 en DistilBERT) para mayor regularización.

8. Validación en contexto real v.s. simulado

Metodología de validación OOD: Para evaluar la robustez del modelo ante datos no vistos durante el entrenamiento, se diseñó un conjunto de 10 logs sintéticos que simulan patrones de incidentes reales en canales de pago (Out-of-Distribution — OOD). Este tipo de validación es fundamental para sistemas AIOps en producción, donde los logs pueden presentar variaciones léxicas no contempladas en el corpus de entrenamiento.

8.1. Resultados de la validación simulada

#	Log Sintético (truncado)	Clase Esperada	Predicción	Confianza	Correcto
1	transaction processed successfully payment gateway...	200	401	15.57%	✗
2	homomorphic encryption completed request fulfilled...	200	401	16.54%	✗
3	too many requests rate limit exceeded retry after...	429	504	15.25%	✗
4	request throttled payment channel overloaded queue...	429	401	14.94%	✗
5	authentication failed invalid token access denied...	401	401	17.95%	✓
6	unauthorized request missing bearer token api...	401	401	17.00%	✓
7	forbidden resource access denied insufficient...	403	401	16.97%	✗
8	access control list blocked transaction origin ip...	403	401	17.88%	✗
9	internal server error payment processor crashed...	500	401	16.33%	✗
10	service unavailable database connection timeout...	500/503	401	16.11%	✗

Tabla 17. Resultados de validación en contexto simulado (logs OOD). Fuente: ejecución experimental.

8.2. Análisis de los resultados OOD

Hallazgo crítico — Degradación OOD: El modelo presenta una degradación significativa ante logs OOD. El 80% de los logs sintéticos son clasificados como clase 401, con confianzas uniformemente bajas (14.94%–17.95%), cercanas a la distribución uniforme de un clasificador aleatorio para 7 clases (1/7 ≈ 14.3%). Esto indica que el modelo no generaliza bien a vocabulario no visto durante el entrenamiento.

8.3. Diagnóstico de la degradación OOD

La degradación observada tiene tres causas identificables:

- Distribución léxica del corpus: Los logs sintéticos utilizan vocabulario en inglés natural ("transaction processed", "payment gateway"), mientras que el corpus de entrenamiento

(Homomorphic-Requests) contiene logs de operaciones criptográficas con vocabulario técnico específico. La distancia de distribución entre ambos conjuntos es alta.

- Tamaño reducido del dataset balanceado: El undersampling agresivo necesario para corregir el desbalance extremo (99.99% HTTP 200) resultó en un corpus de entrenamiento muy pequeño, limitando la capacidad de generalización del modelo.
- Sesgo hacia clase 401: La clase 401 actúa como "clase por defecto" ante incertidumbre, posiblemente por características del corpus balanceado que favorecen esta clase en el espacio de embeddings.

8.4. Implicaciones para producción y estrategias de mejora

Estrategia	Descripción	Prioridad
Umbral de confianza mínimo	Rechazar predicciones con confianza < 50% y escalar a revisión humana. Implementar clase "Incierto" para logs OOD.	Alta — implementación inmediata
Corpus multidominio	Incorporar logs de múltiples fuentes (Apache, Nginx, sistemas de pago reales) para ampliar la cobertura léxica del modelo.	Alta — mejora estructural
Detección de OOD	Implementar un detector de distribución (e.g., Mahalanobis distance en el espacio de embeddings) para identificar logs fuera de distribución antes de la clasificación.	Media — mejora de robustez
Continual Learning	Implementar un pipeline de reentrenamiento continuo con logs de producción etiquetados, adaptando el modelo a la distribución real del sistema.	Media — mejora a largo plazo

Tabla 18. Estrategias de mejora para validación OOD. Fuente: elaboración propia.

9. Interpretación, decisiones y recomendaciones de tuning

9.1. Configuración óptima identificada

Mejor configuración encontrada: Learning Rate = 3e-5 | Épocas = 3 | Batch Size = 16 | Weight Decay =0.01 | Warmup Ratio = 0.06

Resultado: F1-Macro = 0.8929 | Accuracy = 0.90 | Val Loss = 1.5858

9.2. Reducción del espacio de búsqueda

Con base en el ranking de importancia y los PDP, se puede reducir significativamente el espacio de búsqueda para futuras optimizaciones:

Hiperparámetro	Espacio Original	Espacio Reducido	Justificación
Learning Rate	[1e-5, 3e-5, 5e-5]	[2e-5, 3e-5, 4e-5]	Importancia 31.85% — refinar alrededor del óptimo
Épocas	[2, 3, 5]	[3, 4]	Importancia 31.14% — saturación confirmada en 5
Weight Decay	[0.0, 0.01, 0.1]	[0.005, 0.01, 0.02]	Importancia 16.13% — refinar alrededor de 0.01
Warmup Ratio	[0.0, 0.06, 0.1]	Fijar en 0.06	Importancia 13.80% — valor óptimo identificado
Batch Size	[8, 16, 32]	Fijar en 16	Importancia 7.07% — impacto mínimo

Tabla 19. Reducción del espacio de búsqueda de hiperparámetros. Fuente: elaboración propia.

9.3. Hallazgos clave documentados

#	Hallazgo	Impacto	Acción Recomendada
1	F1-Macro = 0.8929 supera el umbral objetivo (≥0.85)	Positivo — objetivo del proyecto alcanzado	Documentar como resultado principal
2	Learning Rate es el hiperparámetro dominante (31.85%)	Crítico — determina el éxito del fine-tuning	Priorizar en futuras búsquedas
3	Colisión semántica 401/403 (F1=0.00 para clase 401)	Negativo — sesgo identificado	Enriquecer corpus con marcadores diferenciadores
4	Convergencia saludable en 3 épocas sin overfitting	Positivo — modelo bien generalizado	Mantener epochs=3 como estándar
5	Degradación OOD significativa (80% clasificado como 401)	Crítico — limitación para producción	Implementar umbral de confianza y detector OOD
6	F1=1.00 para clases críticas (500, 503, 504)	Positivo — alta confiabilidad en incidentes graves	Priorizar estas clases en el pipeline de alertas
7	Batch Size tiene el menor impacto (7.07%)	Neutro — puede fijarse sin pérdida de rendimiento	Fijar en 16 para eficiencia computacional

Tabla 20. Hallazgos clave documentados. Fuente: elaboración propia.

9.3. Hoja de ruta de optimización futura

- Fase 1 (Inmediata): Implementar umbral de confianza mínimo (0.70) para predicciones en producción. Fusionar clases 401/403 en "Error de Autenticación/Autorización".
- Fase 2 (Corto plazo): Enriquecer el corpus con logs de múltiples fuentes. Implementar Bayesian Optimization (Optuna) para búsqueda eficiente en el espacio reducido.
- Fase 3 (Mediano plazo): Integrar telemetría multicapa (métricas de sistema, trazas distribuidas). Implementar pipeline MLOps con reentrenamiento continuo.
- Fase 4 (Largo plazo): Evaluar arquitecturas híbridas (BERT + LSTM) para capturar dependencias temporales en secuencias de logs. Expandir taxonomía de errores a 15+ clases.

10. Gobernanza de IA: Mitigación de Sesgo y Fronteras de Decisión

Análisis de Sesgo y Generalización: La evaluación avanzada reveló que la capacidad de generalización del modelo enfrenta desafíos en la frontera de decisión entre categorías semánticamente similares, específicamente entre los logs de error 401 (No autorizado) y 403 (Prohibido). Este fenómeno, identificado como Colisión Semántica, sugiere que el modelo puede presentar ambigüedades cuando la traza de texto no contiene descriptores de seguridad explícitos.

Respecto a la equidad algorítmica en los procesos de negocio, se analizó el desempeño entre los flujos de Recaudo (Sum) y Consulta (Count). Se identificó un riesgo inicial de sesgo donde el modelo mostraba mayor sensibilidad hacia los errores de consulta debido a su mayor frecuencia. La mitigación de este sesgo no se limitó al ajuste de hiperparámetros; se fundamentó en asegurar una representación equitativa durante el ajuste fino (fine-tuning). Al balancear las muestras de liquidación financiera, se garantizó que las operaciones críticas de recaudo tengan la misma visibilidad diagnóstica que las de consulta. Esta decisión de diseño es vital para la dirección de Facturación y Cobros, ya que asegura que un fallo en el procesamiento de pagos sea detectado con la misma celeridad y precisión que un error de visualización, protegiendo así la integridad financiera del ecosistema.

Conclusiones

El presente trabajo documenta la evaluación avanzada y optimización de hiperparámetros del modelo DistilBERT fine-tuneado para la clasificación predictiva de incidentes en canales de pago. Los principales hallazgos son:

- Objetivo alcanzado: La configuración óptima (lr=3e-5, epochs=3, batch=16, wd=0.01, warmup=0.06) alcanza un F1-Score macro de 0.8929, superando el umbral objetivo del proyecto (≥0.85) y confirmando la viabilidad del enfoque AIOps basado en Transformers para la gestión predictiva de incidentes.
- Hiperparámetros críticos: El Learning Rate y las Épocas de Entrenamiento concentran el 63% de la importancia total, constituyendo los ejes prioritarios de cualquier estrategia de optimización futura. El Batch Size, con solo 7.07% de importancia, puede fijarse sin pérdida de rendimiento.
- Sesgo identificado y mitigado: La colisión semántica entre las clases 401 y 403 representa el principal sesgo del modelo, con justificación operacional parcial. Las estrategias de mitigación propuestas (enriquecimiento del corpus, umbral de confianza, fusión de clases) permiten abordar este sesgo de forma progresiva.
- Generalización saludable en distribución.

Referencias

Bergstra, J., & Bengio, Y. (2012). Random search for hyper-parameter optimization. Journal of Machine Learning Research, 13, 281–305. https://jmlr.org/papers/v13/bergstra12a.html

Devlin, J., Chang, M.-W., Lee, K., & Toutanova, K. (2019). BERT: Pre-training of deep bidirectional transformers for language understanding. Proceedings of NAACL-HLT 2019, 4171–4186. https://doi.org/10.18653/v1/N19-1423

Friedman, J. H. (2001). Greedy function approximation: A gradient boosting machine. Annals of Statistics, 29(5), 1189–1232. https://doi.org/10.1214/aos/1013203451

Goodfellow, I., Bengio, Y., & Courville, A. (2016). Deep learning. MIT Press. https://www.deeplearningbook.org

Hardt, M., Price, E., & Srebro, N. (2016). Equality of opportunity in supervised learning. Advances in Neural Information Processing Systems, 29, 3315–3323. https://arxiv.org/abs/1610.02413

Hutter, F., Hoos, H., & Leyton-Brown, K. (2014). An efficient approach for assessing hyperparameter importance. Proceedings of ICML 2014, 754–762. https://proceedings.mlr.press/v32/hutter14.html

Sanh, V., Debut, L., Chaumond, J., & Wolf, T. (2019). DistilBERT, a distilled version of BERT: Smaller, faster, cheaper and lighter. arXiv preprint arXiv:1910.01108. https://arxiv.org/abs/1910.01108

Sun, C., Qiu, X., Xu, Y., & Huang, X. (2019). How to fine-tune BERT for text classification? China National Conference on Chinese Computational Linguistics, 194–206. https://doi.org/10.1007/978-3-030-32381-3_16

Wolf, T., Debut, L., Sanh, V., Chaumond, J., Delangue, C., Moi, A., Cistac, P., Rault, T., Louf, R., Funtowicz, M., & Brew, J. (2020). Transformers: State-of-the-art natural language processing. Proceedings of EMNLP 2020: System Demonstrations, 38–45. https://doi.org/10.18653/v1/2020.emnlp-demos.6