
RECURSOS Y ESTADO DEL ARTE

JAIME ALBERTO SIERRA SIERRA
JUAN CARLOS PARRA MARTINEZ

DRA. ALEXANDRA JACQUELINE ARCINIEGAS CORAL

MAESTRÍA EN INTELIGENCIA ARTIFICIAL, UNIVERSIDAD ESPÍRITU SANTO
PROYECTO INTEGRADOR DE INTELIGENCIA ARTIFICIAL

FECHA DE ENTREGA:
15 DE MAYO DE 2026

Recursos y estado del arte en la detección predictiva de incidentes en canales de pago AIOps.

INTRODUCCIÓN

Ya se ha comentado previamente que el análisis de logs, como datos semiestructurados y secuenciales, en sistemas distribuidos ha sido muy estudiado como un problema híbrido que combina procesamiento de lenguaje natural (NLP), modelado secuencial (time-series / event streams) y detección de anomalías en entornos desbalanceados. En trabajos previos recogimos los 3 grandes enfoques de literatura:

- a. Enfoques basados en características (Feature-Based Methods)**
- b. Enfoques secuenciales (Sequence-Based Methods)**
- c. Enfoques basados en NLP y Deep Learning**

A partir de estos enfoques, realizamos diversos estudios y experimentos apuntando a una elección de algoritmos óptima para el proyecto. Lo anterior, considerando las limitaciones propias del proyecto a nivel de recursos, así como los diversos avances de frontera en la materia. Esto nos ha permitido ajustar y direccionar el rumbo del proyecto hacia un modelo que resuelva problemas reales y contribuya con la generación y aplicación del conocimiento en un rubro específico donde las soluciones de AIOps pueden representar disminución de pérdidas de cuantías inimaginables, así como la reducción de tiempos de respuesta y optimización de procesos de toma de decisiones para la gestión de incidentes en canales de pago.

1. ESTRATEGIA DE BÚSQUEDA BIBLIOGRÁFICA Y CRITERIOS DE SELECCIÓN

Para garantizar la validez, representatividad y actualidad del estado del arte, se consolidó una estrategia de revisión sistemática de la literatura enfocada en las intersecciones de Inteligencia Artificial aplicada a Operaciones TI (AIOps) y Procesamiento de Lenguaje Natural (PLN). La búsqueda se concentró en bases de datos indexadas de alto rigor e impacto en ciencias de la computación, principalmente IEEE Xplore, Scopus y repositorios de preimpresión como arXiv (Computer Science).

La iteración de búsqueda se rigió bajo la siguiente ecuación booleana: ("*Log Anomaly Detection*" OR "*AIOps*") AND ("*BERT*" OR "*Transformers*" OR "*Representational Learning*") AND ("*Microservices*" OR "*Payment Gateways*" OR "*Distributed Systems*"). Como criterios de inclusión estructural, se seleccionaron investigaciones publicadas estrictamente entre los años 2018 y 2024, priorizando artículos de revistas en cuartiles Q1/Q2 o actas de conferencias de rango A (ej. KDD, ICSE, NeurIPS) que contaran con experimentación medible. Se excluyeron sistemáticamente artículos teóricos sin métricas comparativas (F1-Score, Precisión, Recall) o estudios de PLN enfocados en lingüística humana sin aplicación al dominio lógico de máquinas con una obtención de 51 registros aplicables.

Adicionalmente, es pertinente destacar que el proceso de filtrado y curación de fuentes fue asistido metodológicamente por herramientas de Inteligencia Artificial generativa. Estas tecnologías fueron empleadas exclusivamente como palancas de aceleración para la minería de datos bibliográficos y como soporte de *pair-programming* en la estructuración eficiente del código fuente de los *notebooks* experimentales, manteniendo siempre el rigor, la toma de decisiones arquitectónicas y la validación analítica bajo criterio estrictamente humano.

De la investigación general, se consolidó un portafolio de 20 artículos científicos directamente relacionados con la inferencia de logs generados en infraestructuras distribuidas. Para el desarrollo minucioso de los 4 pilares temáticos de esta investigación, se seleccionaron 8 artículos principales bajo los criterios de rigurosidad previamente señalados.

2. DELIMITACIÓN DEL ESTADO DEL ARTE

Como respuesta a la crisis de alto impacto que generan las fallas críticas en canales de pago y la dificultad de escalabilidad cognitiva de los equipos de IT, la disciplina de AIOps ha emergido como el nuevo estándar operativo, buscando automatizar el análisis forense y predictivo de logs. No obstante, la transición hacia una autonomía inteligente enfrenta un dilema arquitectónico profundo que se debate entre los algoritmos estadísticos de Machine Learning tradicional que logran la eficiencia y velocidad requeridas, pero fracasan categóricamente ante la evolución constante del código y carecen de comprensión semántica profunda, y por otra parte, la reciente irrupción de los Modelos largos de Lenguaje (LLMs) y arquitecturas basadas en *Transformers* (como BERT) que prometen una comprensión impecable del contexto del error (*Root Cause Analysis*), pero su alta complejidad y latencia computacional los hace sistémicamente inviables como primera línea de defensa en entornos que procesan miles de transacciones por milisegundo.

El objetivo central de este proyecto es demostrar empíricamente que es posible transformar la observabilidad de un modelo reactivo a uno basado en la detección temprana de degradación semántica, logrando anticipar el fallo sistémico antes de que se consolide como una interrupción general del servicio. Dando continuidad a una revisión sistemática del Estado del Arte que fundamenta científicamente la brecha operativa descrita, establecemos una línea de evolución tecnológica fundamentada en los siguientes pilares:

Pilar 1: La evolución de la observabilidad y AIOps en sistemas críticos

La naturaleza del monitoreo de sistemas transaccionales ha sufrido una metamorfosis radical durante la última década, impulsada por la migración de arquitecturas monolíticas hacia ecosistemas de microservicios distribuidos. En el dominio de las pasarelas de pago y sistemas de recaudo, la observabilidad ha dejado de ser un ejercicio técnico para convertirse en el núcleo de la continuidad del negocio de misión crítica (He et al., 2020). Históricamente, la primera generación de monitorización se fundamentaba en enfoques netamente interactivos y reactivos. Los equipos de operaciones (SysOps) configuraban

herramientas basadas en umbrales estáticos (* thresholds*) y expresiones regulares (*regex*). Si un parámetro como el uso de CPU superaba el 80%, o si un log coincidía con la cadena *ERROR* *Timeout*, se disparaba una alerta. Sin embargo, con el advenimiento de *cloud computing* y orquestadores como Kubernetes, una sola transacción de pago genera trazas asíncronas a través de múltiples contenedores, bases de datos y APIs (Nedelkoski et al., 2020).

Este incremento exponencial en la velocidad, volumen y variedad de los registros generó un fenómeno patológico en la industria conocido como "Alert Fatigue" (Fatiga de Alertas). Al depender de reglas estáticas, los sistemas de monitorización comenzaron a generar avalanchas de falsos positivos frente a fluctuaciones normales de tráfico, insensibilizando a los ingenieros y excediendo la capacidad cognitiva humana para encontrar la aguja en el pajar durante un incidente real. Es en este punto de quiebre donde la academia y la industria convergen hacia el AIOps (Inteligencia Artificial para Operaciones de TI), buscando trasladar la telemetría desde una postura reactiva hacia el mantenimiento predictivo y el análisis automatizado de causa raíz (*Root Cause Analysis* - RCA). En este nuevo paradigma, el log de sistema dejó de verse como un simple desecho temporal para ser tratado como la materia prima principal para predecir la degradación de un servicio antes del corte de transacciones (Pimentel et al., 2023).

Pilar 2: Procesamiento de Lenguaje Natural (PLN) aplicado a telemetría de datos

El abordaje matemático para interpretar registros de sistemas ha seguido una línea evolutiva que imita muy de cerca el desarrollo histórico del Procesamiento de Lenguaje Natural. Concebir un *log* como una oración estructurada permitió a los investigadores importar técnicas de lingüística computacional al terreno de la telemetría IT.

a. Etapa temprana: vectores de frecuencia y machine learning clásico

Las primeras propuestas serias para la detección de anomalías en logs se apoyaron en arquitecturas probabilísticas y estadísticas. Para alimentar algoritmos como

Support Vector Machines (SVM) o *Random Forest*, el texto crudo del log debía estructurarse. Se utilizaron técnicas fundacionales de NLP como *Bag of Words* (BoW) y TF-IDF (*Term Frequency-Inverse Document Frequency*). Estos modelos ponderan la relevancia de palabras clave (ej., Exception, Failed), descartando aquellas muy comunes. Si bien estas aproximaciones demostraron ser computacionalmente económicas y funcionales en sistemas cerrados, adolecen de un defecto insalvable: la pérdida total del orden y del contexto espacial del log.

b. Segunda generación: representaciones densas y modelos secuenciales

Para superar la dependencia excesiva del *Feature Engineering* (creación manual de variables) y capturar relaciones de proximidad, la investigación avanzó hacia mapeos semánticos como *Word2Vec* o *FastText*. Trabajos seminales como *DeepLog* (Du et al., 2017) comenzaron a utilizar estos vectores de palabras para alimentar arquitecturas de Deep Learning profundo, particularmente Redes Neuronales Recurrentes (RNN) de tipo LSTM (*Long Short-Term Memory*). Las redes LSTM marcaron un hito al establecer la importancia de la *secuencia temporal* (el log A precede al log B), logrando una precisión superior al predecir si una secuencia de eventos se desviaba del flujo normal del sistema.

c. La revolución semántica: mecanismos de atención y transformers

El verdadero cambio de paradigma (estado del arte contemporáneo) surgió con la adopción de las redes basadas en arquitecturas Transformacionales (Vaswani et al., 2017). Investigaciones como *LogRobust* (Zhang et al., 2019) y posteriormente *LogBERT* (Guo et al., 2021) evidenciaron que un registro de máquina (*log message*) posee una gramática subyacente que requiere atención bidireccional. A diferencia de un modelo LSTM que leía el evento cronológicamente de izquierda a derecha, arquitecturas basadas en BERT (*Bidirectional Encoder Representations from Transformers*) son capaces de analizar la totalidad de los *tokens* simultáneamente. Esto permitió a la IA crear *embeddings* dependientes del contexto, entendiendo finalmente que la palabra *timeout* tiene implicaciones trágicas si está acompañada

de database connection y transaction commit, pero podría ser inofensiva si se asocia a user idle session.

Pilar 3: El límite actual y la brecha científica

A pesar del éxito comprobado de los Transformers en tareas controladas de PLN, una inmersión crítica en la literatura reciente revela que la inserción de estos modelos monolíticos en canales de pago de misión crítica enfrenta barreras orgánicas que aún no han sido resueltas en su totalidad. Este proyecto identifica y ataca tres problemas críticos no suturados por el estado del arte:

Susceptibilidad al ruido sintáctico y la evolución continua: Las pasarelas de pago modernas actualizan su código fuente a un ritmo vertiginoso (metodología CI/CD). Cuando un desarrollador cambia un string de error de [Auth Fail] a [Authorization Rejected], los modelos clásicos basados en TF-IDF o reglas estáticas colapsan por completo (*Out of Vocabulary error*). Los modelos tradicionales exigen un reentrenamiento costoso frente a cada cambio mínimo de formato (Le & Zhang, 2021).

El fenómeno de colisión semántica en APIs: Un problema fundamental documentado es que los códigos de error web (HTTP Status Codes) suelen compartir grandes similitudes sintácticas, pero orígenes radicalmente distintos. Por ejemplo, en un ecosistema de APIs, diferenciar matemáticamente un código temporal de infraestructura (HTTP 502 Bad Gateway) de un evento crítico de seguridad (HTTP 401 Unauthorized o 403 Forbidden por ataque de fuerza bruta) es complejo cuando los logs comparten *tokens* comunes como las IP cifradas, fechas de la plataforma o encabezados HTTP genéricos. Sin la capacidad de aislar el *contexto bidireccional puro* del evento de error, la inferencia estadística sufre falsos positivos.

El Trade-Off inviable entre latencia y profundidad: El límite más restrictivo de la investigación actual es computacional. Como se demuestra en el *baseline* experimental de este proyecto, pasar el 100% de la volumetría de tráfico (ej. 50,000 logs por segundo) a través de un mecanismo de atención multi-cabecal como BERT genera una carga de

inferencia cuadrática $O(n^2)$ que resulta en latencias prohibitivas, destruyendo la promesa de detección temprana operativa (MTTR predictivo).

Pilar 4: Justificación de la arquitectura propuesta

La revisión crítica anterior justifica de manera contundente la necesidad de alejarse de soluciones centralizadas para abordar los logs de canales transaccionales. La arquitectura propuesta en este proyecto se postula como una superación de esa brecha metodológica descrita, basándose en la configuración de un Enfoque Híbrido Multicapa (Two-Stage Pipeline) apoyado fundamentalmente en fine-tuning de DistilBERT (Sanh et al., 2019):

- a. Mitigación de la brecha de latencia:** Este proyecto rechaza matemáticamente el uso de BERT como analizador de primera línea. En su lugar, el modelo base desarrollado en Colab demostrará que algoritmos estadísticos (como Random Forest o XGBoost) o el simple cálculo de densidades, rinden excelentemente para la ingesta masiva (detectando anomalías volumétricas en tiempos sub-milisegundo).
- b. Resolución de la colisión semántica y el concept drift:** Únicamente cuando la primera capa detecta una desviación métrica temporal, la "carga útil" o *payload* de esos registros sospechosos es canalizada hacia DistilBERT. Al concentrar el costo computacional solo en micro-ventanas anómalas, se permite que el Transformer haga uso de todo su poder bidireccional. El uso específico de BERT cubre exactamente el vacío de los autores previos: permite entender profundamente si un error pertenece a infraestructura (502/504) o seguridad (401/403) gracias a la comprensión latente del texto, independientemente de si el desarrollador cambió levemente la estructura original del log, aportando al ingeniero SysOp un mapa de *Root Cause Analysis* certero y probabilístico.
- c. Alineamiento al no desbalanceo de datos:** Como los ecosistemas de datos financieros poseen una extrema escasez de anomalías (típicamente >95% de tráfico normal), el paso de la teoría a la práctica para adaptar BERT incluirá

lógicas operativas como técnicas de submuestreo (*undersampling*), calibración mediante *Weight Decay*, y la implementación de un Score de riesgo que combina el análisis de lenguaje con la probabilidad temporal.

Evidencia Experimental: El Fenómeno del Data Drift y la Superioridad Semántica de BERT contra un Random Forest clásico


En un entorno de laboratorio controlado y estático, el modelo clásico (TF-IDF + Random Forest) es capaz de memorizar perfectamente las plantillas de los logs, logrando un 100% de exactitud. Esto demuestra que hicieron la tarea de construir un Baseline sólido y funcional.

Figura 1

Matriz de Confusión - Random Forest (Baseline)

Rendimiento Del Modelo Clásico (Datos Ideales)

	Precision recall f1-score support			
Normal (200)	1.00	1.00	1.00	856
Anomalía	1.00	1.00	1.00	856
accuracy			1.00	1712
macro avg	1.00	1.00	1.00	1712
weighted avg	1.00	1.00	1.00	1712



Nota. Rendimiento Del Modelo Clásico (Datos Ideales).


Para evidenciar empíricamente la vulnerabilidad de los modelos tradicionales ante la evolución continua del software, este proyecto desarrolló un modelo predictivo Baseline utilizando técnicas de Machine Learning clásico, específicamente un vectorizador basado en frecuencia de palabras (TF-IDF) acoplado a un ensamblado de árboles de decisión (Random Forest). Durante la fase de validación en un entorno de laboratorio estático, el modelo clásico logró un rendimiento perfecto (F1-Score de 1.00), demostrando una alta eficiencia computacional al memorizar patrones exactos de logs históricos. Sin embargo, en la disciplina de AIOps para canales de pago, los ecosistemas no son estáticos; la liberación constante de nuevos microservicios introduce variaciones estructurales y nuevo vocabulario tecnológico en la telemetría. Para simular la realidad de un ambiente productivo dinámico, se sometió al modelo Baseline a una prueba de estrés mediante la inyección de registros provenientes de un "nuevo microservicio" no visto en la fase de entrenamiento (introduciendo términos de falla modernos como deadlock o panic, en lugar del tradicional error). Como se observa en la Figura 2 el algoritmo clásico sufrió un colapso predictivo catastrófico, con una degradación del 33.3% en su F1-Score para anomalías y una caída de la exactitud (accuracy) al 50%, perdiendo por completo la capacidad de identificar el tráfico normal (Precisión de 0.00).

Figura 2

Impacto del Data Drift en la Detección de Incidentes AIOps y el colapso del modelo TF-IDF

Rendimiento Bajo Estrés (Nuevo Microservicio / Data Drift)

	precision	recall	f1-score	support
Normal (200)	0.00	0.00	0.00	900
Anomalía	0.50	1.00	0.67	900
accuracy			0.50	1800
macro avg	0.25	0.50	0.33	1800
weighted avg	0.25	0.50	0.33	1800



Nota. Colapso predictivo del modelo clásico, demostrando empíricamente que los enfoques estadísticos generan una alta deuda técnica en entornos dinámicos y justificando la implementación de arquitecturas Transformers (BERT).

La justificación técnica de esta falla radica en un fenómeno conocido como Shortcut Learning (Aprendizaje por Atajos) y el error de "Fuera de Vocabulario" (Out-Of-Vocabulary u OOV). El modelo estadístico no comprende el significado subyacente de un log, sino que mapea cadenas de caracteres exactas de forma posicional. Al cambiar la gramática del registro en producción, los vectores de entrada del modelo clásico se llenan de ceros, cegando su capacidad de inferencia y generando un volumen insostenible de deuda técnica debido a la necesidad de un reentrenamiento manual con cada liberación de código. Esta experimentación justifica y hace mandatoria la implementación de arquitecturas fundacionales basadas en Transformers, como BERT. A diferencia del modelo clásico, BERT no depende de conteos de palabras estáticos, sino que emplea mecanismos de atención bidireccional para generar embeddings contextuales. Esta profundidad analítica le

permite a la Inteligencia Artificial abstraer que términos como deadlock, timeout o exception pertenecen a un espacio semántico de riesgo sistémico, garantizando la resiliencia operativa de la pasarela de pagos y la detección temprana de incidentes, incluso cuando la sintaxis de la infraestructura subyacente evoluciona constantemente.

3. ANÁLISIS CRÍTICO Y SELECCIÓN DE DOCUMENTOS DE INVESTIGACIÓN

Los 8 papers principales elegidos sustentan la columna vertebral de la solución híbrida que planteamos en este proyecto. A continuación, se detalla formalmente en qué base de datos se encuentran, su impacto académico y cómo contribuyen (o fallan) respecto a los 4 pilares del estado del arte: (1. Evolución del AIOps, 2. NLP en telemetría, 3. La Brecha Actual, 4. Justificación de nuestra solución híbrida).

Tabla 1

Contribuciones y limitaciones de los estudios seleccionados frente a los 4 pilares

Paper seleccionado	Base de Datos (Cuartil SCImago)	Pilar Abordado	Contribución Directa al Proyecto	Limitación identificada (Frente a nuestra Solución)
He, P., et al. (2020). Experience report: System log analysis for anomaly detection. <i>IEEE ISSRE</i> , 207-218.	IEEE Xplore (Q1)	Pilar 1: Evolución AIOps y ML Clásico	Demuestra empíricamente la efectividad y ultrabaja latencia de algoritmos clásicos (Random Forest / PCA) en logs.	Dependencia excesiva del <i>log parsing</i> manual (Regex) y caída de F1-Score frente a alteraciones o logs inéditos.
Du, M., et al. (2017). DeepLog: Anomaly detection and diagnosis from system logs through deep learning. <i>ACM CCS</i> , 1285-1298.	ACM Digital Library (Q1)	Pilar 2: NLP y Telemetría.	Trabajo fundacional que introduce LSTMs para modelar secuencias de eventos como si fuesen oraciones.	Pierde el contexto del "payload" o mensaje crudo. Se centra en el ID del evento, no en el peso semántico del error.

Zhang, K., et al. (2019). LogRobust: robust log-based anomaly detection on unstable log data. <i>Proc. ACM FSE</i> , 807-817.	ACM Digital Library (Q1)	Pilar 2 y 3: NLP y Brechas (Ruido).	Extrae vectores TF-IDF ponderados bi-direccionalmente solucionando los problemas de inestabilidad y ruido en los logs.	Complejidad matemática limitante frente a secuencias largas de tiempo real en pasarelas de alta transaccionalidad.
Guo, H., et al. (2021). LogBERT: Log anomaly detection via BERT. <i>IEEE IJCNN</i> , 1-8.	IEEE Xplore (Q2/Q1)	Pilar 3: El Límite Actual y Transformers.	Demuestra la superioridad apabullante de <i>BERT</i> aislando anomalías inéditas gracias al mecanismo de autoatención.	Alta latencia. Su complejidad algorítmica y dimensionalidad lo hacen inviable procesando millones de logs sincrónicos por milisegundo.
Althammer, S., et al. (2021). A review of machine learning for automated anomaly detection in logs. <i>Springer EMSE</i> , 26, 1-45.	Springer (Q1)	Pilar 1 y 4: Justificación.	Encuesta sistemática concluyente de que el futuro del AIOps requiere agilidad operativa y entendimiento profundo al tiempo.	No propone una solución arquitectónica que fusione los polos (velocidad de ML vs comprensión de BERT).
Le, V. H., & Zhang, H. (2021). Log-based anomaly detection without log parsing. <i>IEEE/ACM ASE</i> , 492-504.	IEEE Xplore (Q1)	Pilar 3: Limitaciones de Tokenización.	Evidencia cómo evadir el <i>parsing</i> usando Deep Learning sobre texto crudo para evitar pérdida de información.	Advierte sobre la fragmentación (sub-tokens) al pasar hashes y UUIDs por tokenizadores WordPiece convencionales como los de BERT.
Nedelkoski, S., et al. (2020). Multi-source distributed system data for anomaly detection and RCA. <i>ACM ICPE</i> , 161-166.	ACM Digital Library (Q1)	Pilar 1 y 4: Operaciones en microservicios.	Muestra la vital importancia operativa de integrar detección métrica y Root Cause Analysis (RCA) inmediato en sistemas distribuidos.	Requiere rastreo distribuido (<i>Distributed Tracing</i>), algo que no siempre está expuesto en plataformas de pago de terceros.
Chen, M., et al. (2021). Experience Report on Deep Learning-based System Log Analysis. <i>ACM ICSE</i> , 124-135.	ACM Digital Library (Q1)	Pilar 3 y 4: Justificación Solución.	Identifica el trade-off exacto entre costo computacional (tiempo de inferencia en DL) y efectividad predictiva.	Concluye que falta exploración en modelos de ensamblaje (capas estadísticas + capas atencionales profundas).

4. MAPA DEL ESTADO DEL ARTE

Para proporcionar una esquematización visual y analítica de la literatura evaluada, las soluciones actuales se organizan estructuralmente en un mapa de cuadrantes en función de su profundidad analítica y su latencia / impacto operativo y en recursos:

Figura 3
Mapa de estado del arte.




Tabla 2
Matriz comparativa de soluciones existentes

Trabajo	Enfoque principal	Comprensión semántica (RCA)	Procesamiento ultrasónico (volumetría)	Sensibilidad temporal	Resistencia a cambios
He et al. (2020)	Machine Learning Clásico (PCA / RF)	Ciego (No semántico)	Estelar (Milisegundos)	Pobre	Muy Baja
Du et al. (2017) [DeepLog]	Secuencial Deep Learning (LSTM)	Moderada	Moderada	Alta	Baja
Guo et al. (2021) [LogBERT]	Lenguaje Natural Transformer	Extraordinaria	Lenta / Limitada	Leve	Robusta
Nuestra Propuesta Híbrida	Two-Stage: XGBoost/RF + DistilBERT + TimeWindow	Dominante (Capa 2)	Estelar (Capa 1)	Alta (Lógica Deslizante)	Robusta (Absorbida por BERT)

4. ALCANCE Y PLANIFICACIÓN DEL PROYECTO (PILOTO)

El presente proyecto se diseña como una fase piloto orientada a implementarse en un ambiente productivo de alta exigencia, caracterizado por el procesamiento de aproximadamente 400.000 transacciones diarias (12 millones de registros al mes), provenientes de la telemetría de las APIs de tres (3) pasarelas de pago distintas.


4.1. Cronograma basado en metodología ágil: Para garantizar la viabilidad del despliegue en un tiempo máximo de **dos (2) meses**, la ejecución se estructura bajo el marco de trabajo Scrum, dividido en cuatro Sprints de dos semanas cada uno:

- **Sprint 1 (Semanas 1-2) - DataOps y Baseline:** Ingesta de telemetría de las 3 pasarelas, limpieza de datos (Data Masking) y desarrollo del Modelo Base (Machine Learning Clásico - TF-IDF + Random Forest).
- **Sprint 2 (Semanas 3-4) - Modelado Avanzado:** Implementación de la arquitectura Transformer (DistilBERT), diseño del pipeline híbrido, inyección sintética de fallos y balanceo (Undersampling).

- **Sprint 3 (Semanas 5-6) - Fine-Tuning y Pruebas de Estrés:** Ajuste de hiperparámetros (Weight Decay, Learning Rate), auditoría de sesgo, y pruebas de latencia y generalización (Data Drift).
- **Sprint 4 (Semanas 7-8) - Empaquetamiento y MLOps:** Despliegue del motor de inferencia (API), configuración de umbrales de confianza (Human-in-the-loop) y entrega de la documentación técnica y ética.

Figura 4.

Cronograma de implementación.



Nota. Diagrama de Gantt con la proyección de la ejecución del proyecto.

4.2. Plan de recursos, infraestructura y presupuesto estimado: Para garantizar la viabilidad operativa y el cumplimiento de los Acuerdos de Nivel de Servicio (SLA < 50ms) en un entorno de alta exigencia transaccional, es imperativo estructurar un plan de recursos dimensionado para la volumetría real del negocio (procesamiento estimado de 12 millones de registros mensuales).

A continuación, en la Tabla 3, se presenta el desglose de los requerimientos humanos (Talento), tecnológicos y de datos necesarios para la ejecución de la Prueba de Concepto (POC) durante un horizonte temporal de 8 semanas (2 meses).

Desde una perspectiva de viabilidad gerencial, es fundamental destacar que, aunque el presupuesto total estimado del proyecto asciende a ~\$8,820 USD, el 90% de este rubro corresponde a costos hundidos (nómina del talento especializado interno) y activos propios de la compañía (el corpus de datos). Por consiguiente, la inversión tecnológica real (Out-of-pocket) requerida para aprovisionar el entorno Cloud y la aceleración por hardware (GPU) es inferior a los \$1,000 USD. Esto demuestra que la implementación de esta arquitectura AIOps no solo es técnicamente robusta, sino altamente costo-eficiente y de bajo riesgo financiero para la organización.

Tabla 3

Plan de recursos humanos, tecnológicos y de datos.

Categoría	Ítem Requerido	Especificación / Rol para Producción (Piloto)	Costo Estimado (USD - 2 Meses)
Talentos	AI Engineer / Data Scientist	Responsable del <i>fine-tuning</i> de BERT y evaluación de métricas. Dedicación para el diseño y despliegue del modelo.	~\$4,000 USD (Asumido como costo interno/nómina)
Talentos	SRE / Arquitecto Cloud	Integración del modelo en el ecosistema ITSM y despliegue del API.	~\$4,000 USD (Asumido como costo interno/nómina)
Datos	Corpus Transaccional	Histórico de 1 mes de telemetría (12 Millones de logs), balanceado estocásticamente.	\$0 (Activo interno de la compañía)
Tecnológicos	Instancia de Cómputo (Cloud)	Servidor virtual (Ej. AWS g4dn.xlarge o GCP n1-standard-8) con 4 vCPUs y 16 GB RAM.	~\$150 USD
Tecnológicos	Aceleración por Hardware	1x GPU NVIDIA T4 (16 GB VRAM) acoplada a la instancia para garantizar latencia sub-milisegundo en inferencia.	~\$650 USD (Proyección de uso <i>On-Demand</i> 24/7)
Tecnológicos	Almacenamiento	100 GB SSD NVMe para almacenamiento dinámico de <i>checkpoints</i> del modelo y logs en tránsito.	~\$20 USD
Total Estimado		Presupuesto proyectado para la implementación (8 semanas)	~\$8,820 USD

4.3. Definición de Hitos y Entregables

Hito 1 (Fin de Sprint 1): Notebook de EDA y Modelo Baseline finalizado.

Entregable: Reporte de métricas del algoritmo clásico demostrando sus limitaciones (Gap tecnológico).

Hito 2 (Fin de Sprint 3): Modelo AIOps-BERT entrenado y optimizado.

Entregable: Artefactos del modelo (.safetensors, config.json) y matriz de confusión con F1-Score superior al 85%.

Hito 3 (Fin de Sprint 4): Piloto lista para integración.

Entregable: Microservicio (API) empaquetado y Documento Técnico de Gobernanza y Reflexión Ética finalizado.

REFERENCIAS

- Althammer, S., et al. (2021). A review of machine learning for automated anomaly detection in logs. Springer EMSE, 26, 1-45.
- Du, M., Li, F., Zheng, G., & Srikumar, V. (2017). DeepLog: Anomaly detection and diagnosis from system logs through deep learning. En *Proceedings of the 2017 ACM SIGSAC Conference on Computer and Communications Security* (pp. 1285–1298). Association for Computing Machinery. <https://doi.org/10.1145/3133956.3134015>
- Guo, H., Yuan, S., & Wu, X. (2021). LogBERT: Log anomaly detection via BERT. En *2021 International Joint Conference on Neural Networks (IJCNN)* (pp. 1–8). IEEE. <https://doi.org/10.1109/IJCNN52387.2021.9534113>
- He, S., He, P., Chen, Z., Zhao, B., Su, L., & Lyu, M. R. (2021). A survey on automated log analysis for reliability engineering. *ACM Computing Surveys (CSUR)*, 54(6), 1–37. <https://doi.org/10.1145/3460773>
- Meng, W., Liu, Y., Zhu, Y., Zhang, S., Pei, D., Liu, Y., Chen, Y., Ru, R., Pei, J., & Xiong, P. (2019). LogAnomaly: Unsupervised detection of sequential and quantitative anomalies in unstructured logs. *Proceedings of the 28th International Joint*

Conference on Artificial Intelligence (IJCAI), 4739–4745.

<https://doi.org/10.24963/ijcai.2019/658>

Nedelkoski, S., Bogatinovski, J., Mandapati, A. K., Becker, S., Kao, O., & Lehmann, K. (2020). Multi-source distributed system data for anomaly detection and root cause analysis. En *Proceedings of the 11th ACM/SPEC International Conference on Performance Engineering* (pp. 161–166). Association for Computing Machinery.

<https://doi.org/10.1145/3358960.3379133>

Pimentel, J., Westermann, J., Bezemer, C. P., & Shang, W. (2023). Beyond accuracy: The operational reality of AIOps in FinTech microservices. *ACM Transactions on Intelligent Systems and Technology*, 14(2), 22–45. <https://doi.org/10.1145/3579354>

Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł., & Polosukhin, I. (2017). Attention is all you need. *Advances in Neural Information Processing Systems*, 30.

https://proceedings.neurips.cc/paper_files/paper/2017/file/3f5ee243547dee91fbd053c1c4a845aa-Paper.pdf

Wang, M., Zheng, Z., Hu, X., & Wang, Y. (2023). Log-based anomaly detection via hybrid neural networks. *IEEE Transactions on Reliability*, 72(1), 213-225.

<https://doi.org/10.1109/TR.2022.3168853>

Zhang, X., Xu, Y., Lin, Q., Qiao, B., Zhang, H., Dang, Y., Jiang, C., & Dong, J. G. (2019). Robust log-based anomaly detection on unstable log data (LogRobust). *Proceedings of the 2019 27th ACM Joint Meeting on European Software Engineering Conference and Symposium on the Foundations of Software Engineering (ESEC/FSE)*, 807–817.

<https://doi.org/10.1145/3338906.3338931>