Reflexión Ética del Proyecto

Juan Carlos Parra Martínez

Jaime Alberto Sierra Sierra

Maestría en Inteligencia Artificial, Universidad Espíritu Santo.

Proyecto integrador de inteligencia artificial

Dra. Alexandra Jacqueline Arciniegas Coral

08 de mayo de 2026

Introducción

La adopción de modelos basados en Procesamiento de Lenguaje Natural (como arquitecturas Transformer) para la automatización de Operaciones de TI (AIOps) representa un salto evolutivo en la resiliencia de los ecosistemas financieros. Sin embargo, delegar el triaje y diagnóstico de incidentes transaccionales a un modelo de Machine Learning conlleva responsabilidades inherentes. La automatización sin una gobernanza adecuada puede amplificar sesgos sistémicos, vulnerar la privacidad a través de la exposición de datos telemétricos y diluir la rendición de cuentas (Floridi et al., 2018). El presente documento analiza estructuralmente los riesgos éticos, el impacto diferencial en los stakeholders y establece una Declaración de Responsabilidad Ética con compromisos operativos claros para garantizar que la solución AIOps sea transparente, equitativa y segura.

1. Caso de estudio: Identificación de riesgos éticos

Para este análisis, nos fundamentamos en marcos éticos estandarizados, como las directrices para una IA Confiable de la Unión Europea (Jobin, Ienca & Vayena, 2019), adaptándolos a nuestro entorno de procesamiento de logs y pasarelas de pago.

1.1. Tabla de Riesgos Éticos Completada

Frameworks éticos	Idea central	Pregunta guía	Riesgo que detecta
Ética por principios	Justicia / Equidad Transparencia Beneficencia Autonomía Prudencia No maleficencia	¿Qué principio será más grave?	**Opacidad (Caja Negra) y Sesgo de Priorización**: Riesgo de que el modelo priorice silenciosamente la resolución de fallos en pasarelas corporativas sobre las de usuarios individuales (afectando la Equidad), y la imposibilidad de explicar por qué la IA enrutó un ticket específico (afectando la Transparencia). **Cuestionar las decisiones:** Riesgo de cuestionar las acciones tomadas por los profesionales de TI asumiendo que los análisis efectuado por el modelo pueden dar mejorares resultados.
Enfoque basado en riesgo	Riesgos Técnicos Riesgos Éticos Riesgos Sociales	¿Qué podría salir mal, aunque el proyecto funcione correctamente?	**Sesgo de Automatización (Automation Bias) y Falsos Positivos**: Que el equipo de Ingeniería de Fiabilidad del Sitio (SRE) confíe ciegamente en la IA, ignorando alertas legítimas de fraude, caída de infraestructura o caída del sistema (clasificadas erróneamente por el modelo por colisión semántica 401/403), afectando la seguridad operativa. **Generación de alarmar no procedentes (Falson negativos)**: Riesgo de saturar los sistemas de monitoreo con falsas alarmas debido a la mala interpretación de exitosos reportándolos como errores falsos.

Responsabilidad y rendición de cuentas	Quien Diseña Quien Implementa Quien Responde ante cualquier daño	¿Quién asume la responsabilidad si el proyecto causa un daño?	**Dilución de Responsabilidad Computacional**: Si un fallo no detectado por el modelo genera pérdidas financieras, se corre el riesgo de un vacío legal/operativo al no poder trazar la culpa entre el equipo de IA, el de Monitoreo o el proveedor del software. **Normalización fallos**: Riesgo en la normalización de los errores sin que se haga un análisis de causa raíz adecuado y por ende que no se tomen las acciones correctivas adecuadas o que se confié en acciones no adecuadas.
Derechos humanos y privacidad	Confidencialidad Protección de datos personales Ejercicio de derechos a una explicación Dignidad	¿Qué derecho humano podría ser afectado por el proyecto?	**Fuga de PII (Información Personal Identificable)**: Procesar logs sin un pre-procesamiento adecuado puede exponer tokens, IDs de usuario o montos financieros a los ingenieros de soporte, violando normativas como el Habeas Data o PCI-DSS.
Ética por diseño	Evaluaciones Continuas Mejora Continua	¿En qué etapa se podrían materializar los riesgos éticos?	**Degradación Silenciosa (Data Drift)**: Riesgo de obsolescencia en producción. Sin reentrenamiento, el modelo (IA) comenzará a diagnosticar erróneamente los nuevos tipos de fallos, afectando la disponibilidad del servicio financiero con el tiempo. **No considerar factores de ética**: Riesgo por no considerar el análisis ético en las etapas de diseño del modelo abriendo la vulnerabilidad de tener posibles sesgos en las fases de entrenamiento.

1.2. Análisis de impacto en grupos de usuarios (Diferencial)

- **Usuarios Excluidos o Vulnerables (Afectados Invisibles):** Clientes finales. Si el modelo clasifica erróneamente un fallo de la pasarela como un "Error 401 de usuario" en lugar de un "Error 504 de timeout", la transacción se bloquea y el usuario

asume la culpa. Estos usuarios carecen de medios técnicos para disputar el fallo algorítmico, exponiéndolos a moras o cortes de servicio.

- **Usuarios Indirectos:** Comercios que dependen del *uptime* de la pasarela. Un falso negativo impacta directamente sus ingresos sin que tengan visibilidad ni control sobre la herramienta AIOps que falló en diagnosticar el problema.

1.3. Estrategias de mitigación normativa

Las estrategias de mitigación no se limitan a controles técnicos aislados, sino que establecen un marco de gobernanza integral para contrarrestar los riesgos identificados en cada dimensión ética:

A. Mitigación de la Opacidad y Sesgos (Dimensión: Ética por Principios)

El riesgo de que el modelo priorice incidentes corporativos o tome decisiones "caja negra" que los operadores no puedan auditar se aborda mediante:

- **Inteligencia Artificial Explicable (XAI):** Integración de librerías de explicabilidad algorítmica (como SHAP o LIME) en el *pipeline* de inferencia. Esto permitirá extraer los Attention Weights del modelo Transformer que son valores numéricos, generalmente entre 0 y 1, que cuantifican la importancia o relevancia de cada palabra (o token) en una secuencia con respecto a otra al procesar información, proporcionando a los ingenieros SRE una justificación visual de qué palabras o patrones en la traza del log motivaron el diagnóstico, asegurando el principio de Transparencia.
- **Auditorías de Equidad Algorítmica (Fairness Testing):** Ejecución de evaluaciones trimestrales (ej. *Equal Opportunity*) para medir la tasa de detección (*Recall*) entre diferentes flujos de negocio (ej. usuarios individuales vs. cuentas corporativas). Si se detecta una desviación significativa, se forzará un reentrenamiento utilizando *Undersampling* equilibrado para corregir el sesgo.

B. Mitigación del Sesgo de Automatización y Alarmas no Procedentes (Dimensión: Enfoque Basado en Riesgo)

Para combatir la confianza ciega del equipo SRE (*Automation Bias*) y la saturación de los sistemas ITSM por falsas alarmas (falsos positivos/negativos):

- **Intervención Humana Condicionada (*Human-in-the-loop*):** Establecimiento de un umbral de confianza mínimo (ej. 75% de certeza predictiva). Si el modelo diagnostica un incidente (especialmente en casos de colisión semántica como errores 401 vs 403) con una confianza inferior a este límite, la automatización del *ticket* se suspende y la alerta se etiqueta como "Incierta", escalando obligatoriamente a un operador humano para su triaje manual.
- **Aislamiento de Diagnósticos Críticos:** Las anomalías que el modelo clasifique como errores de infraestructura severos (ej. 500, 503) generarán notificaciones con un nivel de severidad visual distinto en el panel de control, forzando la atención del operador y evitando que se mezclen con el tráfico nominal o falsas alarmas.

C. Mitigación de la Dilución de Responsabilidad y Normalización de Fallos (Dimensión: Rendición de Cuentas)

Para evitar vacíos legales y operativos ante fallos no detectados y prevenir la normalización de incidentes sin un RCA adecuado:

- **Trazabilidad Inmutable (Logs de Inferencia):** Cada decisión tomada por el modelo de IA será almacenada en un registro auditable, indicando la versión del modelo, la hora exacta, el log original analizado y el nivel de confianza de la predicción. Esto garantiza que la responsabilidad del enrutamiento pueda ser trazada históricamente.
- **Circuit Breakers Algorítmicos:** Si el modelo genera un pico anormal de predicciones inciertas (lo que indicaría un patrón de error completamente nuevo que la IA no sabe procesar), un sistema de "corta-circuitos" suspenderá temporalmente la inferencia automatizada, devolviendo el control al equipo SRE y previniendo la normalización de acciones inadecuadas.

D. Mitigación de la Fuga de Información Sensible (Dimensión: Privacidad)

La protección de los datos personales (PII) procesados durante la inferencia se aborda de forma categórica:

- **Privacidad desde el Diseño (Data Masking Determinista):** Implementación de una capa obligatoria de preprocesamiento basada en Expresiones Regulares (Regex). Ninguna traza de log entrará al modelo BERT sin que este componente haya anonimizado previamente todos los *tokens* de pago, identificadores de usuario (user_id), direcciones IP y montos financieros (Mitigación ya incluida en el código).

E. Mitigación de la Degradación Silenciosa y Factores Éticos en Diseño (Dimensión: Ética por Diseño)

Para prevenir la obsolescencia del modelo frente al *Data Drift* y asegurar la ética desde la concepción:

- **Gobernanza MLOps (*Continuous Learning*):** El ciclo de vida del modelo incluirá monitoreo automatizado de la deriva de datos. Si los patrones de los logs cambian debido a actualizaciones de software o nuevos tipos de fraude, el sistema MLOps disparará alertas para programar ciclos de reentrenamiento controlados, garantizando la sostenibilidad a largo plazo.
- **Integración de la Ética en las Fases de Prueba:** Los sets de validación del modelo no solo buscarán la precisión matemática, sino que incluirán intencionalmente casos límite y escenarios de "estrés ético" (ej. logs ambiguos que afecten a usuarios vulnerables) para evaluar cómo la red neuronal maneja la incertidumbre antes de ser desplegada a producción.

2. Workshop: Análisis de stakeholders y sus valores

El ecosistema transaccional y de observabilidad abarca actores que exceden al departamento de TI. A continuación, el mapeo exhaustivo de actores:

2.1. Tabla de Stakeholders Completada

Stakeholders	Tipo	Valor principal	Explicación
Gerente y soporte TI	Directo	Eficiencia Operativa / MTTR	Buscan automatizar el triaje y enrutamiento de incidentes para reducir costos operativos y horas-hombre en análisis manual.
Coordinador de Incidentes	Directo	Precisión / Resiliencia	Requieren alertas altamente confiables (F1-Score alto) para no desperdiciar recursos ni sufrir "fatiga de alertas".
Coordinador de Monitoreo	Directo	Visibilidad / Velocidad	Necesitan integración sin fricción y una latencia de inferencia (SLA < 50ms) que no retrase el pipeline de logs actual.
Líder Técnico de aplicaciones	Directo	Disponibilidad (Uptime)	Su incentivo principal es garantizar que el servicio core opere 24/7, que el RCA (Análisis de causa raíz) sea exacto y que se recupere automáticamente ante disrupciones.
Equipo de desarrollo y analitica	Directo	Reproducibilidad / MLOps	Buscan una deuda técnica baja, gobernanza de datos y capacidad para reentrenar el modelo de forma controlada.
Equipos de seguridad de la información	Directo	Confidencialidad / Compliance	Asegurar que el modelo (IA) no sea un vector de vulnerabilidad ni procese PII o datos financieros en texto claro (PCI-DSS).
Gerente de facturacion, cartera y recaudo	Indirecto	Continuidad Financiera	Interesado en la reducción de transacciones fallidas para garantizar el flujo de caja operativo de la empresa.
Proveedores de aplicaciones y servicios	Indirecto	Interoperabilidad	Interés en que las alertas generadas por AIOps se conecten limpiamente mediante APIs a herramientas ITSM (ServiceNow, Jira).
Entidades bancarias y financieras	Indirecto	Integridad Transaccional	Prevención de disputas, chargebacks o reversiones causadas por timeouts o fallos técnicos prolongados no diagnosticados.
Clientes que pagan sus facturas	Indirecto	Justicia / Transparencia	Desean pagar sin interrupciones ni bloqueos injustificados, garantizando que sus pagos se apliquen a tiempo.

2.2. Identificación de Tensiones Éticas y Posibles Conflictos

La inserción de un modelo predictivo AIOps en el flujo de valor de la pasarela de pagos altera la dinámica de poder y responsabilidad dentro de la organización. A partir del mapeo

de *stakeholders*, se han identificado cuatro tensiones éticas y operativas fundamentales que representan conflictos entre valores corporativos legítimos:

2.2.1. Eficiencia Operativa (MTTR) vs. Transparencia Algorítmica (El Dilema de la Caja Negra)

- **El Conflicto:** El equipo de Soporte TI y Operaciones está incentivado por KPIs de velocidad; buscan que el modelo Transformer enrute el 100% de los incidentes de forma instantánea para reducir el Tiempo Medio de Resolución (MTTR). En contraposición, los equipos de Seguridad de la Información (SecOps) y Cumplimiento Normativo exigen que cada decisión sea explicable.
- **La Tensión Ética:** El afán por la hiper-automatización choca directamente con el principio de Transparencia. En un entorno financiero, si ocurre una caída masiva del canal de recaudo o un bloqueo injustificado a los clientes, la organización no puede justificar ante un regulador o auditor que "la red neuronal lo decidió así". La velocidad operativa no puede lograrse a costa de operar un sistema opaco e inauditable.

2.2.2. Rendimiento del Modelo (Contexto) vs. Privacidad de los Datos (Data Masking)

- **El Conflicto:** Desde la perspectiva del Equipo de Desarrollo y Analítica, mientras más "crudo" y rico sea el texto del log transaccional, mejor será el espacio de *embeddings* (vectores de palabras) generado por BERT, logrando mayor precisión diagnóstica. Sin embargo, SecOps y los marcos regulatorios (*Habeas Data*, PCI-DSS) exigen la mínima exposición de datos, forzando la ofuscación de la información.
- **La Tensión Ética:** Existe un choque entre el *Principio de Beneficencia* (tener el modelo más exacto posible para proteger el servicio) y la *Protección de Derechos Humanos* (la privacidad del cliente). Un enmascaramiento agresivo (Regex) puede causar "colisiones semánticas" (donde el modelo ya no puede distinguir entre un

error 401 y un 403), sacrificando precisión técnica en aras de mantener un estándar ético de confidencialidad.

2.2.3. Automatización Integral vs. Rendición de Cuentas (*Accountability*)

- **El Conflicto:** La gerencia financiera y operativa percibe el modelo AIOps como una herramienta para reducir horas-hombre y minimizar la intervención del nivel 1 de soporte. No obstante, los principios éticos dictan que debe existir un humano responsable (*Accountable*) de las decisiones que afectan a los usuarios finales.
- **La Tensión Ética:** La definición del "umbral de confianza" (la probabilidad *Softmax* mínima para que la IA actúe sola) es el campo de batalla de este conflicto. Si el umbral es muy alto (ej. 95%), el modelo escalará demasiados casos a revisión humana, frustrando el objetivo de negocio de automatizar. Si el umbral es muy bajo (ej. 50%), el sistema cometerá errores que bloquearán injustamente a clientes válidos, diluyendo la responsabilidad legal y ética sobre un algoritmo en lugar de un profesional humano.

2.2.4. Prevención Financiera (Falsos Negativos) vs. Fatiga de Alertas (Falsos Positivos)

- **El Conflicto:** La Gerencia de Facturación y Recaudo tiene tolerancia cero hacia los "Falsos Negativos" (incidentes críticos que la IA ignora y clasifica como tráfico normal), ya que esto significa pérdida directa de dinero. Para complacer esta necesidad, se podría configurar el modelo para ser hipersensible. Sin embargo, esto generará una avalancha de "Falsos Positivos" (alarmas innecesarias).
- **La Tensión Ética:** Se contrapone la *Continuidad Financiera* del negocio frente a la *Calidad de Vida* de los trabajadores (Ingenieros SRE). Configurar un algoritmo paranoico para asegurar el 100% de la recaudación trasladará el costo del sesgo algorítmico directamente a la salud mental de los ingenieros, quienes volverán a sufrir el síndrome de *Burnout* (Fatiga de Alertas) que el proyecto AIOps originalmente prometió erradicar.

3. Workshop: Impacto social y responsabilidad

Como argumenta Mittelstadt (2019), los principios éticos no bastan si no se traducen en acciones garantizadas y auditables; por ello, balanceamos el impacto social del sistema y establecemos compromisos concretos.

3.1. Balance crítico entre impactos positivos y negativos

- **Impacto Positivo:** Democratización de la estabilidad financiera al garantizar canales de pago robustos. Reducción sustancial del estrés laboral (*Burnout*) en los ingenieros de confiabilidad del sitio (SRE) mediante la eliminación del monitoreo manual reactivo.
- **Impacto Negativo:** Incremento de la "brecha de explicabilidad". Al usar redes neuronales profundas para tomar decisiones técnicas, se aliena a los operadores junior que podrían perder su capacidad de análisis crítico (*deskilling*), delegando todo el pensamiento al algoritmo.

3.2. Implicaciones a corto y largo plazo

A corto plazo, el sistema AIOps generará optimización de costos y aceleración en la resolución de caídas del sistema. A largo plazo, el principal riesgo es el exceso de confianza: que los humanos asuman infalibilidad en el sistema y dejen de auditar las métricas base.

3.3. Declaración de Responsabilidad Ética y Criticidad El equipo desarrollador

reconoce que el Modelo Predictivo AIOps opera sobre un entorno de *misión crítica*. Un falso negativo o una clasificación sesgada no solo representa un error técnico, sino una disrupción directa a la liquidez de la empresa y a la economía diaria de los usuarios finales que dependen de las pasarelas de pago. La tecnología debe subordinarse a la supervisión humana, actuando como un copiloto experto (Inteligencia Aumentada) y no como un juez autónomo.

3.4. Compromisos Operativos, Medibles y Claros (Mitigación Ética)

Para garantizar un uso ético y sostenible de la solución, nos comprometemos a:

a. **Compromiso de Privacidad por Diseño (Medible):** El 100% de la telemetría histórica y en tiempo real pasará por un *pipeline* de ofuscación determinista (Regex) que eliminará IPs, tokens de pago y datos de clientes antes de que el texto llegue al modelo de IA.
b. **Compromiso de Equidad Diagnóstica (Operativo):** Realizar auditorías de sesgo trimestrales (Evaluación de *Recall* por clase) para asegurar que la IA no priorice exclusivamente los incidentes de facturación corporativa masiva, ignorando fallos específicos que afectan a minorías de usuarios individuales.
c. **Compromiso de Gobernanza MLOps (Medible):** Implementar un umbral de confianza mínimo (ej. 75% en la salida *Softmax* del modelo). Cualquier incidente cuya predicción esté por debajo de este umbral será etiquetado como "Incierto" y deberá escalar obligatoriamente a un operador SRE, garantizando la rendición de cuentas humana.

Conclusión

La implementación del Modelo Predictivo de Gestión de Incidentes AIOps en el ecosistema crítico de facturación y pasarelas de pago trasciende la mera innovación algorítmica y la búsqueda de eficiencia operativa (reducción del MTTR). Tal como se ha fundamentado a lo largo de este documento, la transición de un monitoreo tradicional reactivo hacia una observabilidad semántica impulsada por aprendizaje profundo impone un mandato ético ineludible frente a la gobernanza corporativa de TI.

A través de este análisis exhaustivo, hemos evidenciado que el despliegue de arquitecturas Transformer en entornos financieros trae consigo desafíos inherentes, tales como el riesgo sistémico de la "caja negra", la colisión semántica en el diagnóstico y la potencial dilución de la responsabilidad técnica. Hemos reconocido que el verdadero reto de la ingeniería moderna no radica únicamente en lograr la convergencia del código, sino en conciliar tensiones éticas legítimas entre los diversos *stakeholders*, equilibrar la necesidad operativa

de hiper-automatización con la exigencia de explicabilidad y auditoría, y balancear la precisión matemática del modelo con la protección inquebrantable de la privacidad de los datos transaccionales (PII).

Por consiguiente, la viabilidad de esta herramienta para su paso a producción no se sustenta exclusivamente en su alta métrica de desempeño algorítmico, sino en la solidez de sus barreras de contención éticas. La adopción de un esquema ético por diseño y de carácter operativo, materializado en el enmascaramiento determinista de datos desde la ingesta, las auditorías periódicas de equidad algorítmica para evitar sesgos entre flujos de recaudo, y la implementación irrestricta de la metodología *Human-in-the-loop* mediante umbrales de confianza, asegura que el control último y la rendición de cuentas permanezcan indelegablemente en manos humanas.

En conclusión, al asumir estos compromisos medibles, el modelo AIOps propuesto deja de ser un simple optimizador de alertas para convertirse en un pilar estratégico de resiliencia empresarial. Se demuestra así empíricamente que la Inteligencia Artificial, en entornos de misión crítica, alcanza su máximo valor cuando opera bajo el paradigma de "Inteligencia Aumentada": una solución tecnológica que no busca reemplazar el juicio crítico del ingeniero SRE, sino empoderarlo, garantizando un servicio financiero que sea continuo, transparente, justo y, sobre todo, éticamente responsable ante la sociedad.

Referencias

Floridi, L., Cowls, J., Beltrametti, M., Chatila, R., Chazerand, P., Dignum, V., Luetge, C., Madelin, R., Pagallo, U., Rossi, F., Schafer, B., Valcke, P., & Vayena, E. (2018). AI4People—An Ethical Framework for a Good AI Society: Opportunities, Risks, Principles, and Recommendations. *Minds and Machines*, 28(4), 689–707. https://doi.org/10.1007/s11023-018-9482-5

Jobin, A., Ienca, M., & Vayena, E. (2019). The global landscape of AI ethics guidelines. *Nature Machine Intelligence*, 1(9), 389–399. https://doi.org/10.1038/s42256-019-0088-2

Mittelstadt, B. (2019). Principles alone cannot guarantee ethical AI. *Nature Machine Intelligence*, 1(11), 501–507. https://doi.org/10.1038/s42256-019-0114-4