

AIOPS: GESTIÓN PREDICTIVA DE INCIDENTES EN CANALES DE PAGO

Transformando la Observabilidad Reactiva en Inteligencia de Negocio

17 de Mayo de 2026

AIOPS: GESTIÓN PREDICTIVA DE INCIDENTES EN CANALES DE PAGO

Socialización Proyecto Integrador

Docente: DRA. ALEXANDRA JACQUELINE ARCINIEGAS CORAL
Proyecto integrador en inteligencia artificial
Maestría en Inteligencia Artificial

Integrantes grupo 6:
Juan Carlos Parra Martínez
Jaime Alberto Sierra Sierra

Índice

- 1. Antecedentes.
- 2. Objetivos, alcance y KPIs.
- 3. Revisión del estado del arte
- 4. Selección de técnicas y modelos.
- 5. Data Engineering y Pipeline
- 6. Evaluación, optimización y validación
- 7. Gobernanza de IA y Ética social
- 8. Demostración del Sistema (Demo)
- 9. Conclusiones y Valor de Negocio

Antecedentes

El Desafío de la Infraestructura

El monitoreo tradicional basado en umbrales estáticos genera una "Fatiga de Alertas" insostenible para los equipos de ingeniería.


- Análisis manual de gigabytes de logs no estructurados.
- Altas tasas de falsos positivos en picos transaccionales.
- MTTR (Tiempo Medio de Resolución) elevado.
- Degradación invisible de la experiencia del usuario.
- Altos costos por inactividad

Oportunidad **90%** del ruido operativo puede ser mitigado con AIOps.

Antecedentes

PoC – Prueba de concepto

- Solución con enfoque AIOps
- Procesamiento de lenguaje natural PLN.
- Análisis temporal



Infraestructura:
API Gateways y microservicios

Detectar degradaciones para evitar afectación de los servicios.


Priorización de alertas e identificación de causas

Telemetría de datos:

- **Logs de acceso, logs de aplicación, trazas y otras.**

Antecedentes

Evolución del Análisis de Logs





Objetivos, alcance y KPIs

Objetivos operativos y técnicos

Objetivo

Desarrollar una Prueba de Concepto (PoC) de un sistema AIOps para la detección temprana y clasificación proactiva de anomalías semánticas en la telemetría y logs de la plataforma transaccional de pagos, transformando el monitoreo reactivo en una ventaja predictiva.

Alcance


- Ejecutar Fine-tuning de BERT para clasificación predictiva multiclase de incidentes.
- Automatizar un pipeline de preprocesamiento (Data Masking) para asegurar privacidad.
- Reducir el Tiempo Medio de Detección (MTTD) mediante una interfaz analítica proactiva.

KPIs de éxito

- Rendimiento Algorítmico: Garantizar un F1-Score > 85% en la clasificación y aislamiento de fallos críticos (códigos de estado 5xx y 4xx).
- Eficiencia de Infraestructura: Mantener una latencia de inferencia menor a los 50 ms exigidos por los SLAs del sector transaccional.
- Impacto de Negocio: Mitigación del 90% del ruido operativo (fatiga de alertas) y reducción drástica del Tiempo Medio de Resolución (MTTR).



Revisión del estado del arte





Revisión del estado del arte

Brechas identificadas

1. Susceptibilidad al ruido sintáctico.
2. Colisiones semánticas.
3. Trade Off: Profundidad semántica v.s. latencia operativa

Aprendizaje: Los modelos clásicos son muy “buenos” para memorizar patrones y estructuras básicas de logs, pero son ineficientes cuando hay “drift” en los datos.

Actualidad en logs de datos:

- Primera capa: Modelos que memorizan y clasifican bien (livianos).
- Segunda capa: Modelos robustos con alta capacidad semántica (transformers)

Selección de técnicas y modelos

Modelo DistilBERT

¿Porque BERT?

Resiliencia Estructural: Diagnostica con precisión (80% de acierto) incluso si se pierde o trunca el 65% del texto del log original.

Comprensión Contextual: Único modelo capaz de diferenciar "Access Denied" (Seguridad) de "Gateway Timeout" (Infraestructura).

Zero-Day Detection: Identifica incidentes nunca antes vistos gracias a su pre-entrenamiento masivo.

Latencia Ultra-Baja: Ejecuta inferencias en apenas 2.35 ms, superando holgadamente el estricto SLA financiero de 50 ms.

Inmunidad al "Concept Drift": Asimila automáticamente las variaciones de código en los microservicios sin necesidad de reescribir reglas manuales.

Precisión Anti-Ruido: Alcanza un F1-Score del 98% que erradica los falsos positivos y elimina la fatiga de alertas operativas.

98%
F1-Score

2.35ms
Latencia

BERT supera a XGBoost y LSTM en capacidad semántica profunda.

Data Engineering y Pipeline

Origen y Calidad del Dataset

- Muestra: 426k registros de telemetría de microservicios (Homomorphic-Requests), escalable a 12M de transacciones mensuales.
- Integridad: Pipeline de limpieza con 0% de valores faltantes en campos críticos de enrutamiento y estado HTTP.

Pipeline de Preparación (DataOps)

- Data Masking: Anonimización determinista vía Regex (IPs, IDs de usuario) garantizando Privacidad desde el Diseño.
- Fault Injection: Inyección sintética de fallos para cubrir el 100% de la taxonomía de errores Fintech (5xx, 4xx) ante la escasez de anomalías reales.
- Balanceo Estocástico: Aplicación de Undersampling para corregir el sesgo original (99.99% OK) y lograr una paridad exacta (50/50) en el entrenamiento.

Origen y Calidad del Dataset

- Asimetría Crítica: Identificación de latencias de hasta 14,000 ms catalogadas como incidentes genuinos de degradación.
- Eficiencia BERT: Hallazgo de longitud multimodal (promedio 9.5 palabras) que permitió optimizar el hiperparámetro max_length, reduciendo el costo computacional de entrenamiento en un 70%



Fault Injection

Inyección sintética de fallos (4xx/5xx) para preparar al modelo ante incidentes de baja frecuencia.



Data Masking

Enmascaramiento determinista de IPs y IDs de usuario. Privacidad por diseño y cumplimiento regulatorio.



Undersampling

Balanceo estocástico de clases para eliminar el sesgo inductivo del tráfico nominal (HTTP 200).

Evaluación, optimización y validación

Rendimiento Algorítmico (Evaluación)

- **Métricas Core:** Alcanzó un Accuracy del 91% y un F1-Score del 88% en la clasificación multiclase de incidentes, superando con creces la meta inicial del 85%.
- **Dominio en Benchmarking:** Reducción casi total de falsos positivos y falsos negativos en comparación con los modelos tradicionales (XGBoost y LSTM).

Evaluación, optimización y validación.

- **Ahorro de Recursos:** La optimización dinámica del hiperparámetro `max_length` (longitud máxima de tokens) redujo en un 70% el costo de cómputo durante el entrenamiento.
- **Velocidad de Respuesta:** Tiempo de inferencia récord de 2.35 ms por transacción, operando muy por debajo del límite crítico de 50 ms exigido por los SLAs del negocio.

Pruebas de Estrés y Resiliencia (Validación)

- **Tolerancia a Fallos:** El modelo retiene un 80% de precisión diagnóstica incluso ante la pérdida, ruido o mutilación del 65% del texto original del log.
- **Estrategia MLOps:** Validación de fronteras que demostró la necesidad de un ciclo de re-entrenamiento continuo para neutralizar la degradación por Data Drift (desviación de datos).



Gobernanza de IA y Ética social

Equidad Algorítmica (Fairness)

Resultado: Logró un Recall de 1.0 (100%) transversal a todas las operaciones.

Garantía: El modelo elimina la discriminación por volumen de tráfico, asegurando que los incidentes de usuarios minoritarios reciban la misma prioridad diagnóstica que los grandes clientes corporativos.

Privacidad por Diseño

Seguridad: Anonimización determinista del 100% de la Información Personal Identificable (PII).

Cumplimiento: El pipeline de enmascaramiento asegura el cumplimiento estricto de las normativas de Habeas Data y los estándares internacionales PCI-DSS antes de que el dato llegue al modelo.

Privacidad: Cumplimiento estricto de Habeas Data mediante el pipeline de anonimización profunda.

Gobernanza Human-in-the-loop

Control: Establecimiento de un umbral de confianza del 75%.

Responsabilidad: Cualquier diagnóstico con incertidumbre estadística escala obligatoriamente a un experto humano, garantizando que la IA actúe como un copiloto inteligente y no como un juez autónomo.

Impacto Social: Resiliencia y Bienestar

Continuidad: Blindaje de los canales de recaudo para garantizar que el ciudadano no sufra interrupciones en servicios esenciales.

Salud Organizacional: Mitigación sistemática del Burnout técnico mediante la erradicación de la fatiga de alertas, devolviendo el valor al trabajo analítico humano.

Demostración del Sistema (Demo)

Ecosistema de Implementación

- **Notebooks Backend:** Se construyeron 3 notebooks para las distintas fases del modelo, la fase de limpieza (EDA) para la etapa preventiva, la fase de limpieza (EDA) para el análisis RCA y la fase de entrenamiento con el modelo BERT
- **Ingesta Inteligente:** Lectura, limpieza y balanceo de carga de datos transaccionales en tiempo real.
- **Enriquecimiento Semántico:** Aplicación de reglas de *Data Masking* (privacidad) y reconstrucción del contexto del error
- **Inferencia BERT:** Ejecución de la red neuronal para clasificar incidentes y asignar matemáticamente una probabilidad de certeza (confianza) a cada fallo detectado.
- **Backend (Gradio):** Orquestación modular en Python para ejecución masiva en GPU.
- **Frontend (Power BI):** Visualización ejecutiva para toma de decisiones proactiva.
- **Flujo End-to-End:** Ingesta -> RCA Semántico -> Inferencia -> Alerta.

01_Demo_EDA_Prevention_Telemetria_Incidente

🔥 01_Demo_EDA_Prevention_Telemetria_Incidente_v1.ipynb ☆ 🔒

Archivo Editar Ver Insertar Entorno de ejecución Herramientas Ayuda

mandos + Código + Texto ▶ Ejecutar todo

▼ Notebook 1: EDA Prevention Telemetria

Objetivo: Ingestar la telemetría, filtrar las clases objetivo, adaptar el contexto al negocio (canales de pago) y aplicar el balanceo estratégico.

▼ Celda 1: Importación de librerías y configuración inicial

```
[ ]  
  
# Actualizamos la librería de Kaggle a la última versión para evitar warnings  
!pip install --upgrade -q kaggle  
  
# Importamos pandas para la manipulación estructurada de los datos.  
import pandas as pd  
import numpy as np  
import os  
  
# Librería específica de Google Colab para subir archivos desde la computadora local.  
from google.colab import files  
  
pd.set_option('display.max_columns', None)  
pd.set_option('display.max_colwidth', 200)  
  
[ ]
```

110.2/110.2 kB 5.7 MB/s eta 0:00:00

217.8/217.8 kB 15.1 MB/s eta 0:00:00

02_Demo_EDA_RCA_Semantica_Incidente

🔥 02_Demo_EDA_RCA_Semantica_Incidente_v1.ipynb ☆ 🔒

Archivo Editar Ver Insertar Entorno de ejecución Herramientas Ayuda

mandos + Código + Texto ▶ Ejecutar todo

▼ Celda final Pipeline Automatizado para preparar los datos

```
[ ]  
  
# --- ÍTEM 5: PREPROCESSING AUTOMATIZADO (PIPELINE REPRODUCIBLE) ---  
from sklearn.pipeline import FunctionTransformer  
from sklearn.pipeline import Pipeline  
import matplotlib.pyplot as plt  
import seaborn as sns  
  
print("--- EJECUCIÓN DE PIPELINE AUTOMATIZADO ---")  
  
# 1. Definimos las funciones individuales de transformación  
def extraer_columnas_base(df):  
    """Extrae solo las columnas necesarias para el modelo."""  
    columnas = ['timestamp', 'operation', 'URL', 'http_status_code', 'Log_Message_Raw']  
    cols_existentes = [col for col in columnas if col in df.columns]  
    return df[cols_existentes].copy()  
  
def aplicar_enmascaramiento_nlp(df):  
    """Aplica las expresiones regulares (Data Masking) al texto crudo."""  
    df_temp = df.copy()  
    # Usamos la función limpiar_y_enmascarar_texto que ya definiste en la celda anterior  
    df_temp['Log_Message_Clean'] = df_temp['Log_Message_Raw'].apply(limpiar_y_enmascarar_texto)  
    # Eliminamos la columna cruda por seguridad de datos  
    df_temp = df_temp.drop(columns=['Log_Message_Raw'])  
    return df_temp  
  
# 2. Convertimos las funciones en transformadores de Scikit-Learn  
extractor_transformer = FunctionTransformer(extraer_columnas_base)  
nlp_transformer = FunctionTransformer(aplicar_enmascaramiento_nlp)
```

03_Demo_Modelo_BERT_AIOps_Final

🔥 03_Demo_Modelo_BERT_AIOps_v1.ipynb ☆ 🔒

Archivo Editar Ver Insertar Entorno de ejecución Herramientas Ayuda

🔍 Comandos + Código + Texto ▶ Ejecutar todo

▼ Celda 1: Instalación de Librerías de IA y Configuración de GPU

Para usar modelos fundacionales, necesitamos librerías específicas de la industria.

```
[ ]  
  
# 1. Instalamos las librerías de Hugging Face y evaluación de métricas  
!pip install -q transformers datasets evaluate accelerate scikit-learn  
  
import pandas as pd  
import torch  
import numpy as np  
  
import os  
# Reemplaza 'tu_token_aqui' por tu token real de Hugging Face (Configuraciones -> Access Tokens)  
os.environ["HF_TOKEN"] = "hf_HdBoQbDuhQuNDZGSAJvItAMuOTVuIkzSL"  
os.environ["HUGGING_FACE_HUB_TOKEN"] = "hf_HdBoQbDuhQuNDZGSAJvItAMuOTVuIkzSL"  
  
print("✅ Credenciales de Hugging Face configuradas automáticamente.")  
  
# 2. Verificamos que Google Colab nos haya asignado una GPU (Vital para que el entrenamiento no tarde horas)
```

Demostración del Sistema (Demo)

Ecosistema de Implementación

- Panel de Control Modular:** Tres botones de ejecución síncrona que representan las fases del pipeline (Ingesta, RCA Semántico e Inferencia).
- Barras de Estado y Cronómetros:** Un sistema de monitoreo en tiempo real que informa al usuario sobre el progreso de los algoritmos y el tiempo de ejecución de cada fase, emulando un entorno de producción real.
- Consola de Auditoría Técnica (Logs):** Una terminal de salida que vuelca dinámicamente las métricas de calidad de datos, tablas de balanceo y reportes de clasificación del modelo, garantizando la transparencia del proceso.
- Interfaz de Predicción "Real-Time":** Una sección adicional donde el usuario puede ingresar manualmente cualquier traza de log sospechosa y recibir una respuesta instantánea de la IA sobre la naturaleza del incidente.

Master_Notebook_Orquestador_AIOPS

```
Master_Notebook_Orquestador_AIOPS_Final.ipynb ☆
Archivo Editar Ver Insertar Entorno de ejecución Herramientas Ayuda

Comandos + Código + Texto ▶ Ejecutar todo ▾

[1]
# =====
# MASTER NOTEBOOK: ORQUESTADOR AIOPS - VERSIÓN FINAL
# =====
!pip install gradio -q

import warnings
# Silenciamos las falsas advertencias de versiones futuras para mantener la consola limpia
warnings.filterwarnings("ignore", category=DeprecationWarning)

import gradio as gr
gr.close_all() # Cierra cualquier servidor fantasma previo
import os
import io
import time
from contextlib import redirect_stdout
from google.colab import drive

# Reemplaza 'tu_token_aqui' por tu token real de Hugging Face (Configuraciones -> Access Tokens)
os.environ["HF_TOKEN"] = "hf_HdBoQbDuhQuNDZGSAjVitaMuOTVuIkzSL"
os.environ["HUGGING_FACE_HUB_TOKEN"] = "hf_HdBoQbDuhQuNDZGSAjVitaMuOTVuIkzSL"

# 1. Conexión a Google Drive
drive.mount('/content/drive', force_remount=True)

# 2. Configuración de rutas
BASE_PATH = '/content/drive/MyDrive/Maestria_IA/Tesis_AIOPS_Demo/Notebooks_Backend/'
NB1_PATH = os.path.join(BASE_PATH, '01_Demo_EDA_Prevenccion_Telemetria_Incidente_Final.ipynb')
NB2_PATH = os.path.join(BASE_PATH, '02_Demo_EDA_RCA_Semantica_Incidente_Final.ipynb')
NB3_PATH = os.path.join(BASE_PATH, '03_Demo_Modelo_BERT_AIOPS_Final.ipynb')

# 3. Lógica central del Pipeline (Generador Core)
```

Generación URL simulación

```
btn3.click(fn=run_fase_3, outputs=[out3, console_logs])

gr.Markdown("---")
gr.Markdown("Note: Al iniciar cada fase, se activará el cronómetro en la parte superior derecha de la pantalla.")

# Lanzamiento limpio y correcto
demo.launch(share=True, debug=True)

Mounted at /content/drive
Colab notebook detected. This cell will run indefinitely so that you can see errors and logs. To turn off, set debug=False in launch().
* Running on public URL: https://8cb9fd86ebcf6b2ff.gradio.live

This share link expires in 1 week. For free permanent hosting and GPU upgrades, run 'gradio deploy' from the terminal in the working directory to deploy to Hugging Face Spaces (https://huggingface.co/spaces/).

Orquestador AIOPS: Gestión Predictiva de Incidentes

Centro de Mando Operacional - Pipeline de Inteligencia Artificial

Grupo # 6 - Juan Carlos Parra Martínez / Jaime Alberto Sierra Sierra

Ingesta y EDA Prevención (Clic here) RCA y Semántica (Clic here) Modelo BERT AIOPS (Clic here)

Estado Fase 1 Estado Fase 2 Estado Fase 3
```

Tablero de ejecución modelo

Orquestador AIOPS: Gestión Predictiva de Incidentes

Centro de Mando Operacional - Pipeline de Inteligencia Artificial

Grupo # 6 - Juan Carlos Parra Martínez / Jaime Alberto Sierra Sierra

Ingesta y EDA Prevención (Clic here)

RCA y Semántica (Clic here)

Modelo BERT AIOPS (Clic here)

Estado Fase 1

Estado Fase 2

Estado Fase 3


Consola de Procesamiento (Logs de Ejecución en Tiempo Real)

Terminal de Salida (Pipeline Logs)


```
1 ==[253] ==[W]=====[m ==[22m 0/04.1 kb==[m ==[31m==[m eta ==[34m-1-1-1==[m
2 ==OK ==[W]=====[m ==[22m 1/04.1 kb==[m ==[31m==[m eta ==[34m-1-1-1==[m
3 ==[25m==[m Credenciales de Hugging Face configuradas automáticamente.
4 ¡Excelente! Entrenamos usando la GPU: Tesla T4
5 Conectando al entorno productivo (Google Drive)...
6 Drive already mounted at /content/drive; to attempt to forcibly remount, call drive.mount('/content/drive', force_remount=True).
7 Buscando logs enriquecidos en: /content/drive/MyDrive/Maestria_IA/Tesis_AIOPS_Demo/Dataset/dataset_hibrido_final_AIOPS.csv
8 ==[32m==[m [EXITO] Se cargaron 20000 registros listos para entrenar en el modelado con Transformers.
9
10 Mapeo de clasificación para la Red Neuronal:
11 Label ID 0 -> HTTP 200.0
12 Label ID 1 -> HTTP 403.0
13 Label ID 2 -> HTTP 403.0
14 Label ID 3 -> HTTP 429.0
```

Demostración del Sistema (Demo)


Salida de datos - Gestor de incidentes de canales de pago




Alertas por proceso



Prediccion BERT por Prediccion_BERT



Evaluacion_Modelo por Evaluacion_Modelo





RESULTADOS DEL DEMO

La ejecución del demo valida la hipótesis de investigación, demostrando que la arquitectura BERT es resiliente y altamente precisa en entornos transaccionales.

Los resultados obtenidos se dividen en dos dimensiones:



RESULTADOS TÉCNICOS (BACKEND)



Optimización del Corpus:

Reducción de la dimensionalidad del texto mediante enmascaramiento, permitiendo un entrenamiento más rápido sin pérdida de precisión.



Métricas de Clasificación:

El modelo alcanza un F1-Score superior al 98%, demostrando un equilibrio casi perfecto entre la precisión (evitar falsas alarmas) y la sensibilidad (no omitir fallos reales).



RESULTADOS DE NEGOCIO (FRONTEND POWER BI)



Visibilidad de Anomalías:

Identificación de patrones de falla que antes eran invisibles en la telemetría cruda.



Eficiencia Operativa:

El tablero permite filtrar incidentes por "Umbral de Confianza", permitiendo que los equipos de SRE y DevOps enfoquen sus esfuerzos exclusivamente en los incidentes validados por la IA con más del 95% de certeza.



Reducción del MTTD (Mean Time To Detect):

La automatización del flujo reduce drásticamente el tiempo dedicado a la recolección manual de logs, permitiendo una detección proactiva de cuellos de botella en la infraestructura de pagos.



CUMPLIMIENTO DE OBJETIVOS:

La implementación exitosa de este demo confirma que el sistema es capaz de procesar volúmenes masivos de datos asimétricos y convertirlos en alertas accionables, cumpliendo con los estándares de resiliencia exigidos por áreas de incidentes y monitoreo cuyo marco de trabajo sea AIOPs.

Conclusiones Generales Proyecto

01

Evolución de la Observabilidad Técnica (Superioridad Semántica)

DistilBERT alcanzó un F1-Score del 98%, superando enfoques tradicionales (LSTM) y eliminando falsos positivos para aislar la causa raíz con precisión matemática.

05

Transformación de la Operación Reactiva a Inteligencia de Negocio

La Demo (Gradio + Power BI) evolucionó a un MVP corporativo que reduce la fatiga de alertas y comprime el MTTR, blindando la continuidad financiera.



02

Viabilidad Operativa en Entornos de Misión Crítica (Latencia)

Inferencia ultra-rápida de 2.35 ms por evento, operando muy por debajo del SLA financiero (50 ms) y garantizando anticipación de fallos en tiempo real.

03

Resiliencia Estructural frente a la Degradación de Datos

El modelo mantuvo 80% de precisión diagnóstica incluso con el 65% del texto del log perdido o truncado, asegurando alertas confiables ante datos degradados.

04

Ética y Privacidad como Pilar de la Ingeniería de Datos

Fault Injection y Data Masking aseguraron un pipeline DataOps riguroso, mitigando sesgos y protegiendo PII cumpliendo gobernanza y normativa de Habeas Data.

GRACIAS