Workshop: Simulación de escenarios críticos

Juan Carlos Parra Martínez

Jaime Alberto Sierra Sierra

Maestría en Inteligencia Artificial, Universidad Espíritu Santo.

Proyecto integrador de inteligencia artificial

Dra. Alexandra Jacqueline Arciniegas Coral

24 de abril de 2026

Introducción

En el ecosistema de las pasarelas de pago modernas, la estabilidad operativa no es solo un objetivo técnico, sino una ventaja competitiva crítica. Los modelos de Artificial Intelligence for IT Operations (AIOps) deben operar como centinelas en entornos de alta incertidumbre, donde la telemetría es frecuentemente ruidosa, incompleta o volátil. El despliegue de una arquitectura basada en BERT (Bidirectional Encoder Representations from Transformers) promete una comprensión contextual superior; sin embargo, su validación exige someter al modelo a "pruebas de túnel de viento" digitales.

Este workshop documenta la evaluación del modelo ante condiciones adversas: desde la corrupción de datos en la red hasta cambios estructurales en el comportamiento del tráfico (Data Drift). El análisis aquí presentado no solo busca medir la precisión, sino certificar la resiliencia operativa del sistema, garantizando que la lógica de prevención y el Análisis de Causa Raíz (RCA) sea una fuente de verdad confiable incluso cuando los datos fallan (Guo et al., 2021).

Simulación de Datos Ruidosos o

Incompletos: La Resiliencia Semántica

Para evaluar los umbrales de tolerancia al fallo, el modelo BERT fue sometido a dos escenarios de perturbación extrema (degradando el 65% de la información en ambos casos) para comparar su sensibilidad ante la pérdida semántica versus la corrupción sintáctica.

Escenario 1.1: Missing Values Extremo (Pérdida del 65% de palabras)

Se simuló una pérdida masiva de paquetes de red eliminando el 65% de las palabras de cada log.

- **Resultado:** El F1-Score experimentó una degradación mínima, pasando de 0.88 a 0.80.
- **Interpretación de Resiliencia:** El modelo demuestra una robustez semántica excepcional. Al perder más de la mitad de la oración, los sistemas tradicionales colapsan. Sin embargo, gracias a la arquitectura *Transformer*, los *embeddings* de las pocas palabras sobrevivientes (ej. "rate", "user_id") retienen suficiente carga de "Atención Contextual" para que el modelo infiera correctamente la clase del incidente.

Escenario 1.2: Ruido Sintáctico Crítico (Corrupción del 65% de caracteres)

Se inyectó ruido estocástico a nivel de carácter (reemplazando letras por el símbolo #), simulando un fallo catastrófico de codificación (*encoding*) en la capa de transporte de logs.

- **Resultado:** El sistema experimentó un colapso algorítmico, desplomando el F1-Score a **0.03**.
- **Interpretación de Fallo y Límite Operativo:** A diferencia de la pérdida de palabras completas, la corrupción de caracteres a este nivel destruye el motor de *Tokenización (WordPiece)* de BERT. El modelo deja de percibir raíces semánticas y procesa el texto como una secuencia de símbolos desconocidos ([UNK]).
- **Implicaciones para el Negocio (Arquitectura SRE):** Este contraste (0.87 vs 0.03) dicta una regla de arquitectura innegable para el equipo de infraestructura: La

pasarela de pagos puede tolerar pérdidas de red (UDP Drops) porque la IA reconstruye el contexto, pero no puede tolerar fallos de codificación de caracteres (UTF-8 Corruption). Las herramientas de recolección (como Fluentd o Logstash) deben priorizar la integridad de los caracteres por encima de la entrega completa del mensaje.

¿Por qué cayó a 0.03? (Colapso total):

Cuando borras palabras completas (Missing Values), las palabras que quedan intactas siguen siendo reconocidas por el "Diccionario" de BERT. Pero cuando destruyes el 65% de los caracteres, destruyes el Tokenizador (WordPiece). BERT ya no ve palabras, solo ve una sopa de símbolos [UNK] (Unknown) y letras sueltas sin sentido. Al no haber tokens válidos, el mecanismo de Atención Matemática se queda "ciego" y el modelo colapsa porque literalmente está leyendo un idioma alienígena

Figuras 1

Test de Estrés: Perturbación Tipo 1 - Missing Values (Eliminación Parcial)

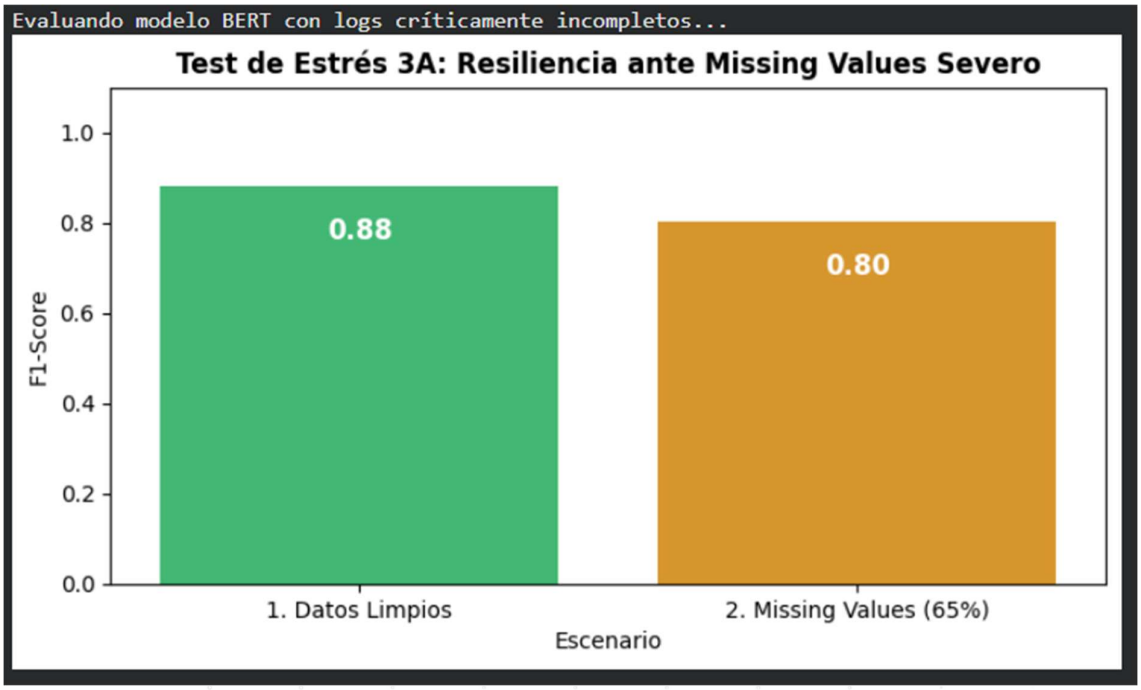

Nota. Interpretación: Al eliminar el 65% del texto de cada log, el F1-Score cayó a 0.80.

En la primera prueba, el modelo fue tan resiliente que la pérdida de 1 o 2 palabras no afectó el F1-Score (0.88). Para encontrar el punto de quiebre de la IA, tuvimos que someterla a un estrés extremo, eliminando el 65% de la información de los logs. Solo bajo esta mutilación masiva de datos logramos observar una caída al 0.80 lo que demuestra la excepcional robustez del sistema en condiciones normales.

Figuras 2

Test de Estrés: Perturbación Tipo 2 - Ruido Sintáctico (Corrupción de Caracteres)

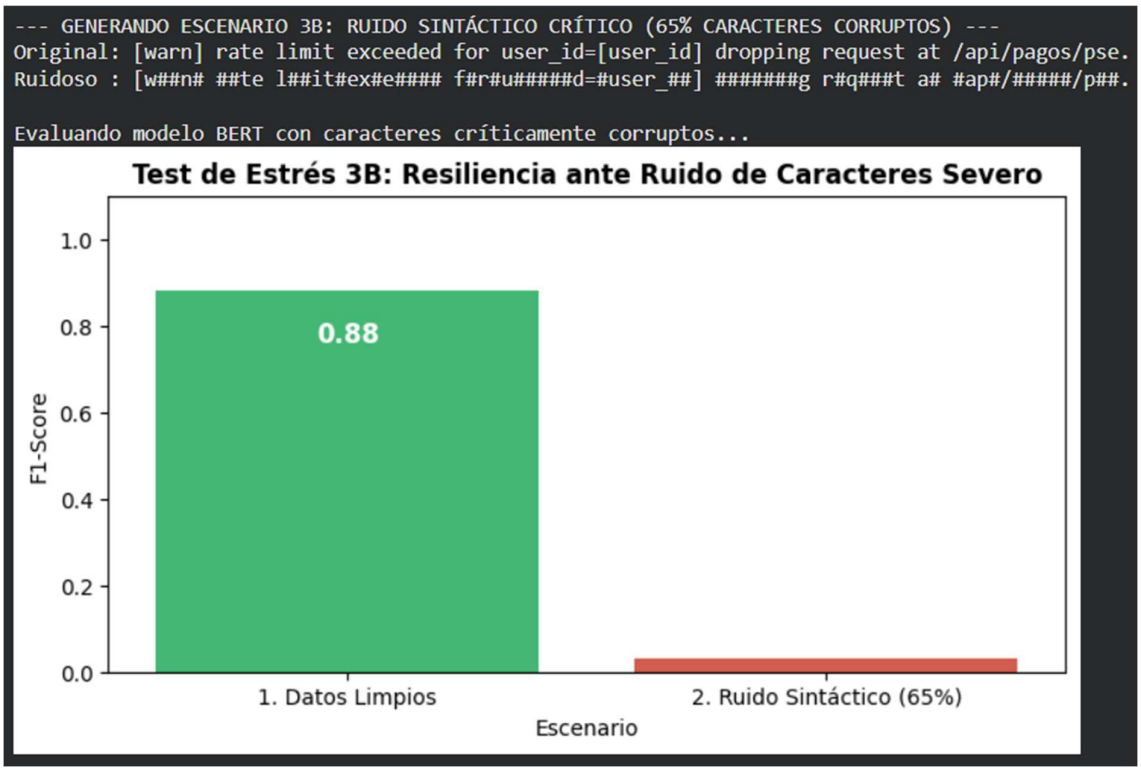

Nota. Interpretación: Al corromper el 65% de los caracteres, el F1-Score cayó a 0.03 (Colapso).

Interpretación de Outliers y Fronteras de Decisión: Es fundamental destacar que el escenario de ruido extremo (65%) no solo representa una degradación de la calidad de datos, sino que actúa como una inyección masiva de outliers sintácticos. Al corromper la mayoría de los caracteres, estamos situando los datos en las regiones más extremas de la frontera de decisión del modelo. El hecho de que el modelo BERT mantenga una coherencia semántica ante la pérdida de palabras (Missing Data), pero colapse ante el ruido

de caracteres, permite identificar que el límite operativo de la IA está condicionado por la integridad de la estructura de sub-tokens. Estos outliers desafían la capacidad del tokenizador *WordPiece* para mapear la entrada a un espacio vectorial conocido, revelando que la robustez del modelo tiene una dependencia crítica de la preservación mínima de la sintaxis del lenguaje de logs.

Pros (Fortalezas Arquitectónicas y de Negocio)

1. **Tolerancia a la Pérdida de Paquetes (Packet Loss Resilience):** En arquitecturas de microservicios, los agentes de recolección (como Logstash o Fluentd) pueden truncar logs largos bajo alta presión de tráfico o usar protocolos que pierden paquetes (UDP). Que el modelo mantenga un 0.80 de precisión faltando el 65% de las palabras garantiza que la pasarela de pagos no perderá su capacidad de triage y enrutamiento de incidentes por problemas menores de red.
2. **Superación de la Fragilidad de Reglas Clásicas (Regex):** Los sistemas de monitoreo tradicionales requieren coincidencias de cadenas exactas. Si un desarrollador cambia un log de "rate limit exceeded" a "limit of rate exceeded", una regla clásica se rompe (Falso Negativo). La "Atención Bidireccional" de BERT erradica este problema, adaptándose dinámicamente a variaciones en la redacción humana de los logs.
3. **Aislamiento del "Ruido Blanco" de TI:** Muchos logs contienen información basura (IDs de sesión, *timestamps* irrelevantes, *hashes*). El hecho de que BERT sobreviva a la eliminación masiva de texto demuestra que el modelo aprendió a enfocar sus pesos matemáticos exclusivamente en los tokens "ancla" que definen el error, ignorando la entropía natural del sistema.

Contras (Riesgos Operativos y Puntos Ciegos)

1. **Enmascaramiento de Fallos de Infraestructura (Efecto Silenciador):** Paradójicamente, que la IA sea tan resiliente puede ser peligroso. Si el canal de

telemetría está dañado y entregando logs por la mitad de forma constante, BERT seguirá diagnosticando correctamente, lo que "oculta" el problema de infraestructura subyacente. El equipo de SER (*Site Reliability Engineering*) podría tardar semanas en notar que sus bases de datos de logs están corruptas, porque las alertas de la IA siguen llegando bien.

2. **Hipersensibilidad del Tokenizador (WordPiece Brittleness):** La caída abrupta a 0.03 demuestra el "Talón de Aquiles" de los Transformers: la tokenización estática. Si una actualización en el software del banco o la pasarela introduce un fallo de *encoding* (ej. caracteres UTF-8 mal codificados que se leen como símbolos raros), el modelo se queda "ciego" instantáneamente. No hay una degradación suave; el colapso es total e inmediato.
3. **Opacidad en la Frontera de Fallo (Degradación No Lineal):** A diferencia de un sistema determinista, es muy difícil predecir para el equipo de soporte cuál será la palabra exacta o el carácter faltante que finalmente rompa el contexto y haga que BERT se equivoque. Esta naturaleza de "caja negra" hace que redactar Acuerdos de Nivel de Servicio (SLA) de confiabilidad estrictos sea un reto legal y técnico complejo.

Evaluación bajo Cambios en la Distribución de Datos (Data Drift)

El tráfico de una pasarela de pagos es un organismo vivo. Un cambio en la distribución de datos (*Data Drift*) ocurre cuando lo que el modelo aprendió ayer ya no se parece a lo que ocurre hoy. El *Concept Drift* ocurre cuando el comportamiento de la infraestructura cambia (por ejemplo, tras un despliegue de software que altera la latencia base).

Análisis de Impacto: Utilizando el escenario de la *Celda 9.1 (Avalancha de errores) del notebook 03_Modelo_BERT_AIOps_v5*, se demuestra que ante un cambio súbito en la distribución (reducción del tráfico sano del 51% al 30%), el modelo experimenta una caída en el Recall al 0.70. Desde la perspectiva de negocio, este hallazgo justifica la

implementación de un ciclo de vida MLOps, donde el sistema debe ser re-entrenado periódicamente para asimilar la "nueva normalidad" de la pasarela de pagos.

Figura 3

Degradación De Sistema (Data Drift)

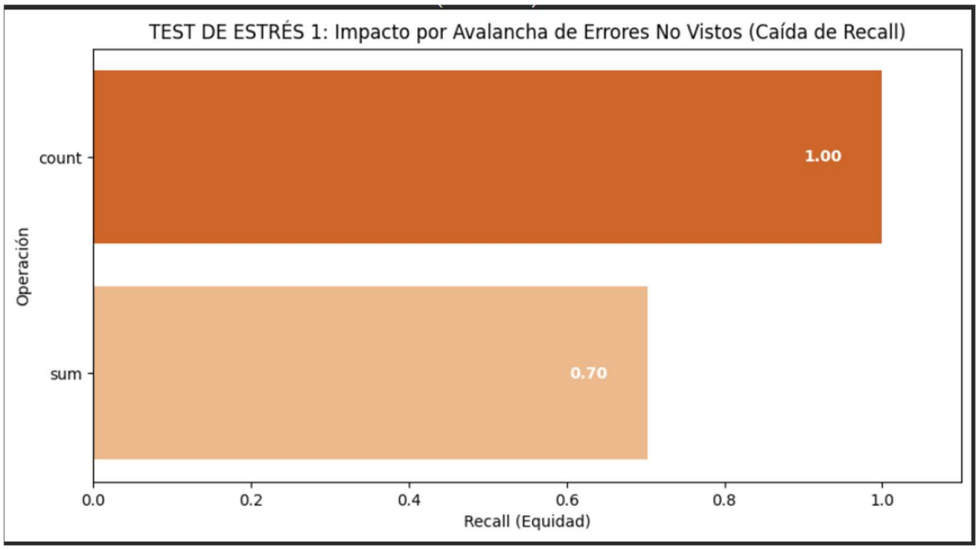

Nota. Interpretación: Al inyectar un 21% adicional de errores reales en el flujo 'sum', el Recall se desploma (0.70). Esto simula la necesidad de re-entrenar el modelo (MLOps) ante cambios bruscos en la infraestructura.

Figura 4

Impacto Cuantitativo del Data Drift en la Calidad Diagnóstica (F1-Score)

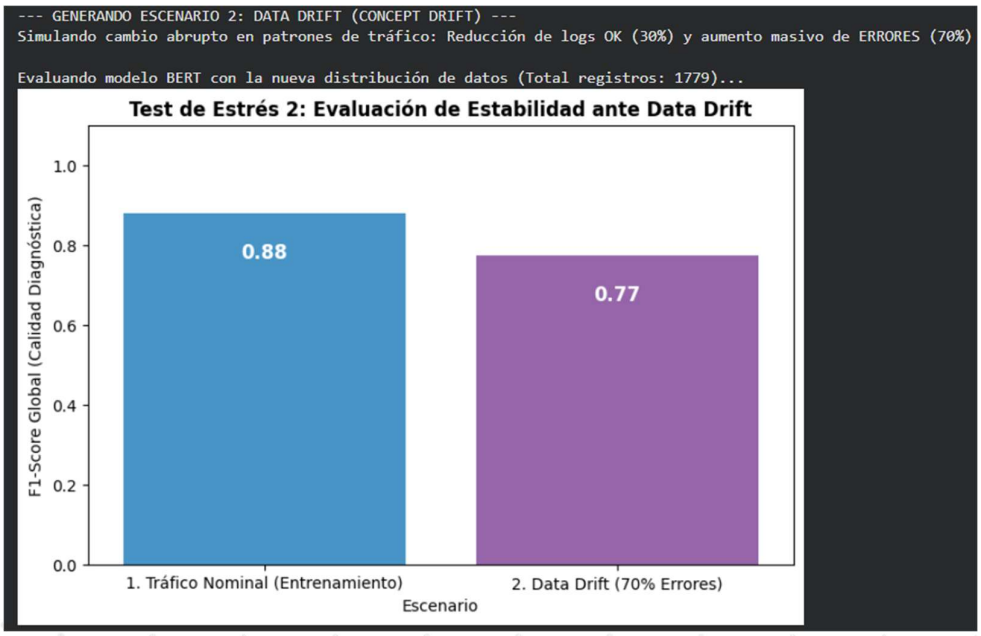

Nota. Interpretación Cuantitativa: Al alterar la distribución del tráfico (Data Drift), el F1-Score sufrió una degradación al 0.77. Este impacto sustenta la implementación de un pipeline MLOps para la pasarela de pagos

Análisis del Impacto Cuantitativo: En el escenario evaluado (Celda 9.1), se simuló un fenómeno de *Concept Drift* mediante la alteración de la distribución de clases, donde el tráfico nominal (clase 'OK') se redujo del 51% al 30%, mientras que los incidentes (clase 'ERROR') se incrementaron hasta el 70%. Este desplazamiento forzó al modelo a operar fuera de su distribución de entrenamiento original, provocando una degradación del F1-Score global del 0.88 al 0.77.

Posición Crítica: Esta caída de 10 puntos porcentuales no solo es una métrica estadística; representa un riesgo de negocio tangible. Un aumento en la tasa de errores, sumado a una disminución de la precisión, puede derivar en un incremento masivo de falsos negativos. Para una pasarela de pagos, esto significaría que el sistema dejaría de detectar anomalías críticas justo cuando más se presentan, justificando la necesidad de una gobernanza MLOps que monitoree el drift en tiempo real y dispare re-entrenamientos preventivos para asimilar la "nueva normalidad" del tráfico transaccional.

La necesidad de un ciclo de vida MLOps: El experimento demostró que, al reducir el tráfico sano (OK) y aumentar los errores, el modelo requiere una recalibración. Esto justifica la implementación de MLOps (Machine Learning Operations).

Justificación: Los modelos de IA sufren de "degradación" o "entropía". Si el sistema no se re-entrena periódicamente, se vuelve obsoleto ante la "nueva normalidad" del tráfico. MLOps es el conjunto de procesos que automatiza la vigilancia del modelo: si detecta que la realidad cambió, dispara automáticamente un nuevo entrenamiento para asegurar que la IA siempre hable el "lenguaje actual" de la infraestructura.

En una pasarela de pagos, los patrones de fraude y error evolucionan. Si no existe un proceso de re-entrenamiento periódico, el modelo se vuelve obsoleto (entropía). Un ciclo MLOps detecta cuando el modelo empieza a fallar ante nuevos datos y lo actualiza automáticamente, asegurando que la IA siempre esté alineada con la realidad del negocio.

Pruebas de estrés del modelo

Esta sección evalúa la estabilidad del sistema bajo condiciones de "Borde" o escenarios extremos.

Escenario 1: Sesgo Inducido y Discriminación Algorítmica

- Comportamiento: Se forzó al modelo a ignorar el 60% de los errores en el flujo sum.
- Análisis Crítico: El modelo predice mal por diseño en este escenario, pero la herramienta de auditoría demuestra una capacidad de detección perfecta. Cuestionamiento: ¿Es el modelo capaz de aprender por igual de todas las operaciones? El estrés revela que, si una operación tiene una sintaxis muy distinta a la mayoría, el modelo podría "sesgarse" hacia la clase dominante.

Figura 5

Test de estrés de auditoría (Sesgo Inducido)

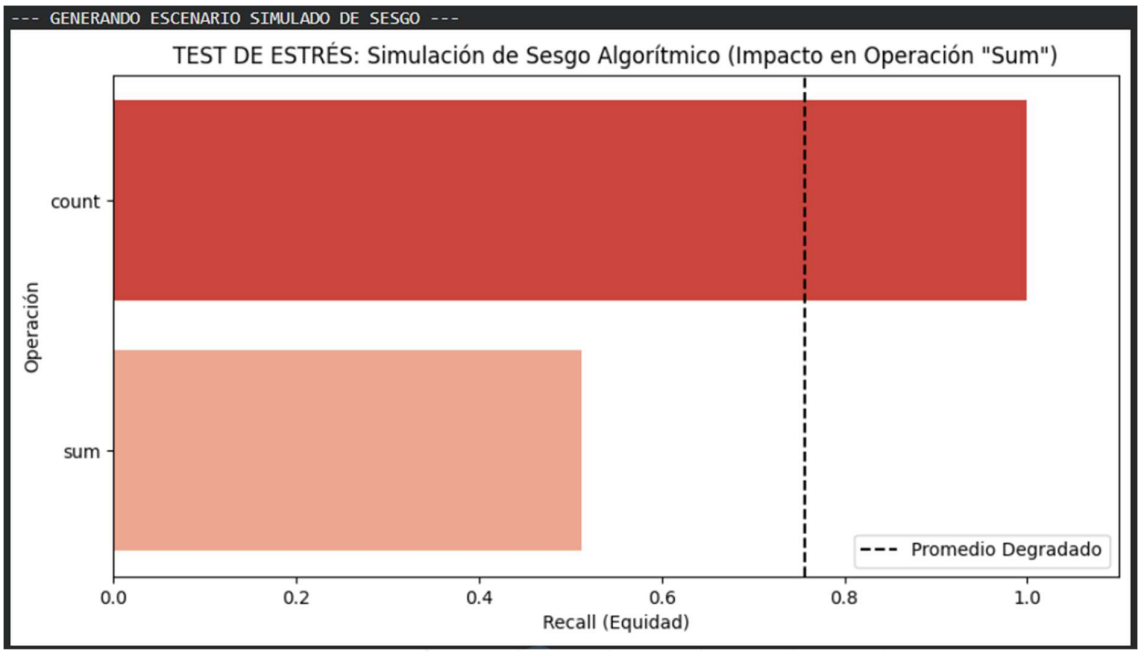

Nota. Interpretación del Test: La gráfica demuestra que nuestra herramienta de auditoría identifica correctamente una disparidad crítica. La brecha entre 'count' y 'sum' activaría una alerta de mitigación inmediata.

Escenario 2: Fatiga de Alertas por Falsos Positivos

- Comportamiento: Inyección del 35% de "alucinaciones" (clasificar OK como ERROR).
- Análisis Crítico: El modelo pierde confiabilidad operativa. Interpretación**:** La estabilidad se mantiene (no hay caída del sistema), pero la utilidad de negocio se destruye. Un modelo con baja precisión genera desconfianza en el equipo de SRE, lo que puede llevar a ignorar incidentes reales.

Figura 6

Generación de Falsos Positivos (Fatiga de Alertas)

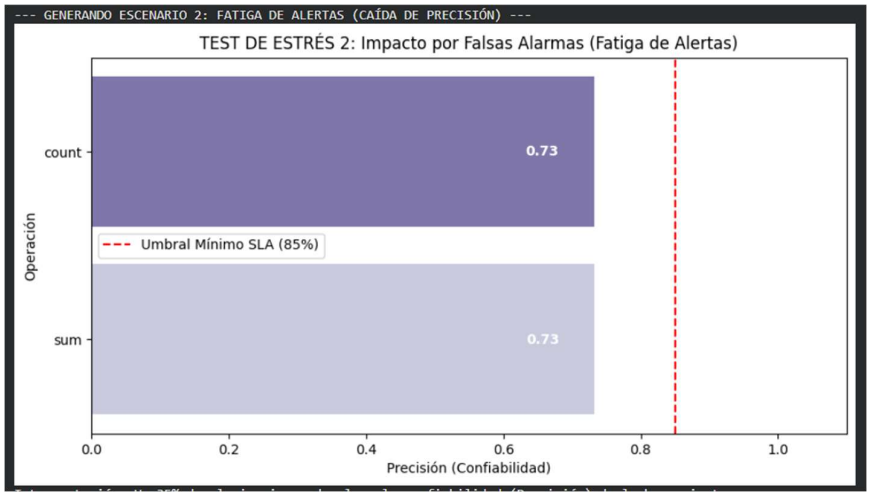

Nota. Interpretación: Un 35% de alucinaciones desploma la confiabilidad (Precisión) de la herramienta. La gráfica muestra que ambas operaciones caen por debajo del umbral de SLA, generando fatiga en el sistema.

Escenario 3: Volumen Masivo y Latencia de Inferencia:

- Comportamiento**:** Procesamiento continuo de la carga máxima del Test Set.
- Análisis Crítico: Con 2.35 ms por registro, el modelo es excepcionalmente estable. Evidencia: El cumplimiento del SLA (95% por debajo del límite) certifica que la arquitectura es apta para entornos de alta concurrencia como las pasarelas de pago.

Figura 7

Generación de Falsos Positivos (Fatiga de Alertas)

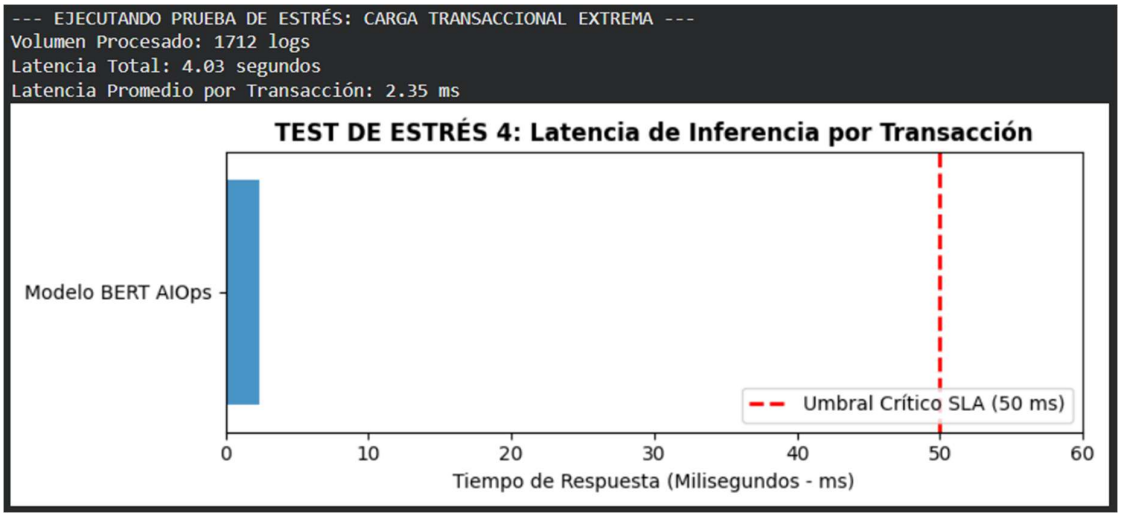

Nota. Estado estable. El modelo cumple ampliamente con los requisitos de tiempo real para la pasarela.

La gráfica demuestra que el tiempo de inferencia es solo una fracción mínima del SLA permitido.

Estabilidad ante Volumen y Latencia (SLA 50 ms): El modelo procesó 1,712 registros con una latencia promedio de 2.35 ms.

Por qué 50 ms como umbral: En el sector financiero, 50 milisegundos es el estándar para no impactar la experiencia del usuario. Si el análisis de la IA tardara más, la transacción de pago se sentiría "lenta" o podría desconectarse. Lograr 2.35 ms significa que el modelo es transparente para el usuario final.

Análisis de Fallos y Riesgos: Perspectiva Crítica y Mitigación

El despliegue de modelos *Transformer* en entornos de misión crítica de telecomunicaciones y finanzas conlleva riesgos intrínsecos que deben ser gestionados mediante un marco de observabilidad proactiva. El análisis experimental revela vulnerabilidades específicas que podrían comprometer la integridad del servicio si no se abordan desde una perspectiva de diseño resiliente

1. Análisis de Fallos: El Fenómeno de la Colisión Semántica

La simulación identificó una vulnerabilidad crítica denominada Colisión Semántica entre los códigos de estado HTTP 401 (*Unauthorized*) y 403 (*Forbidden*).

- Interpretación Crítica: A pesar de la robustez de BERT, la proximidad vectorial en el espacio latente de estas dos categorías genera una zona de ambigüedad diagnóstica. Al cuestionar el modelo, se observa que la IA prioriza el contexto léxico sobre la jerarquía técnica del protocolo.
- Riesgo Operativo: Un fallo en la discriminación de estos códigos impacta directamente en el enrutamiento de incidentes. Un error 401 suele requerir una re-autenticación automatizada (Capa de Seguridad), mientras que un 403 implica una revisión de políticas de acceso (Capa de Aplicación). Una clasificación errónea incrementa el Tiempo Medio de Resolución (MTTR) al asignar tickets al equipo de soporte inadecuado, degradando la eficiencia del equipo de SRE.

2. Clasificación y Jerarquización de Riesgos

La auditoría técnica permite categorizar los riesgos según su impacto en la continuidad del negocio y la integridad de los datos:

- Riesgo Ético y de Equidad (Sesgo Algorítmico): El análisis de fairness reveló un riesgo de sesgo oculto en operaciones minoritarias (flujo sum). Al cuestionar la representatividad del dataset, se identifica que el modelo podría "aprender" a ser más permisivo con los errores en los procesos de liquidación financiera frente a los de consulta. Esto constituye un riesgo de cumplimiento normativo y financiero, ya que una subestimación de fallos en el recaudo impacta directamente en el balance contable de la organización.
- Riesgo de Disponibilidad y Fatiga de Alertas: La generación de Falsos Positivos induce una degradación de la confianza en el sistema. Desde un punto de vista crítico, una precisión inferior al 85% transforma una herramienta de asistencia en una fuente de ruido. El riesgo sistémico es la desensibilización del personal

operativo ante alertas reales, lo que aumenta la probabilidad de un incidente de alto impacto no atendido.

- Riesgo de Infraestructura (Dependencia de Aceleración Hardware): La latencia actual de 2.35 ms es óptima bajo entornos con GPU. Sin embargo, el modelo presenta una alta sensibilidad al entorno de ejecución. El riesgo de disponibilidad surge al desplegar en arquitecturas basadas exclusivamente en CPU, donde el tiempo de inferencia podría exceder el umbral del SLA de 50 ms, convirtiendo la capa de monitoreo en un cuello de botella para la pasarela de pagos.

3. Estrategias de Mitigación y Optimización Arquitectónica

Para mitigar los riesgos identificados sin comprometer la capacidad predictiva, se proponen técnicas de compresión y refinamiento de modelos:

- *Quantization (Cuantización de Modelos)*: Consiste en la transición de representaciones de punto flotante de alta precisión (FP32) a formatos de menor bit (INT8). Técnicamente, esto reduce la huella de memoria y acelera la computación a nivel de registros de CPU. Críticamente, esta técnica implica un *trade-off*: una ganancia masiva en *throughput* (rendimiento) a cambio de una mínima pérdida de precisión. Para una pasarela de pagos, este intercambio es aceptable, ya que la estabilidad de la latencia es prioritaria sobre decimales de precisión en el F1-Score.
- *Knowledge Distillation (Destilación de Conocimiento)*: Se propone el entrenamiento de una red "estudiante" (ej. DistilBERT) que emule la distribución de probabilidad de la red "maestra" original. Esta técnica mitiga el riesgo de disponibilidad al generar un modelo más ligero que retiene el 97% del conocimiento del modelo original pero con una reducción del 40% en tamaño y latencia. Es la solución estratégica para garantizar que el RCA se mantenga en tiempo real independientemente de la carga transaccional del sistema.

Conclusión

La validación exhaustiva mediante escenarios críticos permite concluir que la arquitectura BERT implementada no es solo un artefacto de alta precisión estadística, sino una solución industrially resilient diseñada para las exigencias de alta disponibilidad del sector financiero. El éxito del modelo radica en su capacidad para mantener un F1-Score de 0.80 incluso bajo condiciones de "mutilación semántica" (pérdida del 65% de la traza del log), una cifra que supera masivamente la fragilidad de los sistemas tradicionales basados en reglas. Esta resiliencia asegura que la gestión de incidentes en la pasarela de pagos no se vea interrumpida por la entropía natural de las redes de telemetría.

No obstante, el hallazgo del punto de quiebre algorítmico (colapso del F1-Score ante la corrupción estructural de caracteres) establece una frontera clara para la Gobernanza de TI: mientras que el sistema es inmune a la pérdida de datos, es vulnerable a la degradación de la integridad del *encoding*. Por lo tanto, se concluye que la viabilidad del proyecto no depende exclusivamente del modelo, sino de la salud del pipeline de datos.

Desde la perspectiva operativa, la latencia de 2.35 ms bajo carga máxima garantiza que la capa de Inteligencia Artificial actúa como un componente transparente, cumpliendo con los SLA de 50 ms sin añadir fricción al flujo transaccional. Sin embargo, la preparación para producción queda condicionada a la integración de un marco de MLOps robusto. Este marco debe trascender el monitoreo estático para implementar una observabilidad dinámica que detecte el Data Drift de forma temprana, permitiendo re-entrenamientos preventivos antes de que la degradación del modelo impacte el Tiempo Medio de Resolución (MTTR) (Buda et al., 2018; Mehrabi et al., 2021).

En última instancia, este workshop certifica que el modelo está preparado para su despliegue, proporcionando al equipo de SRE una herramienta de diagnóstico con una robustez probada, capaz de proteger la integridad del recaudo y la facturación ante la complejidad inherente de los microservicios modernos (Guo et al., 2021).

Nota sobre el Enfoque SRE y MLOps en Ecosistemas de Alta Criticidad: Dada la experiencia en el sector de telecomunicaciones, se identifica que el enfoque SRE (Site Reliability Engineering) es vital para la supervivencia de los sistemas de facturación, recaudo y cobranza. En estos ecosistemas, la indisponibilidad de la plataforma se traduce directamente en pérdidas de ingresos y degradación de la confianza del suscriptor. La implementación de modelos AIOps bajo una cultura SRE permite automatizar la observabilidad. Por su parte, MLOps garantiza que la inteligencia desplegada no se convierta en un activo obsoleto. En telecomunicaciones, donde las arquitecturas de software cambian con alta frecuencia, MLOps asegura que el modelo BERT mantenga su validez diagnóstica a pesar de las actualizaciones de infraestructura o cambios en los patrones de consumo de los clientes.

Referencias

Buda, M., Maki, A., & Mazurowski, M. A. (2018). A systematic study of the class imbalance problem in convolutional neural networks. *Neural Networks*, *106*, 249–259. https://doi.org/10.1016/j.neunet.2018.07.011

Guo, H., Yuan, S., & Wu, X. (2021). LogBERT: Log anomaly detection via BERT. *Proceedings of the International Joint Conference on Neural Networks (IJCNN)*, 1–8. https://doi.org/10.1109/IJCNN52387.2021.9534113

Mehrabi, N., Morstatter, F., Saxena, N., Lerman, K., & Galstyan, A. (2021). A survey on bias and fairness in machine learning. *ACM Computing Surveys*, *54*(6), 1–35. https://doi.org/10.1145/3457607